

Hutchinson 手法に基づく行列対角化を用いた 2 次近似勾配学習法に関する研究

山富 龍[†] マハブービ シェヘラザード[†] 二宮 洋[†]

[†] 湘南工科大学情報工学科 〒251-8511 神奈川県藤沢市辻堂西海岸 1-1-25

E-mail: {19A3211@sit, 20T2503@sit, ninomiya@info}.shonan-it.ac.jp

あらまし 本研究では、ニュートン法の計算コスト削減を目指した新しい 2 次近似勾配法に基づく学習アルゴリズムを提案する。ニューラルネットワーク (NN) の学習において、1 次近似勾配法は計算コストが低いため、一般的に使用されている。しかし、非線形問題の最適化において、1 次近似勾配法は解を得る為に多くの反復を必要とし、問題の非線形性の強さによっては現実的な時間で解を得ることができない。一方、この問題に対して有効とされている 2 次近似勾配法のニュートン法に基づく学習アルゴリズムでは、ヘッセ行列が使用されているため計算コストが高く、大規模な非線形問題に対する学習が困難となる。そこで本研究では、ニュートン法の計算コストを削減に着目し、ヘッセ行列を対角行列に近似できる Hutchinson 手法に基づく行列対角化手法をニュートン法に導入した新たな学習アルゴリズム Hutchinson 対角化ニュートン法 (HdN) を提案する。提案手法を NN の学習に応用し、その有効性を実験により示す。

キーワード ニューラルネットワーク, 学習アルゴリズム, ニュートン法, ヘッセ行列近似法, Hutchinson 手法

On the Study of Second-Order Training Algorithm using Matrix Diagonalization based on Hutchinson estimation

Ryo YAMATOMI[†], Shahrzad MAHBOUBI[†], and Hiroshi NINOMIYA[†]

[†] Shonan Institute of Technology 1-1-25 Tsujido Nishikaigan, Fujisawa, Kanagawa, 251-8511 Japan

E-mail: {19A3211@sit, 20T2503@sit, ninomiya@info}.shonan-it.ac.jp

Abstract In this study, we propose a new training algorithm based on the second-order approximated gradient method, which aims to reduce the computational cost of the Newton method. In neural network (NN) training, the first-order approximate gradient methods are commonly used because of its low computational cost. However, when applied to highly nonlinear problems, first-order methods still converge too slowly, and optimization error cannot effectively reduced within finite time despite its advantages. On the other hand, the training algorithm based on Newton method which is considered effective for this problem, is computationally expensive because it uses Hessian matrices, making it difficult to train for large-scale nonlinear problems. In this study, we focus on reducing the computational cost of the Newton method and propose a new learning algorithm as Hutchinson diagonalized Newton method (HdN), which is realized by the approximated diagonal Hessian matrix using the diagonal matrix based on Hutchinson estimator. We apply the proposed method to the training of NN, and the performance of the proposed method is demonstrated through computer simulations.

Key words Neural network, training algorithm, Newton method, Hessian approximation scheme, Hutchinson estimator

1. ま え が き

近年, IoT の急速な進化により, 多様かつ膨大なデータの取得, 及び, 蓄積が可能になった。これに伴い, データの複雑 (非線形) 性は増し, その量は日々増加しつつある。従って, 大規模かつ非線形性が強い (強非線形) データの高精度かつ高速な処理が可能となる技術が必要である。これを可能とする技術の一

つとして人工知能 (AI) が注目され, 幅広く応用されている。AI の急速な発展における核となる技術はニューラルネットワーク (NN) である。NN において高精度な学習を実現するためには, 学習アルゴリズムが重要であり, 一般的に勾配学習法が用いられている [1]。勾配学習法は学習率の形状から 1 次近似勾配法と 2 次近似勾配法に分類することができる。1 次近似勾配法では学習率はスカラーであり, 計算効率の観点から広く応用され,

代表的なアルゴリズムの一つとして Adam [2] が挙げられる。しかし、1 次近似手法では強非線形性を内包する学習データの高精度な学習に対して、現実的な時間における学習が困難である [3]。このため、強非線形データの学習には目的関数の曲率情報を利用した、2 次近似手法が有効とされている。2 次近似手法の基礎となるアルゴリズムとしてニュートン (Newton) 法が挙げられる [4]。しかし、Newton 法では各反復で、ヘッセ行列の導出、及び、逆行列が必要であるため、計算コストが 1 次近似勾配法と比較して非常に高いという欠点を持つ。近年、この問題を解決するために、様々なアプローチが行われてきた。その一例として、準ニュートン法 (QN)、及び、記憶制限準ニュートン法 (LQN) が挙げられる [4]。これらの改良手法、特に LQN は計算コストの削減と共に高い学習精度の維持が特徴である一方で、計算コストは 1 次近似勾配法と比較して高いままである。

本研究では強非線形の問題に対する高精度な学習を維持しながら 1 次近似勾配法に近い計算コストを得るため、Hutchinson 手法に基づく行列対角化手法に着目し、ニュートン法に導入した新しい手法、Hutchinson 対角化ニュートン法 (Hutchinson Diagonalized Newton, HdN) を提案する。提案手法は 2 つの分類問題を通して、従来手法と比較を行った上、その有効性をシミュレーションにより示す。

2. ニューラルネットワークの学習と 1 次近似勾配学習法

本研究で対象とする NN は、入出力関係として (1) の関係を持つ階層型 NN を考える。

$$\mathbf{o}_p = f_{NN}(\mathbf{w}, \mathbf{x}_p) \quad (1)$$

ここで、 $\mathbf{x}_p$ は p 番目の入力ベクトルを、 $\mathbf{o}_p$ は $\mathbf{x}_p$ に対する NN の出力ベクトルを示す。また、NN の重みベクトルを $\mathbf{w} \in \mathbb{R}^n$ とする。 p 番目の教師信号ベクトルを $\mathbf{d}_p$ とすると、誤差関数は (2) として定義される。

$$\min_{\mathbf{w} \in \mathbb{R}^n} E(\mathbf{w}) = \frac{1}{|T_r|} \sum_{p \in T_r} E_p(\mathbf{w}). \quad (2)$$

ここで、(2) の T_r は学習データセット、 $\{\mathbf{x}_p, \mathbf{d}_p\}, p \in T_r$ を示し、サンプル数を $|T_r|$ と表す。学習は NN の重み $\mathbf{w}$ に関して (2) を最小化する無制約最適化問題となる。

2.1 1 次近似勾配学習法

1 次近似勾配法における基本的なアルゴリズムの更新ベクトルは (3) に示す最急降下法 (GD) である。

$$\mathbf{v}_{k+1} = -\eta \nabla E(\mathbf{w}_k). \quad (3)$$

ここで $\nabla E(\mathbf{w}_k)$ は $E(\mathbf{w})$ の勾配ベクトルであり、 η は学習率であり、スカラーを用いる。1 次近似手法では学習率がスカラーであるため、計算コストが低く、一般的に使用されている。近年、GD の高速化アルゴリズムとして提案された Adam の更新ベクトルを (4) に示す [2]。

$$\begin{aligned} v_{k+1,i} &= -\eta \frac{m_{k,i}}{\sqrt{\theta_{k,i} + \lambda}}, \\ m_{k,i} &= \rho_1 m_{k-1,i} + (1 - \rho_1) \nabla E(\mathbf{w}_k)_i, \\ \theta_{k,i} &= \rho_2 \theta_{k-1,i} + (1 - \rho_2) (\nabla E(\mathbf{w}_k)_i)^2. \end{aligned} \quad (4)$$

ここで、 $\rho_1 = 0.9, \rho_2 = 0.999, \lambda = 10^{-8}$ を通常用いる。Adam は 1 次近似勾配法において、もっとも有名なアルゴリズムであり、一般に使用されている [1]。しかし、強非線形問題の最適化において、収束までに多くの時間を必要とする。

2.2 2 次近似勾配学習法: Newton 法

2 次近似勾配学習法における基礎アルゴリズムは Newton 法である [4]。Newton 法は $E(\mathbf{w})$ を $\mathbf{w}_k$ のまわりで 2 次の項までテーラー展開で近似することで導出される。

$$E(\mathbf{w}) \approx \hat{E}(\mathbf{w}) = E(\mathbf{w}_k) + \nabla E(\mathbf{w}_k) \Delta \mathbf{w} + \frac{1}{2} \Delta \mathbf{w}^T \nabla^2 E(\mathbf{w}_k) \Delta \mathbf{w}. \quad (5)$$

ここで、 $\Delta \mathbf{w} = \mathbf{w} - \mathbf{w}_k$ であり、 $\nabla^2 E(\mathbf{w}_k)$ は $E(\mathbf{w}_k)$ の曲率情報を示すヘッセ行列である。(5) の最適解は、 $\frac{\partial \hat{E}(\mathbf{w})}{\partial \mathbf{w}} = 0$ とおくと、(6) となる。

$$\Delta \mathbf{w} = -\nabla^2 E(\mathbf{w}_k)^{-1} \nabla E(\mathbf{w}_k), \quad (6)$$

ここで、 $\mathbf{w}$ の更新量 $\Delta \mathbf{w}$ を $\mathbf{w}_k$ から $\mathbf{w}_{k+1}$ への移動方向と考えると、 $\Delta \mathbf{w} = \mathbf{w}_{k+1} - \mathbf{w}_k$ と考えられる。従って、Newton 法の更新ベクトルをスカラーである学習率 η を用いて (7) と示すことができる。

$$\mathbf{v}_{k+1} = -\eta \nabla^2 E(\mathbf{w}_k)^{-1} \nabla E(\mathbf{w}_k). \quad (7)$$

Newton 法は強非線形問題に対して高い収束速度を持つ。しかし、この手法では更新ベクトルにヘッセ行列を求める必要があるため、計算コストが高いという欠点がある。

2.3 Hutchinson 推定手法

Hutchinson 推定手法は確率的に行列のトレース (対角和) を推定する方法である [5] [6]。とある行列 $\mathbf{A}$ のトレース $tr(\mathbf{A})$ を推定するために、行列 $\mathbf{A}$ とラージマッヘル分布に基づき生成された -1 と 1 で構成されるランダムベクトル $\mathbf{z}$ を用いて、 $\mathbf{z}^T \mathbf{A} \mathbf{z}$ を s 回計算し、その平均により近似を求める手法である [5]-[7]。従って、 $tr(\mathbf{A})$ は (8) の様に求めることができる。

$$tr(\mathbf{A}) \approx \frac{1}{s} \sum_{r=1}^s \mathbf{z}_r^T \mathbf{A} \mathbf{z}_r. \quad (8)$$

(8) は行列 $\mathbf{A}$ の対角化の推定問題にも容易に応用できる [6]。

3. 提案手法: Hutchinson 対角化 Newton 法

本研究では、Newton 法の高精度な学習を維持しながら、計算コストの削減を行うために、Hutchinson 手法に基づく行列対角化に着目し、Newton 法のヘッセ行列を対角化に近似した Hutchinson 対角化 Newton 法 (HdN) を提案する。提案手法 HdN では、Hutchinson 手法に基づく行列対角化を用いて、Newton 法のヘッセ行列を (9) のように対角化する手法を NN の学習に導入する。

$$\text{diag}(\mathbf{H}_k) \approx \left[\sum_{r=1}^s \mathbf{z}_r \otimes \mathbf{H}_k \mathbf{z}_r \right] \oslash \left[\sum_{r=1}^s \mathbf{z}_r \otimes \mathbf{z}_r \right]. \quad (9)$$

ここで、 $\mathbf{H}_k = \nabla^2 E(\mathbf{w}_k)$ はヘッセ行列を表し、 $\mathbf{z}$ は 1 と -1 のみで構成されているランダムに生成されたベクトル、 s は近似回数を示す。また、 $\otimes$ はアダマール乗算、 $\oslash$ はアダマール除算を表す。(9) はヘッセ行列の対角化を示している一方、(9) を求めるために、ヘッセ行列を使用している。そこで本研究では、ヘッセ行列とベクトルの内積である $\mathbf{H}_k \mathbf{z}_r$ を (10) に示すように勾配ベクトル $\nabla E(\mathbf{w}_k)$ と $\mathbf{z}_r$ ベクトルの内積 $(\nabla E(\mathbf{w}_k) \mathbf{z}_r)$ を $\mathbf{w}$ で微分したものとして近似することでヘッセ行列の計算を削減する。

$$\begin{aligned} \frac{\partial \nabla E(\mathbf{w}_k)^T \mathbf{z}_r}{\partial \mathbf{w}_k} &= \frac{\partial \nabla E(\mathbf{w}_k)^T}{\partial \mathbf{w}_k} \mathbf{z}_r + \nabla E(\mathbf{w}_k)^T \frac{\partial \mathbf{z}_r}{\partial \nabla E(\mathbf{w}_k)} \\ &= \frac{\partial \nabla E(\mathbf{w}_k)^T}{\partial \mathbf{w}_k} \mathbf{z}_r = \mathbf{H}_k \mathbf{z}_r. \end{aligned} \quad (10)$$

ここで、(10) を (9) に代入することで、(11) ヘッセ行列の対角化をヘッセ行列を使用せずに求めることができる。

$$\text{diag}(\mathbf{H}_k) \approx \left[\sum_{r=1}^s \mathbf{z}_r \otimes \frac{\partial \nabla E(\mathbf{w}_k)^T \mathbf{z}_r}{\partial \mathbf{w}_k} \right] \oslash \left[\sum_{r=1}^s \mathbf{z}_r \otimes \mathbf{z}_r \right]. \quad (11)$$

従って、提案手法 HdN の更新ベクトルは $\lambda_k = \text{diag}(\mathbf{H}_k)$ を用いて、(12) のように示される。

$$\mathbf{v}_{k+1} = -\eta \lambda_k^{-1} \nabla E(\mathbf{w}_k). \quad (12)$$

提案手法 HdN と Hutchinson 対角化を用いたヘッセ行列の対角化のアルゴリズムをそれぞれ Algorithm 1 と 2 に示す。

Algorithm 1 Hutchinson diagonalized Newton method (HdN)

Require: $\mathbf{w}_0$: Initial Parameters, η : Learning Rate

- 1: **for** 0, 1, 2..., k **do**
 - 2: Calculate $\nabla E(\mathbf{w}_k)$
 - 3: Compute $\mathbf{D}_k$ based on Algorithm 2
 - 4: $\mathbf{v}_{k+1} = -\eta \lambda_k^{-1} \nabla E(\mathbf{w}_k)$
 - 5: $\mathbf{w}_{k+1} = \mathbf{w}_k + \mathbf{v}_{k+1}$
 - 6: **end for**
-

Algorithm 2 Hessian diagonal estimator based on Hutchinson

Require: $\mathbf{z}$ = zero vector, λ = zero vector

- 1: **for** 1, 2, 3, ..., s **do**
 - 2: $\mathbf{z}_s$ = generate random vector consisted ± 1
 - 3: $\lambda_s = \mathbf{z}_s \otimes \frac{\partial \nabla E(\mathbf{w}_k)^T \mathbf{z}_s}{\partial \mathbf{w}_k}$
 - 4: $\lambda = \lambda + \lambda_s$
 - 5: $\mathbf{z} = \mathbf{z} + \mathbf{z}_s$
 - 6: **end for**
 - 7: **return** $\lambda \oslash \mathbf{z}$
-

4. 実験

提案手法 HdN の有効性を示すため、2 つの画像分類問題に対し実験を行い、従来手法の SGD [1], Adam [2] と比較を行った。実験は、ミニバッチ学習法を採用した。ミニバッチ学習法とは、1 反復で学習データセット T_r からランダムに抽出され

た $X \subseteq T_r$ 個のデータを用いて学習する手法である。従って、誤差関数 $E(\mathbf{w})$ は (13) に示す交差エントロピーであり、出力層の活性化関数は (14) の SoftMax 関数である。なお本研究で使ったネットワークの中間層には (15) のシグモイド関数を用いた。

$$E_b(\mathbf{w}) = -\frac{1}{b} \sum_{p \in X} \sum_{l=1}^L d_{p,l} \log(o_{p,l}), \quad (13)$$

$$\text{softmax}(o_{p,l}) = \frac{\exp(f_{p,l})}{\sum_{l=1}^L \exp(f_{p,l})}. \quad (14)$$

$$\text{sigmoid}(\mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{x})}. \quad (15)$$

ここで、 $b = |X|$ はミニバッチサイズであり、フルバッチ手法の場合 $X = T_r$, $b = |T_r|$ となる。 $d_{p,l}$ と $o_{p,l}$ はそれぞれ d_p と o_p の l 番目の要素であり、 L は出力のユニット、分類クラス数である。さらに、 $f_{p,l}$ は活性化関数前の出力 f_p の l 番目の要素である。SGD, Adam そして HdN の学習率をそれぞれ $\eta = 0.01, 0.001, 0.05$ とした。Adam で使用されるハイパーパラメータは [1] に基づいて設定した。提案手法 HdN の対角ヘッセ行列の近似の回数 $s = 5$ とした。なお、学習の終了条件は最大反復回数 $Epoch = k_{max}$ とし、実験環境には Google Colabatory [8] と TensorFlow [9] を使用した。

4.1 Iris : アヤメの分類問題

提案手法 HdN の有効性を示すため、まず Iris データ [10] を用いて実験を行った。この問題はアヤメの萼片の長さ、幅、及び、花弁の長さ、幅によって 3 種類のヒオウギアヤメ、ブルーフラッグそしてバージニカに分類する問題である。データサンプル数は $|T| = 150$ である。本実験では、ランダムにサンプルの 80% (120 個) を学習データ T_r に、20% (30 個) をテストデータ T_s に使用した。ネットワークには 10 個のニューロンを持つ中間層 1 層を使用した。従って、NN の構造は 4-10-3 となる。ミニバッチサイズ $b = 4$ であり、最大反復回数 $k_{max} = 100$ とした。実験結果を図 1 と 2 に示す。図 1 は、横軸は反復回数、縦軸は log スケールの学習誤差であり、反復回数毎の学習誤差の関係性を示す。図より、提案手法 HdN は誤差関数の曲率情報であるヘッセ行列の対角化を行っているため、学習初期の段階で SGD や Adam よりも小さな誤差を得られていることが分かる。さらに、最大反復回数以内ではもっとも低い誤差を得ている。一方で、SGD や Adam は HdN と同様な誤差を得るに




図 1 Iris の反復回数と学習誤差の関係。




図2 Iris の反復回数とテスト精度の関係。

は、より多くの反復回数が必要である。図2では横軸が反復回数、縦軸がテストの精度を表し、反復回数毎のテスト精度の変化を示すグラフである。この図でも、HdNが学習誤差同様に早い段階で高いテスト精度を得ていることがわかる。

4.2 手書き数字文字 MNIST の分類問題

次に、HdNの有効性を 28×28 手書き数字 MNIST [11] に対して調べた。この問題では 28×28 ピクセルの画像を 0 から 9 まで、合計 10 個のクラスに分類する問題である。学習サンプル数 $|T_r| = 60,000$ 、テストサンプル数 $|T_e| = 10,000$ である。ネットワークには 10 個のニューロン数を持つ中間層 1 層を使用した。従って、NN の構造は $784-10-10$ となり、最大反復回数 $k_{max} = 20$ とし、ミニバッチサイズ $b = 256$ とした。実験の結果を図3と4に示す。図3は横軸は反復回数、縦軸は $\log$ スケールの学習誤差であり、反復回数毎の学習誤差を示す。この問題でも、先ほどと同様に少ない反復回数の中で提案手法 HdN が他のアルゴリズムよりも、早い段階で小さな誤差を得ている。図4では横軸は反復回数、縦軸はテストの精度を表すグラフである。図4からもこれまでと同様に HdN が早い段階で高い精度を得ていることがわかる。従って、提案手法 HdN は短い反復回数において高精度な学習を行うことができると結論付けられる。

5. ま と め

本研究では、ニュートン法の計算コスト削減を目指した新しい2次近似勾配法に基づく学習アルゴリズムを Hutchinson 対角化ニュートン法 (Hutchinson Diagonalized Newton method, HdN) を提案した。提案手法は Hutchinson 手法に基づく行列対角化手




図3 MNIST の反復回数と学習誤差の関係。




図4 MNIST の反復回数とテスト精度の関係。

法を用いてニュートン法のヘッセ行列を対角行列に近似することでニュートン法の計算コストを削減した。提案手法 HdN は2つの分類問題を用いて、SGD と Adam との比較した。結果として、その有効性、少ない反復回数で高い精度を持つことを示した。今後の課題として、HdN のハイパーパラメータである行列対角化回数 s の最適値に対して調査することが挙げられる。また大規模なデータの学習における提案手法の有効性の調査も必要となる。なお、本研究では、HdN の高速化を目指し、[3] と同様に慣性項の導入も検討している。

謝辞

本研究の一部は科研費基盤研究 (c)(課題番号:20K11979) の補助を得た。ここに謝意を表する。

文 献

- [1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [2] D. P. Kingma, and J. Ba, "Adam: A Method for Stochastic Optimization", *Proc. ICLR*, pp. 1–13, 2015.
- [3] H. Ninomiya, "A novel quasi-Newton optimization for neural network training incorporating Nesterov's accelerated gradient", *NOLTA*, vol. E8–N, no. 4, pp. 289–301, 2017.
- [4] J. Nocedal, and S. J. Wright: *Numerical Optimization Second Edition*, Springer Science & Business Media, 2006.
- [5] M. F. Hutchinson, "A stochastic estimator of the trace of the influence matrix for laplacian smoothing splines", *Communications in Statistics-Simulation and Computation*, vol. 19, no. 2, pp. 433–450, 1990.
- [6] C. Bekas, E. Kokiopoulou, and Y. Saad, "An Estimator for the Diagonal of a matrix", *Applied numerical mathematics*, vol. 57, no. 11–12, pp. 1214–1229, 2007.
- [7] Z. Yao, A. Gholami, S. Shen, M. Mustafa, K. Keutzer and M. Mahoney, M, "ADAHESIAN: An Adaptive Second Order Optimizer for Machine Learning", *Proc. AAAI*, vol. 35, no. 12, pp. 10665–10673, 2021.
- [8] Google Colab, <https://colab.research.google.com>. (last access 22 October 2021)
- [9] Tensorflow, <https://www.tensorflow.org>. (last access 22 October 2021)
- [10] R. A. Fisher, "The use of multiple measurements in taxonomic problems", *Annual Eugenics*, vol. 7, part. 2, pp. 179–188, 1936.
- [11] Y. LeCun, L. Bottou, Y. Bengio and P. Haffner, "Gradient-based learning applied to document recognition." *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.