

重み差分伝播法を用いた確率的勾配学習に関する研究

マハブービ シェヘラザード[†] 山富 龍[†] 二宮 洋[†]

[†] 湘南工科大学 〒251-8511 神奈川県藤沢市辻堂西海岸 1-1-25

E-mail: {20T2502@sit, 19A3211@sit, ninomiya@info}.shonan-it.ac.jp

あらまし 本研究では、誤差逆伝播法の計算コストの削減を目指した新たな学習手法を提案する。近年、IoT の急速な発展とともに、大規模なデータの学習が可能なニューラルネットワークを実装したマイクロコンピュータで処理する必要性が増加しつつある。一方で、搭載されているニューラルネットワークの学習は誤差逆伝播法に基づいているため、重みの更新に学習サンプル毎に出力層からの逆伝播が必要となり、ハードウェア及び計算コストが増加する。本研究では、この問題を解決するため、重みの更新に、重みと重みの更新量の積を用いた誤差逆伝播法の改良を試みる。これにより、ミニバッチ学習における学習サンプル毎の逆伝播がなくなり、ハードウェア及び計算コストの削減が実現できる可能性がある。提案手法の有効性をシミュレーションにより示す。

キーワード ニューラルネットワーク, 学習アルゴリズム, 確率的勾配降下法, 重み差分伝播法

On the Study of Stochastic Gradient Descent Learning using Weight Difference Propagation

Shahrzad MAHBOUBI[†], Ryo YAMATOMI[†], and Hiroshi NINOMIYA[†]

[†] Shonan Institute of Technology 1-1-25 Tsujido Nishikaigan, Fujisawa city, Kanagawa, 251-8511 Japan

E-mail: {20T2502@sit, 19A3211@sit, ninomiya@info}.shonan-it.ac.jp

Abstract In this paper, we propose a new training algorithm to reduce the computational cost of the error backpropagation method. In recent years, with the rapid development of the IoT, there has been an increasing need to process large-scale data on microcomputers equipped with neural networks capable of training. On the other hand, since the neural network implemented in the microcomputer is based on the error backpropagation method, the backpropagation of the difference of the output layer is required for each training sample to update the weights increases the hardware and computational cost. In order to solve this problem, we try to improve the error backpropagation method by using the weights and the updated amount of the weights for updating the weights. This method eliminates the need for backpropagation for each training sample in mini-batch training, thus reducing the hardware and computational cost. Simulations demonstrate the effectiveness of the proposed method.

Key words Neural network, gradient-based training algorithm, stochastic gradient descent method, weight difference propagation

1. はじめに

近年、情報通信技術の発達により様々な機器の IoT 化が進み、多様かつ膨大なデータの取得、及び、蓄積が可能になった。これに伴い、データの複雑（非線形）性とその量が日々増加している。従って、大規模かつ非線形データの高精度かつ高速な処理が可能となる技術が必要である。近年、これを可能とする技術の一つとして人工知能（AI）が注目され、機械工学、統計学、物理学、経済学、認知科学そして脳科学など幅広い分野で応用されている。AI の急速な発展における核となる技術は階層型ニューラルネットワーク（NN）である [1][2]。一般的に、NN は誤差逆伝

播法（BP、及び、SG）に基づく勾配学習アルゴリズムを用いて学習を行っている。誤差逆伝播法の学習は非常に優れたアルゴリズムであり、様々な改良手法も提案されている。改良手法の一つとしてビッグデータの学習を目的とした確率的勾配降下法（SGD）である [1]。しかし、BP に基づくアルゴリズムを用いた NN の学習において、重みの更新に対して学習サンプル毎に出力層からの逆伝播が必要である [3]。これは、IoT 機器に搭載されているマイクロコンピュータで処理する場合、計算コストが増加し、ハードウェアの負担に繋がる [3]。加えて、改良された BP のアルゴリズムでは、様々なパラメーターが追加されており、計算コストがさらに増している。従って、NN をマイク

ロコンピュータで処理したときの欠点の一つとして計算コストが挙げられる。この欠点を克服するために、逆伝播を必要としない新しいアルゴリズムが[3][4][5]で提案されている。しかし、これらのアルゴリズムは非同期的な並列学習ができない、もしくは、大規模データの学習に適していないため、まだ改良を必要とする。また、これらの論文では、提案アルゴリズムのシミュレーション実験が不足しており、近年の非線形データに対する学習精度が保障されていない。

本研究では、BPの欠点、及び、ビッグデータの処理の必要性に着目し、SGD改良手法として、確率的重み差分伝播法 (Stochastic Weight Difference Propagation, SWDP) を提案する。SWDPは従来のBPと異なり、重みの更新に次層の重みと重みの差分の積で学習が可能となる手法である。これにより、各層の各ニューロンの並列学習を可能にする。従って、ミニバッチ (確率的) 学習における学習サンプル毎の逆伝播が必要なくなり、ハードウェア、及び、計算コストの削減が実現できる。提案手法を、3つのベンチマーク問題を用いて従来手法のSGDと比較し、その有効性をシミュレーションより示す。

2. 確率的勾配降下法 : SGD

本研究で対象とするNNの学習とは、重みベクトル $\mathbf{w} \in \mathbb{R}^n$ に関して誤差関数 $E(\mathbf{w})$ を最小化する無制約最適化問題となる。

$$\min_{\mathbf{w} \in \mathbb{R}^n} E(\mathbf{w}). \quad (1)$$

BPでは、1 Epochで学習データセット T_r 全てを用いて学習を行い、その勾配を計算するフルバッチ手法に基づいている。従って、誤差関数 $E(\mathbf{w})$ は(2)として定義される。

$$E(\mathbf{w}) = \frac{1}{|T_r|} \sum_{p \in T_r} E_p(\mathbf{w}). \quad (2)$$

ここで、 $|T_r|$ はサンプル数、 p はサンプルパターン番号を示す。しかし、本研究で対象とする確率的学習法、別名ミニバッチ学習法と呼ぶ、1 Epochで T_r からランダムに抽出された $X \subseteq T_r$ 個のデータを用いて学習するため、この勾配は(3)に示す誤差関数 $E_b(\mathbf{w})$ によって求める。

$$E_b(\mathbf{w}) = \frac{1}{b} \sum_{p \in X} E_p(\mathbf{w}). \quad (3)$$

ここで、 $b = |X|$ はミニバッチサイズであり、フルバッチ手法の場合 $X = T_r, b = |T_r|$ となる。NNの入力の関係を

$$\mathbf{o}_p = \mathbf{x}_p^{out} = f_{NN}(\mathbf{w}, \mathbf{x}_p), \quad (4)$$

と定義する。 x_p, o_p はそれぞれ p 番目の入力と出力ベクトルである。対象とするNNの p 番目の入力に対する s 層の i 番目のニューロンの出力を $x_{i,p}^s$ ($1 \leq s \leq out$) とし、 $s-1$ 層の j 番目のニューロンから s 層の i 番目のニューロンへの重みを w_{ij}^s とすると、ニューロンの入出力関係は次のように与えられる。ここで、 out は出力層を表す。

$$x_{i,p}^s = f(z_{i,p}^s), \quad (5)$$

$$z_{i,p}^s = \sum_j w_{ij}^s x_{j,p}^{s-1}, \quad (6)$$

ただし、 $f(z_{i,p}^s)$ は活性化関数とする。ここで、 p 番目の入力に対する出力層の i 番目のユニットにするため、教師信号を $d_{i,p}$ とする。(1)の $\mathbf{w}$ は、ネットワークの各結合 w_{ij}^s を成分として持つ結合ベクトルを表す。ここで、SGDは、学習率 η を用いて、(7)の更新式によって定義される。

$$w_{ij}^s(t+1) = w_{ij}^s(t) - \eta \frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s}. \quad (7)$$

ここで、 t は反復回数を示し、

$$\frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} = \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial w_{ij}^s}, \quad (8)$$

は確率的勾配であり、連鎖律を用いて(9)のように示される。

$$\begin{aligned} \frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} &= \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} \cdot \frac{\partial x_{i,p}^s}{\partial z_{i,p}^s} \cdot \frac{\partial z_{i,p}^s}{\partial w_{ij}^s} = \\ &= \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1}, \end{aligned} \quad (9)$$

となる。ここで、 $f'(z_{i,p}^s)$ は活性化関数の微分となる。以下では、ニューロンが出力層の場合 ($s = out$) とそうでない場合に分けて勾配 $\partial E_b(\mathbf{w}) / \partial w_{ij}^s$ を求める。

► s が出力層 ($s = out$) の場合:

s が出力層の場合、 $\partial E_p(\mathbf{w}) / \partial x_{i,p}^s$ は誤差関数の微分となる。ここで、平均2乗誤差 (MSE) とシグモイド活性化関数、及び、交差エントロピー誤差 (CE) とソフトマックス活性化関数を用いた場合の2通りを示す。

1. MSE と sigmoid 関数の場合:

平均2乗誤差とシグモイド関数をそれぞれ(10)と(11)に示す。

$$E_b(\mathbf{w}) = \frac{1}{b} \sum_{p \in X} \frac{1}{2} \|d_{i,p} - x_{i,p}^{out}\|^2, \quad (10)$$

$$x_{i,p}^{out} = f(z_{i,p}^s) = \frac{1}{1 + \exp(-z_{i,p}^s)}. \quad (11)$$

ここで、(10)と(11)を用いたネットワークでは s が出力層である場合の $\partial E_b(\mathbf{w}) / \partial w_{ij}^s$ は(12)のように求まる。

$$\begin{aligned} &\frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1} \\ &= \frac{1}{b} \sum_{p \in X} -(d_{i,p} - x_{i,p}^{out}) \cdot x_{i,p}^{out} \cdot (1 - x_{i,p}^{out}) \cdot x_{j,p}^{s-1}. \end{aligned} \quad (12)$$

2. CE と softmax 関数の場合:

交差エントロピー誤差とソフトマックス関数をそれぞれ(13)と(14)に示す。

$$E_b(\mathbf{w}) = -\frac{1}{b} \sum_{p \in X} \sum_{l=1}^L d_{i,p,l} \log(x_{i,p,l}^{out}), \quad (13)$$

$$x_{i,p,l}^{out} = f((z_{i,p}^s)_l) = \frac{\exp((z_{i,p}^s)_l)}{\sum_{l=1}^L \exp((z_{i,p}^s)_l)}. \quad (14)$$

ここで、 $d_{i,p,l}$ と $x_{i,p,l}^{out}$ はそれぞれ $d_{i,p}$ と $x_{i,p}^{out}$ の l 番目の要素であり、 L は出力のユニット、別名分類クラス数である。ここで、(13) と (14) を用いたネットワークでは s が出力層である場合の $\partial E_b(\mathbf{w})/\partial w_{ij}^s$ は (15) のように求まる。

$$\frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1} = \frac{1}{b} \sum_{p \in X} (d_{i,p,l} - x_{i,p,l}^{out}) \cdot x_{j,p}^{s-1}. \quad (15)$$

► s が出力層以外の場合:

s 層の i 番目のニューロンの出力 $x_{i,p}^s$ が変化することによって $(s+1)$ 層の k 番目のニューロンの内部状態 $z_{k,p}^{s+1}$ が変化し、 $(s+1)$ 層の各ニューロンの出力も変化する。これらの変化が $(s+1)$ 層以降のニューロンを伝達し $E_p(\mathbf{w})$ の値を変動させ、(16) のように求まると考えられる。

$$\frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} = \frac{1}{b} \sum_{p \in X} \sum_k \frac{\partial E_p(\mathbf{w})}{\partial z_{k,p}^{s+1}} \cdot \frac{\partial z_{k,p}^{s+1}}{\partial x_{i,p}^s}. \quad (16)$$

(16) の右辺において、 $(s+1)$ 層の k 番目のニューロンへの内部状態 $z_{k,p}^{s+1}$ が変化することにより、そのニューロンの出力 $x_{k,p}^{s+1}$ を変化させ、従って、 $E_p(\mathbf{w})$ も変化させる。また、(16) の右辺の $\partial z_{k,p}^{s+1}/\partial x_{i,p}^s$ は (6) より、 w_{ki}^{s+1} であるため、(16) を (17) のように表すことができる。

$$\begin{aligned} \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{i,p}^s} &= \frac{1}{b} \sum_{p \in X} \sum_k \frac{\partial E_p(\mathbf{w})}{\partial z_{k,p}^{s+1}} \cdot \frac{\partial z_{k,p}^{s+1}}{\partial x_{i,p}^s} \\ &= \frac{1}{b} \sum_{p \in X} \sum_k \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot w_{ki}^{s+1}. \end{aligned} \quad (17)$$

(17) より、学習サンプル毎に出力層ニューロンの出力と教師信号との誤差が逆伝播することによって勾配を求めることができる。結果として、勾配は (18) で与えられる。

$$\frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} = \frac{1}{b} \sum_{p \in X} \sum_k \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot w_{ki}^{s+1} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1}. \quad (18)$$

3. 提案手法: 確率的勾配重み差分降下法 (SWDP)

本研究では、SGD の学習における計算コスト問題を解決した新しい手法、確率的重み差分伝播法 (Stochastic Weight Difference Propagation, SWDP) を提案する。SWDP は SGD の学習における学習サンプル毎の逆伝播に着目し、これを次層の重みと重みの差分の積の形で求めることで、学習サンプル毎の逆伝播を不要にする手法である。SWDP も SGD と同様に s 層のニューロンが出力層かそうでない場合を考える。

► s が出力層 ($s = out$) の場合:

s 層のニューロンが出力層の場合、 $E_p(\mathbf{w})$ は SGD と同様に定義されるため、同じ形となる。従って、勾配は (12) または (15) で求められる。

► s が出力層以外の場合:

s 層が出力層以外の場合、勾配 $\partial E_b(\mathbf{w})/\partial w_{ij}^s$ は (18) で与えら

れる。本提案手法では (18) からの変形を考える。

$$\frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} = \frac{1}{b} \sum_{p \in X} \sum_k \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot w_{ki}^{s+1} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1}. \quad (18)$$

$$= \sum_k \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot w_{ki}^{s+1} \cdot f'(z_{i,p}^s) \cdot x_{j,p}^{s-1} \quad (19)$$

$$= \sum_k \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot x_{i,p}^s \cdot w_{ki}^{s+1} \cdot \frac{f'(z_{i,p}^s)}{x_{i,p}^s} \cdot x_{j,p}^{s-1}. \quad (20)$$

ここで、 $x_{i,p}^s \neq 0$ と仮定した。また、学習サンプル p に関する和を分割する近似を行うと、

$$\begin{aligned} &\approx \sum_k \left(\frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot x_{i,p}^s \cdot w_{ki}^{s+1} \right) \cdot \left(\frac{1}{b} \sum_{p \in X} \frac{f'(z_{i,p}^s)}{x_{i,p}^s} \cdot x_{j,p}^{s-1} \right) \\ &= \sum_k \left(\frac{\partial E_p(\mathbf{w})}{\partial w_{ki}^{s+1}} \cdot w_{ki}^{s+1} \right) \cdot \left(\frac{1}{b} \sum_{p \in X} \frac{f'(z_{i,p}^s)}{x_{i,p}^s} \cdot x_{j,p}^{s-1} \right) \end{aligned} \quad (21)$$

ここで、(9) より、

$$\frac{\partial E_p(\mathbf{w})}{\partial w_{ki}^{s+1}} = \frac{1}{b} \sum_{p \in X} \frac{\partial E_p(\mathbf{w})}{\partial x_{k,p}^{s+1}} \cdot f'(z_{k,p}^{s+1}) \cdot x_{i,p}^s \quad (22)$$

を用いた。ここで、(7) で示す SGD を考える。(7) より、重みの更新量 (差分) Δw_{ki}^{s+1} を考えると、

$$\Delta w_{ki}^{s+1} = w_{ki}^{s+1}(t+1) - w_{ki}^{s+1}(t) = -\eta \frac{\partial E_p(\mathbf{w})}{\partial w_{ki}^{s+1}}, \quad (23)$$

となる。(23) を (21) に代入すると、

$$\frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} = \sum_k \left(-\frac{1}{\eta} \Delta w_{ki}^{s+1} \cdot w_{ki}^{s+1} \right) \cdot \left(\frac{1}{b} \sum_{p \in X} \frac{f'(z_{i,p}^s)}{x_{i,p}^s} \cdot x_{j,p}^{s-1} \right) \quad (24)$$

を得る。これを (7) に代入することにより、提案手法 SWDP は、

$$\begin{aligned} w_{ij}^s(t+1) &= w_{ij}^s(t) - \eta \frac{\partial E_b(\mathbf{w})}{\partial w_{ij}^s} \\ &= w_{ij}^s(t) + \sum_k \left(\frac{1}{\eta} \Delta w_{ki}^{s+1} \cdot w_{ki}^{s+1} \right) \cdot \left(\frac{1}{b} \sum_{p \in X} \frac{f'(z_{i,p}^s)}{x_{i,p}^s} \cdot x_{j,p}^{s-1} \right), \end{aligned} \quad (25)$$

となる。(25) より、学習サンプル毎の逆伝播は必要なくなり、次層に繋がる重みと重みの更新量の内積だけで学習ができることになる。従って、SGD と比較して学習構成は単純化され、計算コストが低くなりながらも、誤差伝播法に基づいているため、学習精度が維持されると期待できる。




図1 ミニバッチサイズと学習誤差の関係(左. 中間層1層, 右. 中間層2層).

4. 実験結果

本研究では, 提案手法 SWDP のパフォーマンスを調べるため, 3つのベンチマーク問題, 2ビットパリティ問題と2つの分類問題を用いて, SGD との比較を行った. ここでは, 全ての問題において SGD と SWDP の学習率 $\eta = 0.1$ と設定した. ミニバッチサイズは, 2ビットパリティ問題では $b = 1, 2$ そして3の3つであり, 分類では $b = 1, 2, 4, 6, 8, 10, 12, 14, 16, 18, 20$ そして32の12個とした. 終了条件は反復回数 = 500,000, 及び, $E(w) < 10^{-3}$ とした.

4.1 2ビットパリティ問題

最初の問題は, 2ビットパリティ問題である. この問題の学習データサンプル数 $|T_r| = 4$ であり, 入出力データは各点の座標である. 本実験では, 2つのネットワーク, 10個のニューロン数を持つ中間層1層と中間層2層を持つネットワークで学習を行った. 従って, それぞれNNの構造は, 2-10-2と2-10-10-2である. この実験では, 活性化関数は(11)に示すシグモイド関数そして誤差関数には(10)に示す平均2乗誤差を用いた. 実験結果を図1と2そして表1に示す. まず図1はミニバッチサイズ毎の学習誤差の変化を示しており, 横軸はミニバッチサイズ, 縦軸が学習誤差となっている. 図1では左のグラフは中間層1層, 右は中間層2層を持つNNの結果である. この図より, 中間層1層を用いたNNでは提案手法SWDPはSGDと同様な誤差を得ていることがわかる. また, NNの層の増加により, 若干のズレは生じるものの, ほぼ同様な誤差を得られている. 一方, 図2はミニバッチサイズ毎のEpoch数の変化を示し




図2 ミニバッチサイズとEpochの関係(左. 中間層1層, 右. 中間層2層).

表1 2ビットパリティ問題の計算時間とEpochの関係.

Algorithm	Mini batch Size	Epoch	Time (sec)	per Iteration Time(sec)
SGD	1 Hidden layer			
	1	987	0.463	0.00046
	2	1,000	0.284	0.00028
	3	1,334	0.177	0.00013
	2 Hidden layer			
	1	9,858	6.74	0.00068
	2	9,652	3.465	0.00035
	3	6,866	1.174	0.00017
SWDP	1 Hidden layer			
	1	987	0.045	0.000045
	2	6,723	0.144	0.000021
	3	24,168	0.296	0.000012
	2 Hidden layer			
	1	9,858	0.259	0.000026
	2	15,946	0.255	0.000015
	3	106,364	0.988	0.000009

ており, 横軸はミニバッチサイズ, 縦軸がEpoch数となっている. 図2も図1と同様に, 左のグラフは中間層1層, 右は中間層2層を持つNNの結果である. Epoch数の比較では, 提案手法SWDPは学習課程を簡略化しているため, SGDと同様な誤差を得るのに多くのEpoch数を必要とする. なお, ネットワークが多層になるにつれて, 両アルゴリズムは収束により多くのEpochを必要とするが, その関係性は変わらない. しかし, 表1に示す時間とEpochの関係では, 全体の計算時間はEpochの増加と共に増加する, 一方で, 1Epochにおける計算時間はSGDよりも少ない. これは学習サンプル毎の逆伝播の代わりに, 次層に繋がる重みと重みの更新量の内積だけで学習を行っているため, 計算コストが減少し, 高速化していると結論付けられる.

4.2 3-Spiral

次に, 分類問題である3-Spiral問題[6]に対して提案手法の有効性を調べる. 3-Spiralは図3に示す通り学習データサンプル $T_r = 1,050$ 個を3のクラスに分類する問題であり, 各クラスは350個のデータサンプルを持つ. 入力データは各点の座標であり, ネットワークには10個のニューロン数を持つ中間層1層を使用した. 従って, NNの構造は2-10-3となる. この問題は画像分類問題であるため, 中間層の活性化関数は(11)のシグモイド関数, 出力層の活性化関数は(14)のソフトマックス関数であり, 誤差関数は(13)に示す交差エントロピー誤差である. 実験結果を図4と5そして表2に示す. まず図4はミニバッチサイズ毎の学習精度の変化を示しており, 横軸はミニバッチサイズ, 縦軸が学習精度となっている. 図4より, ミニバッチサイズ=1, 及び, 2では提案手法とSGDは同様の精度を得ていることがわかる. しかし, ミニバッチサイズの増加により提案手法SWDPの精度は, 5%から最大で20% ($b = 10$) 程低下する. 従って, この問題の学習において, SWDPはミニバッチサイズ, 及び, 初期値には強く依存するものの, SGDの精度を最大20%ほどしか低下せずに, SGDと近い学習精度を得ることができる. 図5では, ミニバッチサイズ毎のEpoch数の変化を示しており, 横軸はミニバッチサイズ, 縦軸がEpoch数となっ




図3 3-Spiral.

ている。Epoch 数の比較では、最初の問題同様にミニバッチサイズの増加に伴い、SWDP は SGD よりも Epoch を必要とする。しかし、計算時間と Epoch 数をまとめた表 2 から、収束までの計算時間は Epoch と同様に増加しても、1 Epoch における計算時間は SGD よりも低いことが分かる。

4.3 8×8MNIST

最後の問題は図 6 に示す 8×8 ピクセルの手書き数字文字 [7] の分類問題である。8×8MNIST は図 6 に示す通り学習データサンプル $|T| = 1,797$ 個の手書き数字画像を 0 から 9 まで 10 個のクラスに分類する問題である。本実験では、ランダムにサンプルの 75% (1,347 個) を学習データ T_r に、25% (450 個) をテストデータ T_s に使用した。この問題では入力 64, 出力 10 であり、ネットワークには 10 個のニューロン数を持つ中間層 1 層を使用した。従って、NN の構造は 64-10-10 となる。この問題も前の問題と同様、分類問題であるため、中間層の活性化関数は (11) のシグモイド関数、出力層の活性化関数は (14) のソフトマックス関数、誤差関数は (13) の交差エントロピー誤差である。実験結果を図 7 と 8 として表 3 に示す。まず図 7 はミニバッチサイズ毎の学習精度の変化を示しており、横軸はミニバッチサイズ、縦軸が学習精度となっている。図 7 より、この問題では SGD と提案手法 SWDP の学習精度がほぼ等しいことが分かる。一方で、テスト精度に関してはミニバッチサイズの増加に伴い、最大 5% 程精度が低下する。従って、この問題でも、ミニバッチサイズと初期値に依存していることが結論付け




図4 ミニバッチサイズと精度の関係。




図5 ミニバッチサイズと Epoch の関係。

表2 3-Spiral の計算時間と Epoch の関係。

Algorithm	Mini batch Size	Epoch	Time (sec)	per Iteration Time(sec)
SGD	1	476	70.37	0.1478
	2	953	76.95	0.0807
	4	1,908	80.51	0.0421
	6	2,262	70.14	0.0310
	8	2,262	56.97	0.0251
	10	2,262	48.08	0.0212
	12	2,233	43.44	0.0194
	14	2,262	39.46	0.0174
	16	3,042	49.10	0.0161
	18	2,190	33.23	0.0151
	20	2,262	30.93	0.0136
	32	2,715	30.80	0.0113
SWDP	1	476	7.15	0.0150
	2	952	10.38	0.0109
	4	1,909	16.75	0.0087
	6	2,857	22.67	0.0079
	8	3,817	28.86	0.0075
	10	4,762	35.22	0.0073
	12	5,748	41.47	0.0072
	14	6,666	47.38	0.0071
	16	7,692	54.06	0.0070
	18	8,621	59.98	0.0069
	20	9,616	66.66	0.0069
	32	15,625	105.08	0.0067

られる。図 8 ではミニバッチサイズ毎の Epoch 数の変化を示しており、横軸はミニバッチサイズ、縦軸が Epoch 数となっている。Epoch 数の比較では、これまでと同様にミニバッチサイズの増加に伴い、SWDP はより多くの Epoch を必要とする。しかし、計算時間と Epoch 数をまとめた表 3 から、前の問題と同様に、1 Epoch における計算時間は SGD よりも低いことが分か




図6 8×8MNIST サンプル。




図7 ミニバッチサイズと精度の関係

る。従って、提案手法 SWDP は問題の非線形性、ミニバッチサイズ、及び、初期値に依存するが、従来手法の SGD と同じ学習性能を得ながらも、SGD の計算時間を減少し、高速化できていることが結論付けられる。

5. ま と め

本研究では、確率的勾配学習に基づいた誤差逆伝播法の計算コストの削減を目指した新たな学習法、確率的重み差分伝播法 (Stochastic Weight Difference Propagation, SWDP) を提案した。従来の誤差逆伝播法は、重みの更新に学習サンプル毎に出力層からの逆伝播が必要となり、ハードウェア、及び、計算コストが増加する欠点があった。しかし、提案手法の SWDP では、この問題を解決するため、重みの更新に、重みと重みの更新量の積を用いた誤差逆伝播法を行うことで、ミニバッチ学習における学習サンプル毎の逆伝播が必要なくなり、計算コストの削減が実現でき、ハードウェアのコストを低く抑制できる可能性を示すことができた。提案手法の有効性は3つのベンチマーク問題を通して、従来手法の SGD と比較し、シミュレーションより示した。今後の課題として、提案手法 SWDP は従来手法の SGD と同精度な学習が可能であるが、バッチサイズ、初期値、及び、問題の強非線形性に強く依存している。従って、より堅牢な学習が行えるように改良を必要とする。なお、大規模なデータに対する提案手法の有効性を調べると共に、本研究で




図8 ミニバッチサイズと Epoch の関係

表3 8×8MNIST の時間と Epoch 回数.

Algorithm	Mini batch Size	Epoch	Time (sec)	per Iteration Time(sec)
SGD	1	27	61.45	2.2762
	2	27	32.05	1.1873
	4	28	15.57	0.5563
	6	27	9.81	0.3636
	8	27	7.44	0.2757
	10	30	6.73	0.2243
	12	26	5.18	0.1993
	14	30	5.42	0.1807
	16	23	4.25	0.1851
	18	25	3.42	0.1371
	20	23	2.81	0.1224
	32	28	2.41	0.0863
SWDP	1	27	0.75	0.0279
	2	78	1.50	0.0192
	4	204	3.21	0.0157
	6	471	6.88	0.0146
	8	1,050	14.60	0.0139
	10	1,806	24.35	0.0134
	12	2,439	32.27	0.0132
	14	3,002	39.33	0.0131
	16	5,015	65.10	0.0129
	18	6,649	85.91	0.0129
	20	7,171	92.28	0.0128
	32	11,905	149.93	0.0125

は SWDP を FPGA などのハードウェアで実装し、その効果の検証も行う予定である。

謝辞

本研究の一部は科研費基盤研究 (c)(課題番号:20K11979) の補助を得た。ここに謝意を表する。

文 献

- [1] I. Goodfellow, Y. Bengio, and A. Courville, "Deep Learning", MIT Press, 2016.
- [2] S. Haykin: "Neural Networks and Learning Machines", Pearson (2009).
- [3] H. Ninomiya and N. Kinoshita, "A new learning algorithm without explicit error backpropagation", *Proc. IJCNN'99*, vol.2, No.99CH36339, pp. 1389–1392, 1999.
- [4] R. D. Brandt and F. Lin, "Supervised Learning in neural networks without explicit error back-propagation", *Proc. Annual Allerton Conference on Communication Control and Computing*, pp. 294–303, 1994.
- [5] R. D. Brandt and F. Lin, "Can supervised learning be achieved without explicit error back-propagation?", *Proc. IEEE International Conference on Neural Networks (ICNN)*, pp. 300–305, 1996.
- [6] J. Bassey, X. Li and L. Qian, "An Experimental Study of Multi-Layer Multi-Valued Neural Network", *Proc. IEEE International Conference on Data Intelligence and Security (ICDIS)*, pp. 233–236, 2019.
- [7] E. Alpaydin, and C. Kaynak, "Optical recognition of handwritten digits data set", *UCI Machine Learning Repository*, 1998.