

目的

- OASIS法にネステロフの加速勾配を導入し学習を高速化
- 学習が高速化したことを計算機実験にて示す

ニューラルネットワークの学習

- 誤差関数

$$E(\mathbf{w}) = \frac{1}{|T_r|} \sum_{p \in T_r} E_p(\mathbf{w}) \quad (1)$$

※ $\mathbf{w}$: ニューラルネットワークのパラメータ, T_r : 学習データ, $|T_r|$: 学習データ数

- パラメータの更新式

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mathbf{v}_{k+1} \quad (2)$$

※ $\mathbf{v}_{k+1}$: 更新ベクトル

Ex) 最急降下法 (Gradient Descent, GD) の更新ベクトル

$$\mathbf{v}_{k+1} = -\alpha \nabla E(\mathbf{w}_k) \quad (3)$$

※ $\nabla E(\mathbf{w}_k)$: 勾配, α : 学習率

従来手法 I

- ニュートン法の更新ベクトル
ニュートン法は二次近似手法の基となる学習アルゴリズム

$$\mathbf{v}_{k+1} = -\alpha \nabla^2 E(\mathbf{w}_k)^{-1} \nabla E(\mathbf{w}_k) \quad (4)$$

※ $\nabla^2 E(\mathbf{w}_k)$: ヘッセ行列

ニュートン法はヘッセ行列の逆行列の計算コストが高い

↓

ヘッセ行列を対角行列に近似し計算コストを削減 (HdN・OASIS)

- HdN[1], OASIS[2]
HdN, OASISはどちらもニュートン法のヘッセ行列を対角行列に置き換えた学習アルゴリズム。対角行列の求め方が異なる

- ◆ HdN, OASISの更新ベクトル

$$\mathbf{v}_{k+1} = -\alpha \nabla E(\mathbf{w}_k) \oslash \mathbf{h}_k \quad (5)$$

※ $\mathbf{h}_k$: 対角ヘッセ行列, $\oslash$: アダマール除算

- ◆ Hutchinson手法を用いたヘッセ行列の対角近似(HdN)

Hutchinson手法のヘッシアンノイズを複数のサンプルの平均を求め削減

$$\mathbf{h}_k = \frac{1}{s} \sum_l \mathbf{z}_l \otimes \frac{\partial (\nabla E(\mathbf{w}_k))^T \mathbf{z}_l}{\partial \mathbf{w}} \quad (6)$$

※ s : 近似サンプル数, $\otimes$: アダマール乗算, $\mathbf{z}$: -1 と 1 でできたランダムに生成されるベクトル

- ◆ Hutchinson手法を用いたヘッセ行列の対角近似(OASIS)

Hutchinson手法のヘッシアンノイズを指数平滑移動平均で削減
→ HdN法と比べ計算コストが低い

$$\mathbf{h}_k = \beta \mathbf{h}_{k-1} + (1 - \beta) \left(\mathbf{z}_l \otimes \frac{\partial (\nabla E(\mathbf{w}_k))^T \mathbf{z}_l}{\partial \mathbf{w}} \right) \quad (7)$$

※ β : 平滑化係数

従来手法 II

- モーメント法 (Classical Momentum, CM)
GDに慣性項を追加し、学習を高速化した学習アルゴリズム
◆ モーメント法の更新ベクトル

$$\mathbf{v}_{k+1} = \mu \mathbf{v}_k - \alpha \nabla E(\mathbf{w}_k) \quad (8)$$

※ μ : モーメント係数

- Nesterov's Accelerated Gradient descent method (NAG)[3]
モーメント法にネステロフの加速勾配を導入した学習アルゴリズム
◆ NAGの更新ベクトル

$$\mathbf{v}_{k+1} = \mu \mathbf{v}_k - \alpha \nabla E(\mathbf{w}_k + \mu \mathbf{v}_k) \quad (9)$$

※ $\nabla E(\mathbf{w}_k + \mu \mathbf{v}_k)$: ネステロフの加速勾配




図1 GDの最適化イメージ




図2 CMの最適化イメージ




図3 NAGの最適化イメージ

提案手法: OASIS + NAG

OASIS

+

NAG

- ◆ Hutchinson手法を用いたヘッセ行列の対角近似(OASIS+NAG)

$$\mathbf{h}_k = \beta \mathbf{h}_{k-1} + (1 - \beta) \left(\mathbf{z}_l \otimes \frac{\partial (\nabla E(\mathbf{w}_k + \mu \mathbf{v}_k))^T \mathbf{z}_l}{\partial \mathbf{w}} \right) \quad (10)$$

- ◆ OASIS + NAGの更新ベクトル

$$\mathbf{v}_{k+1} = \mu \mathbf{v}_k - \alpha \nabla E(\mathbf{w}_k + \mu \mathbf{v}_k) \oslash \mathbf{h}_k \quad (11)$$

- ◆ OASIS + NAGのアルゴリズム

Input $\mathbf{w}$: パラメータ, α : 学習率, μ : モーメント係数, β : 平滑化係数, s : 近似サンプル数

$$\mathbf{h}_0 = \frac{1}{s} \sum_l \mathbf{z}_l \otimes \frac{\partial (\nabla E(\mathbf{w}_0))^T \mathbf{z}_l}{\partial \mathbf{w}}$$

$$\mathbf{w}_1 = \mathbf{w}_0 - \alpha \nabla E(\mathbf{w}_0) \oslash \mathbf{h}_0$$

For 2, 3, ..., k

$$\mathbf{h}_k = \beta \mathbf{h}_{k-1} + (1 - \beta) \left(\mathbf{z}_l \otimes \frac{\partial (\nabla E(\mathbf{w}_k + \mu \mathbf{v}_k))^T \mathbf{z}_l}{\partial \mathbf{w}} \right)$$


$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu \mathbf{v}_k - \alpha \nabla E(\mathbf{w}_k + \mu \mathbf{v}_k) \oslash \mathbf{h}_k$$

End For

Return $\mathbf{w}$

実験

実験 I: Irisの分類問題



Epoch: 100, Batch Size: 120

[Hyper Parameter]

OASIS α : 0.1

OASIS+Momentum α : 0.1, μ : 0.8

OASIS+NAG α : 0.1, μ : 0.8, β : 0.99

ネステロフの加速勾配による学習の高速化を確認

実験 II: MNISTの分類問題

Epoch: 50, Batch Size: 1024

[Hyper Parameter]


Adam[4] α : 0.001

HdN α : 0.1, s : 3

OASIS α : 0.1

OASIS + NAG α : 0.1, μ : 0.99, β : 0.99

提案手法が従来手法と比べ低い損失を得ている



実験 III: MNISTの分類問題

(バッチサイズ比較)

ハイパーパラメータは実験 II と同様

提案手法がいかなるバッチサイズでも、Adamより高いスコアを得ることを確認

Batch Size	Adam		OASIS+NAG	
	Train Loss	Test Accuracy	Train Loss	Test Accuracy
512	0.827/0.767	0.75/0.77	0.391/0.367	0.883/0.89
1024	0.71/0.654	0.792/0.80	0.429/0.415	0.868/0.876
2048	0.698/0.667	0.794/0.812	0.486/0.48	0.851/0.86

5times Average / Best