

AutoEncoder と Pix2Seq を用いた大喜利生成 AI の実装に関する研究

山富 龍 マハブービ シェヘラザード 二宮 洋

湘南工科大学工学部 〒251-8511 神奈川県藤沢市辻堂西海岸 1-1-25

E-mail: {19a3211@sit, 20t2502@sit, ninomiya@info}.shonan-it.ac.jp

あらまし 本研究では、画像に対し大喜利を生成する AI の実装を試みる。画像を入力とし文章を出力する Pix2Seq では、一般的に、画像の特徴抽出器として事前学習済みの大規模画像認識モデルを使用する。しかし、この方法を用いる際、事前学習時の画像ドメインと Pix2Seq の学習時の画像ドメイン間に乖離がある場合、画像の特徴を抽出することが困難である。本研究では、この問題を解決するため、学習時にアノテーションを必要としない AutoEncoder に Pix2Seq の学習時の画像を学習させ、そのエンコーダを Pix2Seq の画像の特徴抽出器として用いる新たな Pix2Seq の学習モデルを提案する。実験として提案手法を用い大喜利生成 AI を実装し、アンケートにより大喜利生成 AI の性能を評価する。

キーワード 大喜利生成 AI, ニューラルネットワーク, Pix2Seq, AutoEncoder

Study on the Implementation of AI for Generating Humorous Response Sentence to Image Using AutoEncoder and Pix2Seq

Ryo YAMATOMI Shahrzad MAHBOUBI and Hiroshi NINOMIYA

Shonan Institute of Technology 1-1-25 Tsujido Nishikaigan, Fujisawa, Kanagawa, 251-8511 Japan

E-mail: {19a3211@sit, 20t2502@sit, ninomiya@info}.shonan-it.ac.jp

Abstract In this study, we attempt to implement an AI that can generate a humorous response for an image. Pix2Seq, which takes images as input and output sentences, generally uses a pre-trained large-scale image recognition model as an image encoder. However, if there is a discrepancy between the pre-trained image domain and the Pix2Seq training domain, image features cannot be extracted. To solve this problem, we propose a new learning model for Pix2Seq that uses AutoEncoder, which does not require annotation, to learn Pix2Seq training images and then uses the encoder as a feature extractor for Pix2Seq images. As an experiment, we implement the proposed method in an AI that can generate a humorous response for an image and evaluate the performance of the humorous response by a questionnaire.

Keywords Ogiri(Japanese Joke) AI, Neural Network, Pix2Seq, AutoEncoder

1. はじめに

近年、情報通信技術の発展により、膨大かつ複雑なデータの収集及び蓄積が可能となった。それに伴い、取得したデータを高速かつ高精度に処理する手段として AI が高い注目を集めている。AI は流通や自動運転などの実益に関わる分野のみならず、絵画や音楽といった芸術分野でも活用されている。しかし、AI を芸能分野に活用した例は少ない。笑いは日常生活において重要な要素だが、近年の感染症の影響により人々からコミュニケーションは減少しており、それに伴い日常から笑いの機会も失われている。よって、感染症の恐れのない AI による笑いの提供に需要があると考えられる。[1]では、画像を入力とし大喜利を出力とする AI を実装するため、画像に対し大喜利を投稿できる WEB サイトである bokete[2]の画像と大喜利をスクレイピングし、収集したデータを Pix2Seq[3]に学習させるこ

とで大喜利生成 AI を実装する方法を提案している。

また、[1]では、事前学習済みの ResNet152 を画像の特徴抽出器とした Pix2Seq に対し、作成したデータセットを学習させることで大喜利生成 AI を実装しており、アンケートにより実装した大喜利生成 AI の性能を評価している。[1]で実装された大喜利生成 AI は大喜利らしい文章を生成する例もあるが、画像と関連性の低い大喜利を生成する例もある。これは、Pix2Seq の画像のエンコーダである事前学習済みの ResNet152 が bokete 特有の画像に対し、画像の特徴を捉えられていないことが問題であると考えられる。画像を入力とし、文章を出力する Pix2Seq では、[1]のように、画像の特徴抽出器として事前学習済みの大規模画像認識モデルを使用する方法が一般的である。事前学習済みの大規模画像認識モデルを Pix2Seq の画像の特徴抽出器として用いる際、事前学習時の画像ドメインと、Pix2Seq の学習時の画像ドメイン間に乖離がある場合、画像の特

特徴を抽出することができない可能性がある。この問題に対し、事前学習済みの大規模画像認識モデルに Pix2Seq の学習時の画像を再学習することで Pix2Seq の学習時の画像に適応させる方法があるが、この方法では Pix2Seq の学習時の画像に対しアノテーションが必要となる。また、事前学習済みの大規模画像認識モデルは大容量であり、モデルの構造を変更することができないため、低性能なデバイスで使用できないという問題もある。これらの問題を解決するためには、任意のネットワークの構造を定義でき、学習時にアノテーションを必要としない画像の特徴抽出器が必要となる。そこで、本研究では、学習時にアノテーションを必要としない AutoEncoder[5]に Pix2Seq の学習時の画像を学習させ、そのエンコードを Pix2Seq の画像の特徴抽出器とする新たな学習モデルを提案する。実験として、提案手法を用いて大喜利生成 AI を実装し、実装した大喜利生成 AI の生成する大喜利の面白さをアンケートにより評価する。

2. 基盤技術

2.1. Pix2Seq[3]

Pix2Seq は、画像と単語を入力することで、入力した単語に続く単語の確率分布を出力する AI である。Pix2Seq に対し、再起的に画像と単語を入力することで文章が生成される。Pix2Seq の構造を図 1 に示す。ここで、 $\mathbf{F}$ は画像、 w_t は文章の t 番目の単語である。 $\mathbf{F}$ は画像の特徴抽出器へ入力され、特徴ベクトルに変換される。 w_t は埋め込み層で分散表現に変換され、LSTM により t 時点の内部状態である r_t と共に処理される。画像の特徴抽出器の出力と LSTM の出力は、マージし全結合層へ入力され、その出力は $t+1$ 番目の単語の確率分布となる。画像の特徴抽出器の学習を Pix2Seq の学習と同時に進める場合、学習データの文章の長さが全て同じでなければ、画像の学習機会に偏りが生じる。また、学習時のパラメータが膨大になることで、バッチサイ

ズを大きくして学習することができず、学習が不安定になる問題に繋がる。これらの問題を解決するため、一般的に Pix2Seq の画像の特徴抽出器には事前学習済みの大規模画像認識モデルが使用されている。事前学習済みの大規模画像認識モデルは、ImageNet[4]のような膨大な数の画像とカテゴリからなるデータセットを高精度に分類するように学習しており、これにより未知の画像に対して特徴を抽出することが可能となる。

2.2. AutoEncoder[5]

AutoEncoder は、学習時にデータに対するアノテーションを必要とせず、データの特徴抽出と次元圧縮が可能な AI である。AutoEncoder は入力されたデータを圧縮するエンコーダと、エンコーダの出力からエンコーダへの入力を復元するデコーダにより構成される。AutoEncoder の学習は(1)を目的とする。

$$\min_{\mathbf{w}_e, \mathbf{w}_d} E(\mathbf{X}, \text{decoder}(\text{encoder}(\mathbf{X}))). \quad (1)$$

ここで、 $\mathbf{w}_e$, $\mathbf{w}_d$ はそれぞれエンコーダとデコーダのパラメータ、 E は二乗和誤差などの損失関数、 $\mathbf{X}$ は入力である。 $\text{encoder}(\mathbf{X})$ は、エンコーダへ $\mathbf{X}$ が入力された場合の出力であり、入力 $\mathbf{X}$ の特徴ベクトルとなる。エンコーダの出力の次元数は任意に定義することができ、入力 $\mathbf{X}$ の次元数よりも小さく定義することで次元圧縮が可能である。

3. 提案手法

本研究では、低性能なコンピュータで大喜利生成 AI の実装を可能とするため、Pix2Seq[3]の改良を試みる。一般的に、Pix2Seq の画像の特徴抽出器として事前学習済みの大規模画像認識モデルが使用される。しかし、この方法では、事前学習時の画像のドメインと Pix2Seq の学習時の画像のドメイン間に乖離がある場合、画像の特徴を上手く抽出することができない。この問題に対し、事前学習済みの大規模画像認識モデルに Pix2Seq 学習時の画像を再学習させる方法があるが、この方法では Pix2Seq 学習時の画像に対しアノテーションが必要となる。Pix2Seq のデータセットには、画像に対するアノテーションが付与されていないものもあり、この場合、手動でのアノテーション付与が必要となるため、手間と時間を要する。また、事前学習済みの大規模画像認識モデルは、パラメータ数が膨大であり、低性能なコンピュータでの使用が困難である。さらに、事前学習済みの大規模画像認識モデルは、配布元のライセンスに則り使用する必要があり、モデルによっては二次配布や商用利用が禁止されている。これらの問題を





図 1 Pix2Seq の構造

解決するためには、学習時に画像に対するアノテーションを必要とせず、任意の構造を定義することができる画像の特徴抽出器が必要となる．そこで、本研究では、事前に Pix2Seq 学習時の画像を学習させた AutoEncoder のエンコーダを、Pix2Seq の画像の特徴抽出器として用いる新たな Pix2Seq の学習モデルを提案する．提案手法の構造を図 2 に示す．図 2 に示すように、画像は AutoEncoder のエンコーダに画像を入力するが、この際、エンコーダの重みは凍結し学習は行わない．提案手法では、画像の特徴抽出器を Pix2Seq の学習時の画像を用いて学習しているため、従来の事前学習済みの大規模画像認識モデルを特徴抽出器とした場合と比べ、高精度に Pix2Seq を学習することが期待できる．

1. training AutoEncoder



2. training Pix2Seq




図 2 提案手法の構造

4. 実験

4.1. 実験 1：大喜利生成 AI の実装

提案手法の有効性を検証するため、提案手法を大喜利生成 AI に応用する．画像を入力とし、大喜利を出力とする Pix2Seq を学習するためには、画像とそれに対応する大喜利で構成されるデータセットが必要となる．しかし、それに該当するオープンデータセットは存在しない．そこで、本実験では、従来研究[1]に倣い、bokete[5]の WEB サイトをスクレイピングすることでデータセットを作成した．作成したデータセットは、お題画像が 69,365 枚とそれに対応する大喜利が 552,613 文章で構成される．大喜利文章には、「!」や「?」のような特殊文字を取り除く前処理を行なった．本実験で使用する AutoEncoder のエンコーダは入力サイズが縦横 256 ピクセルの 3 チャンネルであり、畳み

込み層 5 層と全結合層 1 層で構成する．エンコーダの出力である画像の特徴次元数は 16,384 次元とした．デコーダは全結合層 1 層と逆畳み込み層 5 層で構成する．AutoEncoder の学習時、画像は 0 から 1 に正規化し、損失関数を二乗和誤差、最適化手法を Adam ($\eta = 0.0001, \beta_1 = 0.9, \beta_2 = 0.999$)、ミニバッチサイズを 32、学習エポック数を 150 回とした．本実験で使用する Pix2Seq は、単語の埋め込み次元数を 128 次元、LSTM のユニット数を 1,024、出力層のユニット数を 48,480 とした．Pix2Seq の学習時、エンコーダの重みは凍結している．損失関数を交差エントロピー誤差、最適化手法を Adam ($\eta = 0.0001, \beta_1 = 0.9, \beta_2 = 0.999$)、ミニバッチサイズを 2048、学習エポック数を 50 回とした．実装した大喜利生成 AI によって生成された大喜利を表 1 に示す．表 1 の画像は大喜利生成 AI への入力であり、文章は大喜利生成 AI が生成した大喜利である．本実験では、大喜利生成 AI の出力する単語の確率分布に則りランダムに単語を選択している．また、表 1 の入力画像は、学習に使用していない未知の画像である．表 1 から、実装した大喜利生成 AI は画像に適した大喜利を生成することに成功していることがわかる．

表 1 提案手法を用いた大喜利生成 AI の生成例

画像	文章
	● 私のすっぴんよ ● 歯医者私は私です ● 私すっぴんでしょ ● ママスッピンなの ● メイク忘れてる
	● 野生の UFO キャッチャー ● みろよ野生のネズミが飛んできたぞ ● 野生の江頭 ● いまだ遠い朝だよ
	● どうぞどうぞどうぞ ● えっ家が燃えてる ● トリックダンス中 ● トリック教えてあげる ● トリックを教えてあげるパパ

4.2. 実験2: 従来手法を用いた大喜利生成 AI の実装

次に、従来手法の Pix2Seq の画像の特徴抽出器に事前学習済みの ResNet152 を使用した大喜利生成 AI を実装し、実験 1 で実装した大喜利生成 AI の生成する大喜利と比較を行う。本実験で使用するデータセット、学習条件は実験 1 と同様であるが、画像の特徴抽出器が ResNet152 であるため、画像サイズは縦横 224 ピクセルの 3 チャンネルとなっている。本実験で実装した大喜利生成 AI が生成した大喜利を表 2 に示す。表 2 から、本実験で実装した大喜利生成 AI は実験 1 で実装した大喜利生成 AI 比べ、画像に適した単語を含んだ大喜利を生成できていないことが確認できる。

表 2 従来手法を用いた大喜利生成 AI の生成例

入力画像	生成大喜利
	● 八丁味噌蟹クリーム味 ver ● お義父さんここおっさん ● また失敗して放置してみたわわ
	● ああまたフリーズしちゃった ● ここにとっておきの熱湯を ● 背中にチャックついてるぞ ● 俺の毛が大好きだって
	● グラサンしてるときになんか興味あるけどねえ ● うほっいい鬼瓦 ● バックダンサー用のお仕事 ● こういう餓鬼よ ● 観音様のトコへ急いで...

4.3. 実験3: アンケートによる大喜利生成 AI の評価

最後に、[1]に倣い、アンケートにより生成された大喜利のお面白さを評価する。アンケートでは、実験 1

で実装した提案手法を用いた大喜利生成 AI の大喜利、実験 2 で実装した従来手法を用いた大喜利生成 AI の大喜利、STAIAR Caption データセット[6]を学習したキャプション AI のキャプション、bokete をスクレイピングしたデータからランダムに選択した大喜利を人間に見せ、人間は、画像とそれに対応する文章を見て、面白い、やや面白い、やや面白くない、面白くないの 4 段階で大喜利を評価する。アンケートは LINE の Bot を用いて行い、509 件の投票を得た。アンケートの結果を表 3 に示す。表 3 より、提案手法を用いて実装した大喜利生成 AI は従来手法の事前学習済みの大規模画像認識モデルを用いて実装した大喜利生成 AI と比べ、面白い大喜利を生成できることがわかる。

5. まとめ

本研究では、画像に対し大喜利を生成する AI を実装するため、AutoEncoder のエンコーダを画像の特徴抽出器とする新たな Pix2Seq の学習モデルを提案した。実験より、提案手法を用いて実装した大喜利生成 AI は画像に適した大喜利を生成することを確認した。また、実装した大喜利生成 AI の生成した大喜利の面白さをアンケートにより評価を行い、従来手法より面白く、人間より面白くないという結果を得た。今後の研究では、より面白い大喜利が生成できるよう AI の改良を行う予定である。

文 献

- [1] 美濃口 宗尊, 他, “Neural Joking Machine-面白キャプションの生成及び評価に関する基礎検討-” 精密工学会誌, vol.85, no.12, pp.1151-1156 (2019).
- [2] 株式会社オモロキ, “bokete”, <https://bokete.jp/>(最終アクセス:2022/12/13).
- [3] O. Vinyals, et al., "Show and tell: A neural image caption generator", *Proc. CVPR*, pp.3156-3164 (2015).
- [4] Deng, Jia, et al., "Imagenet: A large-scale hierarchical image database" *2009 IEEE conference on computer vision and pattern recognition*. Ieee, pp. 248-255 (2019).
- [5] G. E. Hinton, et al., "Reducing the dimensionality of data with neural networks", *Science*, Vol.313, No.5786, PP.504-507 (2006).
- [6] Y. Yoshikawa, et al., "STAIR Captions: Constructing a Large-Scale Japanese Image Caption Dataset", *Proc. ACL*, vol.2, pp. 417-421 (2017).

表 3 アンケートの結果

手法	面白くない	やや面白くない	やや面白い	面白い	平均
キャプション AI	79%	5%	8%	5%	0.41
従来手法	64%	12%	13%	9%	0.68
提案手法	54%	16%	12%	16%	0.90
人間	28%	10%	29%	32%	1.66