

背景・目的


背景

- 近年、大喜利生成AIの研究が盛んに行われている[1,2]
- 画像キャプションモデル[3]の画像の特徴抽出機として、事前学習済みの画像認識モデルが使用される[1]
- 画像キャプションモデルの画像の特徴抽出器としてAutoEncoderのエンコーダを用いる方法を提案[2]

目的

- 大喜利生成AIの画像の特徴抽出機として適したAutoEncoderの構造を模索する

画像キャプションモデル[3]



※ I : 画像, w_t : 文章の t 番目の単語, r_t : t 時点の内部状態

画像のエンコーダとして事前学習済みの画像認識モデルが一般的に使用される

メリット


- 画像のエンコーダを学習しないため、計算コストが低い
- 事前学習済みモデルはImageNetのような大規模なデータで学習しており、幅広い種類の画像に対応できることが期待できる

デメリット

- 事前学習済みモデルの再学習には画像に対するアノテーションが必要
- 事前学習済みモデルはパラメータ数が膨大かつ、任意に構造を変更できない

Neural Joking Machine[1]

- 画像キャプションモデルの画像のエンコーダとして、ImageNetを事前学習済みのResNet152を使用
 - 大喜利⇔画像のデータセットをbokete[5]のWebサイトをスクレイピングし作成
 - 一部の画像に対し、不適な単語を含む大喜利が生成される
- 事前学習済みResNet152がbokete特有のアニメ・マンガ画像等に対し、特徴抽出が困難




提案手法

- 画像キャプションモデルの画像のエンコーダとしてboketeの画像を学習したAutoEncoderのエンコーダを使用[2]
- メリット
- boketeのデータに適したエンコーダを用いることで、高精度に学習できることが期待できる
- デバイスに適した性能のエンコーダを用いることができる
- デメリット
- AutoEncoderを事前に学習する必要がある

AutoEncoder[4]

データの次元圧縮や、特徴抽出が可能
学習時にデータに対するアノテーションを必要としない
任意の構造のエンコーダ・デコーダを定義できる



※ I : 入力, z : 特徴量

本研究

[2]においてAutoEncoderの最適な構造について言及は無い

大喜利生成AIに適したAutoEncoderのエンコーダの構造を模索する

データセット

[1]に倣い、bokete[5]のWebサイトをスクレイピングし、大喜利⇔画像データセットを作成
画像: 88102枚, 大喜利: 759501文章

こんな首相は 大好き だ	うそ、君が男!? CMのあと驚きの鑑定結果が! 先生、純白かあっ! いつ...生き返った!
宿題制度を廃止にする 首相がキムタク ディフェンスに定評がある すそが短い	

実験

実験目的

[1]で使用されているResNet152のパラメータ数58,370,944よりパラメータ数が少なく、高性能なAutoEncoderのエンコーダを模索

実験1: 畳み込み層の数を変更

実験条件

ネットワークの初期値を10回変更

画像サイズ: 縦横128Pixel, 最大エポック: 100, バッチサイズ: 16,

最適化手法: Adam(学習率: 0.0001), 損失関数: 二乗和誤差, 特徴量次元数: 2048

フィルタ数: 2^{5+L} , カーネルサイズ: 3×3 , スライド: 2, 活性化関数: LeakyReLU, L: 層番号

実験1 パラメータ数・検証誤差

畳み込み層の数	5層 vest/average	6層 vest/average	7層 vest/average
パラメータ数	39,827,072	49,265,280	58,703,488
検証誤差	0.0079/0.0080	0.0094/0.0096	0.0109/0.0111

実験2: 特徴量の次元数を変更

実験条件

ネットワークの初期値を10回変更

画像サイズ: 縦横128Pixel, 最大エポック: 100, バッチサイズ: 16,

最適化手法: Adam(学習率: 0.0001), 畳み込み層の数: 5層

フィルタ数: 2^{5+L} , カーネルサイズ: 3×3 , スライド: 2, 活性化関数: LeakyReLU

実験2 パラメータ数・検証誤差・FID

特徴量次元数	512 vest/average	1024 vest/average	2048 vest/average
パラメータ数	14,659,712	23,048,832	39,827,072
検証誤差	0.0111/0.0111	0.0086/0.0086	0.0079/0.0080
FID※	108.30/109.38	73.03/74.37	61.76/62.87

※ Frechet Inception Distance(FID)[5]

画像群Aと画像群Bの分布がどれほど近いと測る指標。0に近ければ近いほど分布は近い

実験3: 大喜利生成AIを学習


3つの条件で大喜利生成AIを比較

- [1]と同様に画像の特徴抽出機として、事前学習済みResNet152を使用
- 画像の特徴抽出機として、実験2で学習した特徴量の次元数が512のエンコーダを使用
- 画像の特徴抽出機として、実験2で学習した特徴量の次元数が2048のエンコーダを使用

実験条件

LSTMユニット数: 512, バッチサイズ: 1024, エポック: 100, 損失関数: 交差エントロピー

最適化手法: Adam(学習率: 0.0001), 損失関数: 二乗和誤差



実験3 学習損失

実験3 学習精度

入力画像(学習画像)	生成大喜利
	ResNet152: バツツの すそ がカピカビになっている
	AutoEncoder:512: 出会い系で待ち合わせ
	AutoEncoder:2048: 子供の頃から ディフェンス に定評のある人
入力画像(非学習画像)	生成大喜利
	ResNet152: 夕飯はカレー
	AutoEncoder:512: しゃっくりが止まらない
	AutoEncoder:2048: 脱出 イリュージョンをしている
入力画像(非学習画像)	生成大喜利
	ResNet152: こいつが噂の 鮫肌男 か
	AutoEncoder:512: あーんこの人痴漢です
	AutoEncoder:2048: 実は 痔 なんです
入力画像(非学習画像)	生成大喜利
	ResNet152: 火事だー
	AutoEncoder:512: プリキュアの最終回
	AutoEncoder:2048: よしー一旦 CM の時間だ
入力画像(非学習画像)	生成大喜利
	ResNet152: これか私の スタンド
	AutoEncoder:512: おれのボケに対する 評価
	AutoEncoder:2048: このとおり忙しいんだから早く 宿題 を

[1] 美濃口 宗尊, 他, 精密工学会誌, vol.85, no.12, pp.1151-1156 (2019).

[2] 山富 龍, 他, IEICE 信学技報 CCS 研究会, CCS2022-73, pp.59-62(2023).

[3] Vinyals, O., et al., Proc. IEEE CVPR, pp. 3156-3164 (2015).

[4] G. E. Hinton, et al., Science, vol.313, no.5786, pp.504-507(2006).

[5] 株式会社オモロキ, bokete, <https://bokete.jp/> (最終アクセス: 2023/6/6).

[6] Heusel, Martin, et al., NeurIPS, 30 (2017).