



大喜利生成 AI に適した AutoEncoder の構造に関する研究

Study on the Suitable AutoEncoder Structure for AI for Generating Humorous Response Sentence to Image

山富 龍 マハブービ シェヘラザード 二宮 洋

湘南工科大学大学院電子情報工学専攻

1. まえがき

近年、画像に対する大喜利生成 AI の実装に関する研究が行われている[1][2]。本研究ではこれまでに、画像から文章を生成するモデルである Pix2Seq を用いた大喜利生成 AI を実装した。提案手法では、Pix2Seq の画像の特徴抽出器として AutoEncoder のエンコーダを用いることで画像に適した大喜利の生成を試みた。しかし、[2]で実装した AutoEncoder はパラメータ数が膨大であり、低性能な PC での利用が困難であった。そこで、本研究では AutoEncoder の構造に対する検討を行い、低性能な PC で実装可能な大喜利生成 AI に適した AutoEncoder の構造に関する検討を行う。

2. AutoEncoder[3]

AutoEncoder はニューラルネットワークを用いた教師無し学習手法であり、データの特徴抽出、次元圧縮が可能である。AutoEncoder は、任意に構造を定義可能なエンコーダとデコーダで構成され、 $\min_{\mathbf{w}_e, \mathbf{w}_d} E(\mathbf{X}, \text{decoder}(\text{encoder}(\mathbf{X})))$ を目的として学習を行う。ここで、 $\mathbf{w}_e$ と $\mathbf{w}_d$ はそれぞれエンコーダとデコーダのパラメータ、 E は任意の損失関数、 $\mathbf{X}$ は AutoEncoder への入力である。

3. 実験

本研究では、[1]において Pix2Seq の画像の特徴抽出器である ResNet152 のパラメータ数 58,370,944 よりパラメータ数が少なく、低性能なコンピュータで実行可能かつ高性能な AutoEncoder の実装を試みる。学習に使用するデータは、bokete[2]の Web サイトをスクレイピングすることで得られた画像 88,102 枚とし、90%を学習用、10%を検証用に用いた。画像は画素値が 0 から 1 になるよう正規化した。実験 1 と実験 2 はパラメータを変えて 10 回学習を行い、その平均値とベスト値を求めている。全ての表において左の値がベスト値、右の値が平均値である。実験 1 では、AutoEncoder のエンコーダの畳み込み層の数を 5 層、6 層、7 層に変更し学習を行う。実験結果を表 1 に示す。表 1 では層の数を増やせば増やすほど損失が大きくなる結果が得られた。これは層が増えることで不要な線形変換が行われたためであると考えられる。実験 2 では、AutoEncoder のエンコーダの出力する特徴量の次元数を 512、1,024、2,048 に変更し学習を行う。実験結果を表 2 に示す。表 2 では特徴量の次元数を増やせば増やすほど損失が小さくなる結果が得られた。これは、特徴量の次元数が増えることでエンコーダの表現力が向上したためであると考えられる。実験 3 では、実験 2 で最も低い学習損失を得られた特徴量の次元数 2,048 の AutoEncoder のエンコーダと、最も高い学習損失を得られた特徴量の次元数 512 の AutoEncoder のエンコーダそして [1]で使用されている事前学習済みの ResNet152 をそれぞれ画像の特徴抽出器とした Pix2Seq を

用いて大喜利生成 AI の実装を行い、学習結果を比較する。実験結果を図 1 と図 2 に示す。ここで、図 1 は横軸が学習反復回数、縦軸が学習損失のグラフ、図 2 は横軸が学習反復回数、縦軸が学習精度のグラフ、両方のグラフで緑線が ResNet152 を用いた結果、青線が特徴量の次元数が 512 のエンコーダを用いた結果、オレンジ線が特徴量の次元数が 2,048 のエンコーダを用いた結果である。図 1 と図 2 から AutoEncoder のエンコーダを用いた結果が ResNet152 を用いた結果と比べて低い学習損失と高い学習精度が得られている。また、特徴量の次元数が 512 の AutoEncoder のエンコーダを用いた結果と特徴量の次元数が 2,048 の AutoEncoder のエンコーダを用いた結果を比較すると、特徴量の次元数が 2,048 のエンコーダを用いた結果が 1%低い学習損失と 0.7%高い学習精度を得られている。これらの結果から高精度に大喜利生成 AI を実装するために、AutoEncoder のエンコーダを画像の特徴抽出器として使用すること、AutoEncoder のエンコーダの出力する特徴量の次元数を大きくすることが有効であることを確認した。

表 1 実験 1 の結果

	5 層	6 層	7 層
MSE	0.0079/0.0080	0.0094/0.0096	0.0109/0.0111
params	39,827,072	49,265,280	58,703,488

表 2 実験 2 の結果

	512	1,024	2,048
MSE	0.0111/0.0111	0.0086/0.0086	0.0079/0.0080
params	14,659,712	23,048,832	39,827,072




図 1 学習損失のグラフ




図 2 学習精度のグラフ

4. まとめ

本研究では、大喜利生成 AI の画像の特徴抽出器に用いる AutoEncoder のエンコーダの最適な構造の検討を試みた。今後は、他の評価指標で学習結果を評価し、デコーダの最適な構造の検討を行う。

参考文献

- [1] 美濃口 宗尊, 他, 精密工学会誌, vol.85, no.12, pp.1151-1156 (2019).
- [2] 山富 龍, 他, IEICE 信学技報 CCS 研究会, CCS2022-73, pp.59-62(2023).
- [3] G. E. Hinton, et al., Science, vol.313, no.5786, pp.504-507 (2006).