

大喜利生成 AI の実装に関する研究

山富 龍 マハブービ シェヘラザード 二宮 洋

湘南工科大学工学部情報工学科

1. はじめに

近年、情報通信技術の普及により膨大かつ複雑なデータの取得が可能となった。それに伴いこのようなデータの学習を可能とする高性能な AI が必要とされており、この需要を満たすため、盛んに研究が行われている。AI の活用分野は多岐に渡り、医療分野などの実益に繋がる分野のみならず、絵画や音楽といった芸術分野での活用も注目されている。しかし、AI を芸能の分野に活用した研究は少ない。笑いは日常生活において重要な要素であるが、近年の感染症の流行により人々のコミュニケーションが減少し、それに伴い笑いの機会も減っている。そこで、本研究では感染症の恐れのない AI による笑いの機会を提供する。具体的には、画像を入力とし、その画像に対し大喜利を生成する AI の実装を試みる。画像に対し文章を生成する Pix2Seq[1]では、一般的に、画像の特徴を抽出するエンコーダとして、事前学習済みの大規模画像認識モデルを用いる。しかし、この方法では事前学習時の画像のドメインと実際に使用する画像のドメインに乖離がある場合、画像の特徴を抽出できない可能性がある。この問題を解決するためには事前学習済みモデルに実際に使用する画像を再学習させる必要がある。しかし、この場合、画像に対するアノテーションが必要となる。また、大規模画像認識モデルはモデルの構造をユーザーが任意に変更できないという問題もある。そこで、本研究では、任意にネットワークの構造を定義でき、学習時に画像に対するアノテーションを必要としない AutoEncoder[2]を事前に学習し、そのエンコーダの出力を画像の特徴量として使用する新たな Pix2Seq の学習モデルを提案する。

2. 基盤技術

本章では、本研究で実装する大喜利生成 AI で使用する Pix2Seq[1]と AutoEncoder[2]について説明する。

2.1. Pix2Seq[1]

Pix2Seq は画像と単語を再帰的に入力し、出力を合わせることで文章を出力する手法である。Pix2Seq の構造を図 1 に示す。図 1 では、 $\mathbf{F}$ は画像、 w_t は文章の t 番目の単語である。 $\mathbf{F}$ はエンコーダに入力され、特徴ベクトルに変換される。一般的に、このエンコーダとして、事前学習済みの大規模画像認識モデルが用いられる。 w_t は埋め込み層でベクトルに変換され、LSTM 層で t 時点の内部状態 r_t と共に処理される。エンコーダと LSTM 層の出力はマージし全結合層に入力され、その出力は $t+1$ 番目の単語の確率分布となる。




図 1 Pix2Seq の構造

2.2. AutoEncoder[2]

AutoEncoder は、学習時にデータに対しアノテーションを必要とせず、データの特徴抽出と次元圧縮が可能な手法である。AutoEncoder の学習では、データをエンコーダに入力し特徴ベクトルを取得する。取得した特徴ベクトルをデコーダに入力し、元のデータを復元するように学習を行う。AutoEncoder の学習では(1)を目的とする。

$$\min_{\mathbf{w}_e, \mathbf{w}_d} E(\mathbf{X}, \text{decoder}(\text{encoder}(\mathbf{X}))). \quad (1)$$

ここで、 $\mathbf{w}_e$ はエンコーダの重み、 $\mathbf{w}_d$ はデコーダの重み、 E は損失関数、 $\mathbf{X}$ は入力である。

3. 提案手法

一般的に, Pix2Seq の画像の特徴を抽出するエンコーダとして, 事前学習済みの大規模画像認識モデルが使用される. この方法を用いる場合, 事前学習時の画像のドメインと Pix2Seq の学習時の画像のドメイン間で乖離があると, 画像の特徴が抽出できない可能性がある. このような問題に対し, Pix2Seq を学習する際の画像で再学習する方法がある. しかし, この方法では画像に対するアノテーションが必要となる. また, 事前学習済みモデルは大容量かつ, モデルの構造を変更できないため, 環境に応じたスペックのコンピュータでの使用が困難である. そこで, 本研究では, これらの問題を解決するため, 学習時にアノテーションを必要とせず, 任意にネットワークの構造を定義できる AutoEncoder を事前学習し, そのエンコーダの出力を画像の特徴量として用いた新たな Pix2Seq の学習モデルを提案する. 提案手法の構造を図 2 に示す.




図2 提案手法の構造

4. 実験

4.1. 実験条件

画像を入力とし, その画像に対する大喜利を生成する AI を実装するために, 画像とそれに対応する大喜利が対となったデータセットが必要となる. しかし, 既存のデータセットにこれに該当するものはない. そこで, 本研究では, bokete[3]という画像に対し大喜利を投稿するサービスに着目し, この Web ページをスクレイピングすることで学習データを作成した. 本実験では, bokete の全お題画像 6,950,675 万枚の内 69,365 枚のお題画像とそれに対応する大喜利 552,618 文章を学習に使用する. 本実験で使用する AutoEncoder は, 畳み込み層 5 層からなるエンコーダと, 逆畳み込み層 5 層からなるデコーダで構成される. AutoEncoder の学習時, 画像は 0 から 1 に正規化し, 損失関数として二乗和誤差を使用し, 学習エポック数を 150 回, ミニバッチサイズを 32 とした. Pix2Seq は, 単語のベクトル次元数を 128 次元, LSTM のユニット数を 1,024

個, 出力層のユニット数を 48,480 個とした. Pix2Seq の学習時, 損失関数として交差エントロピー誤差を使用し, 学習エポック数を 50 回, ミニバッチサイズを 2,048 とした.

4.2. 実験結果

実装した大喜利生成 AI によって生成された大喜利の例を表 1 に示す. 本実験では, AI の出力した確立分布からルーレット選択により単語を選択している. ここで, 入力画像は学習に使用していない画像である. 表 1 から, 実装した AI は画像に適した大喜利らしい文章を生成することができていることが分かる.

表 1 生成した大喜利の例

生成例 1	
入力画像	生成された大喜利
	・私のすっぴんよ ・歯医者私は私です ・私すっぴんでしょ ・ママすっぴんなの ・森口ロールの新 CM ・メイク忘れてる
生成例 2	
入力画像	生成された大喜利
	・えっそんなに鼻からうどん出てきたの ・ウルトラマンの惑星にてオーディション初めての写真 ・えっこれ誰の嫁

5. まとめ

本研究では, 画像に対して大喜利を生成する AI を実装するため, 新たな Pix2Seq の学習モデルを提案した. 実験より, 実装した AI は大喜利らしい文章を生成することを確認した. 本研究の課題として, 実装した AI の生成した大喜利に対する評価が挙げられる. そのため, 今後の研究では, AI の生成した大喜利と人間の大喜利に対しアンケートを行う.

参考文献

- [1]. O. Vinyals, et al., "Show and tell: A neural image caption generator.", *Proc. IEEE CPVR* (2015).
- [2]. G. E. Hinton, et al., "Reducing the dimensionality of data with neural networks.", *Science*, Vol.313, No.5786, PP.504-507 (2006).
- [3]. 株式会社オモロキ, "bokete", <https://bokete.jp/>(最終アクセス:2022/12/13).