

ディープラーニングを用いた生成画像の識別に関する研究

Deep Learning based Classification System of Real and Generated Images by Various AI Models

李 洪企¹ 山富 龍² マハブービ シェヘラザード¹ 二宮 洋^{1,2}

¹ 湘南工科大学 工学部 情報工学科 ² 湘南工科大学大学院 工学研究科 電気情報工学専攻

1 はじめに

近年, BigGAN[1] や Stable Diffusion[1] 等の画像生成 AI が注目されており, このような画像生成 AI が生成した画像がフェイクニュースに使用される問題が発生している. [1] では, AI によって現実と生成 AI の画像を分類する手法が提案された. この手法では, 識別器が学習に使用した AI モデルの生成画像に対しては高精度に分類できる. 一方で, 未学習なモデルの生成画像に対しては分類精度が著しく低下する問題がある. 本研究では, この問題の解決を目指した, 新たな生成画像分類システムを提案する. 提案システムの有効性は実験より示す.

2 従来研究: GenImage[1]

[1] の従来手法では, ResNet50[1] や Swin-Transformer[2] など 7 種類の識別モデルに対して, 1 種類の AI モデルにより生成された画像を学習させ, 入力画像が現実か生成かの分類を行なった. この論文で使用されたデータセットは, ImageNet[1] の各クラス名を BigGAN や Stable Diffusion などの 8 種類のモデルに入力し, 生成された画像から構成されており, 公開されている. [1] の実験より, 提案データセットに対して最も高精度に生成と現実の画像を分類したモデルは Swin-Transformer である.

3 提案手法

従来手法では, 学習データに含まれている生成画像の高精度な分類は可能である. 一方で, 未学習の生成モデルの画像に対しては精度が著しく低下する問題がある. 本研究ではこの問題を解決するため, 異なる生成モデルが生成した画像をそれぞれ学習した識別器を複数組み合わせることで現実か生成画像かを判別する新たな分類モデルを提案する. 提案手法の構造を図 1 に示す. 図 1 では, 複数の生成モデル画像をそれぞれ学習した識別器を生成モデルの数分用意し, 組み合わせる. その後, 画像を入力し, それぞれの識別器に分類させる. 分類過程において, いずれかの識別器が生成画像であると判定した場合は生成画像と見なす. 一方で, 全てのモデルが現実と判定した場合は現実画像とする. このシステムでは, 各生成モデルに特化した識別器を無数に追加することが可能であるため, 新しい生成モデルにも対応できる利点がある.




図 1 提案システムの構造

4 実験

本研究では, 提案モデルの有効性を調べるため, [1] のベンチマーク問題に対する実験を行う. 実験では, [1] と同様に生成モデルごとに学習した識別器と全てのモデルを学習した識別器そして提案手法で比較を行う. ベンチマーク問題として, [1] で公開されている GLIDE[1], ADM[1], Stable Diffusion ver.1.5(SDv5), Stable Diffusion ver.1.4(SDv4), BigGAN によって生成された画像と ImageNet の現実画像を使用する. 学習と検証データの比率は約 23:1 であり, 生成画像と現実画像の比率は約 8:1 である. 検証データの現実画像枚数増加のため Flickr 30K[3] も含んでいる. 識別器には事前学習済み Swin-Transformer で転移学習を行う. 実験結果を表 1 に示す. 表 1 において行は画像データのソースを示し, 列は各ソースのデータのみを学習に使用した識別器を示す. ここで, “All” はは全てのソースのデータを学習した識別器であり, “Ours” は提案手法である. 表より, 提案手法は生成画像に対する分類精度が他の識別器と比べ高いことがわかる. 一方で, 現実画像に対する分類精度が他の手法と比べて低い. これは, 提案手法では現実画像に対して全ての識別器で正しく分類しなければならないことが原因である.

表 1 実験結果

Image Source	Discriminator Classification Accuracy						
	GLIDE	ADM	SDv5	SDv4	BigGAN	All	Ours
GLIDE	99.9	99.36	45.28	32.65	89.14	99.93	99.96
ADM	71.39	99.43	38.15	31.61	29.04	99.1	99.51
SDv5	15.41	48.6	99.82	99.52	1.25	99.88	99.92
SDv4	16.15	49.48	99.9	99.68	1.35	99.9	99.96
BigGAN	94.95	95.96	19.6	11.56	100.0	99.96	100.0
ImageNet	99.78	99.23	99.12	99.41	99.92	96.73	97.92
Flickr30k	99.99	99.77	99.86	99.94	99.99	99.21	99.42

5 おわりに

本研究では, 異なる画像生成 AI が生成した画像をそれぞれ学習した識別器を複数組み合わせさせた, 現実と生成画像を分類する新しいシステムを提案した. 実験より, 従来と比べて高精度に分類できることを示した. 今後は他の生成モデルの画像を提案手法と従来手法にて追加学習し, 比較を行う.

参考文献

- [1] M.ZHU, et al, *arXiv :2306.08571*, Jun.2023.
- [2] Z.LIU, et al, *Proc. IEEE/CVF ICCV*, pp.10012-10022, Oct.2021.
- [3] P.YOUNG, et al, *TACL*, Vol.2, pp.67-78, Feb.2014.