

AutoEncoderによる非可逆圧縮のための バイナライズ損失に関する研究

On the study of Binarized Loss for Lossy Compression using AutoEncoder

秋山 優
Yu Akiyama

山富 龍
Ryo Ymatomi

マハブーブ シェヘラザード
Shahrzad Mahboubi

二宮 洋
Hiroshi Ninomiya

湘南工科大学
Shonan Institute of Technology

1 はじめに

近年、非可逆圧縮のための AutoEncoder に関する研究が行われている [1]。非可逆圧縮のための AutoEncoder は、エンコーダが出力する実数の特徴量を離散化することで入力を符号語に変換している。この際、離散化すると元の特徴量と誤差が生じる問題がある。本研究ではこの問題の解消を目的とした、エンコーダの出力が 0 か 1 に近づくよう制約を課す、バイナライズ損失を用いた非可逆圧縮のための AutoEncoder を提案する。

2 AutoEncoder

AutoEncoder はエンコーダとデコーダの 2 つのニューラルネットワークで構成される。エンコーダにより入力を任意の次元に変換し、デコーダはエンコーダの出力からエンコーダへの入力を復元するよう学習する。画像を入出力とする AutoEncoder は入力画像と出力画像からなる再構成誤差を最小化するよう学習を行う。

3 提案手法

本研究では、エンコーダの出力が 0 か 1 に近づくよう制約を課すバイナライズ損失を用いた非可逆圧縮のための AutoEncoder を提案する。非可逆圧縮のための AutoEncoder では、エンコーダの出力層の活性化関数を sigmoid 関数とする。学習時、エンコーダは入力 $\mathbf{X}$ を特徴量 $\mathbf{f}(\mathbf{f} \in [0, 1]^D)$ に変換し、デコーダは $\mathbf{f}$ から入力 $\mathbf{X}$ を復元するよう学習する。ここで、 D はエンコーダの出力次元数である。推論時、入力 $\mathbf{X}$ に対するエンコーダの出力 $\mathbf{f}$ を閾値を基準に二値化することで符号語 $\hat{\mathbf{f}}(\hat{\mathbf{f}} \in \{0, 1\}^D)$ とする。この際、連続値である $\mathbf{f}$ と閾値でバイナリに変換された $\hat{\mathbf{f}}$ の差だけ $\mathbf{f}$ を入力した際のデコーダの出力と、 $\hat{\mathbf{f}}$ を入力した際のデコーダの出力に誤差が生じる。本研究では、 $\mathbf{f}$ と $\hat{\mathbf{f}}$ の差の最小化を目的とした制約項を AutoEncoder の学習の損失に加えることで、この問題の解決を試みる。提案手法が最小化する損失を (1) に示す。

$$E = \text{MSE}(\mathbf{X}, \text{Decoder}(\text{Encoder}(\mathbf{X}))) + \alpha t \quad (1)$$

$$t = \sum_{i=1}^{|\mathbf{f}|} f_i(1 - f_i) \quad (2)$$

ここで、 $\text{MSE}(\mathbf{A}, \mathbf{B})$ は画像 $\mathbf{A}$ と画像 $\mathbf{B}$ のピクセルごとの差分の二乗の平均、 $\mathbf{X}$ が入力画像、 $\text{Encoder}(\mathbf{X})$ はエンコーダに $\mathbf{X}$ を入力した際の出力、 $\text{Decoder}(\mathbf{X})$ はデコーダに $\mathbf{X}$ を入力した際の出力、 α は制約項の影響を調整するハイパーパラメータである。提案手法は (2) を最小化するためエンコーダの出力を 0 か 1 に近づけるよ

う学習することを目指す。従って、 $\mathbf{f}$ と $\hat{\mathbf{f}}$ の差が減少することが期待できる。

4 実験

本実験では、学習データとして MNIST を用いて提案手法を評価する。MNIST の画像は縦横それぞれ 28 ピクセル、各ピクセルの輝度を 256 段階の 8bit で表現している。このことから、MNIST の画像は 1 枚当たり $28 \times 28 \times 8 = 6272 \text{bit}$ となる。本実験では、(1) の α を実験に基づいて 0.18 とし、エンコーダの出力次元数を 11 パターンに変更し学習する。本実験で使用するエンコーダは畳み込み層 2 層、全結合層 1 層で、デコーダは全結合層 1 層、逆畳み込み層 2 層で構成される。また、制約項の影響を検証するため、(1) の α を 0、圧縮率を 90% とした AutoEncoder も学習する。学習した提案手法による再構成画像を図 1 に、学習結果を図 2 に示す。図 1 はそれぞれの圧縮率、 α の AutoEncoder による再構成画像、図 2 の縦軸は PSNR、横軸は圧縮率、各値はその圧縮率における PSNR である。また、●が $\alpha = 0.18$ の場合の結果、■が $\alpha = 0$ の場合の結果である。図 1 から、制約項無しで学習した AutoEncoder の復元画像に比べ、制約項有りで学習した AutoEncoder の復元画像の方が高精度に元の画像を復元できていることがわかる。このことから、(2) の制約項は、 $\mathbf{f}$ と $\hat{\mathbf{f}}$ の差の最小化することに有効であると言える。図 2 から、圧縮率が向上するにつれ PSNR が低下することがわかる。これは、圧縮率が高くなり特徴量次元数が小さくなることで入力画像の情報が損なわれたことが原因であると考えられる。




図1 再構成画像

図2 PSNR と圧縮率

5 おわりに

本研究では、エンコーダの出力が 0 か 1 に近づくよう制約を課す、バイナライズ損失を用いた非可逆圧縮のための AutoEncoder を提案した。提案手法では、バイナライズ損失を用いない場合と比べ、高い精度で入力を復号できることを数値実験により示した。

参考文献

[1] Lucas Theis, et al., ICLR, pp.1-19 Mar. 2017.