

大喜利文章と画像の適合性判定 AI に関する研究

山富 龍[†] マハブーブ シェヘラザード[†] 二宮 洋[†]

[†] 湘南工科大学大学院工学研究科 〒251-0057 神奈川県藤沢市辻堂西海岸 1 - 1 - 2 5

E-mail: {23T2003@sit, shaa@info, ninomiya@info}.shonan-it.ac.jp

あらまし 本研究では、文章と画像のペアが大喜利として成立しているか否かを判定する AI を提案する。近年、あるデータが条件を満たすかを判定する適合性判定 AI の研究が盛んである。しかし、このような AI の学習にはデータが適合しているか否かのアノテーションが必要であり、膨大な人手と時間を要する問題がある。本研究では、画像と文章のペアが大喜利として成立している場合を適合していると定義し、それを判定する AI を提案する。提案手法では、人間が作成した大喜利のペアを正例とし、正例の画像と文章をランダムに組み替えたペアを負例とするデータセットを構築し、判定 AI はこれを学習する。正例はインターネットからスクレイピングし、負例はプログラムで自動生成するため、人手によるアノテーションは不要である。提案手法の有効性を計算機実験により示す。

キーワード 大喜利 AI, 適合性判定システム, マルチモーダル AI.

On the Study of Compatibility Judgement AI between Ogiri Texts and Images

Ryo YAMATOMI[†], Shahrzad MAHBOUBI[†], and Hiroshi NINOMIYA[†]

[†] Shonan Institute of Technology 1-1-25 Tsujido Nishi-Kaigan, Fujisawa City, Kanagawa, 251-0057 Japan

E-mail: {23T2003@sit, shaa@info, ninomiya@info}.shonan-it.ac.jp

Abstract In this study, we propose an AI that judges whether or not a sentence-image pair is a valid Ogiri. In recent years, there has been a lot of research on AI for validity judgment, which judges whether data satisfies a condition. However, training such AI requires annotation of whether data satisfies a condition or not, and it requires a huge amount of manpower and time. In this study, we define validity as a sentence-image pair being a valid Ogiri pair, and propose an AI that judges such a validity. In the proposed method, a dataset is constructed using human-created Ogiri pairs as positive examples, and pairs of unrelated sentences combined with the image as negative examples, and the judgment AI learns from this dataset. The positive examples are scraped from the Internet, and the negative examples are generated automatically by the program, thus eliminating the need for manual annotation. The effectiveness of the proposed AI is demonstrated through computer experiments.

Key words Ogiri AI, Compatibility Judgment, Multimodal AI.

1. はじめに

近年、AI の適用範囲は拡大し、さまざまな分野で活用されている。その中でも、特定のデータが定められた条件を満たしているかを判定する適合性判定は、AI の重要な応用の一つである。AI による適合性判定は、自動化によって手間を削減できるだけでなく、常に一貫した判定を提供できるという利点がある。これは、AI の判定が人間の主観に依存せず、同じデータに対して常に同一の結果を出力するためである。さらに、適合性判定を行う AI はデータとそのラベルをもとに自動で適合性を判定するアルゴリズムを学習するため、従来のルールベース手法と比較してタスクごとの専門的知識を必要としない。このため、適合性判定 AI はさまざまなタスクに柔軟に適用できる。

[1] は、ミームが攻撃的であるか否かを判定する AI の分類

精度を競うコンペティションである。ミームとは、画像と文章で構成されるコンテンツであり、ジョークや社会風刺の手段としてインターネット上で広く拡散されている。しかし、その特性上、性別や人種に対する差別的な内容を含む場合がある。このコンペティションでは、差別を含むミームを攻撃的であると定義している。このコンペティションでは、ミームとその攻撃性に関するラベルが付与されたデータセットが提供された。ラベルはアノテーターによって付与されている。このコンペティションにおいて、画像と文章の両方を入力とするマルチモーダルモデルを用いた結果、69% の分類精度が達成された。

[2] は、画像と文章のペアからなる大喜利が面白いか否かを判定する AI の分類精度を競うコンペティションである。このコンペティションでは、画像と文章のペアからなる大喜利と、その大喜利が面白いか否かのラベルが付与されたデータセット

が提供された。このデータは、大喜利投稿サイト「ボケて」[3]から収集され、ラベルは同サイトにおける大喜利の評価に基づいて付与されている。しかし、配布されたデータセットにはラベルの適切性に問題があり、実際の面白さと一致しないラベルが含まれていた。

本研究では、画像と文章のペアが大喜利として成立している場合を適合していると定義し、それを判定するAIを提案する。近年、ユーモアの自動評価に関する研究が進められているが、本研究で目的とするような画像と文章がペアとなったコンテンツの判定は依然として困難である。特に、大喜利は文脈依存性が高く、同じ画像や文章であっても組み合わせによって意味が大きく異なるため、これを判定するAIは高い文章・画像理解能力、発想力を必要とする。本研究では、ボケてに存在する画像と文章のペアからなる大喜利を正例とし、その画像と文章をランダムに組み替えたペアを負例としてAIに学習させる。ボケてに投稿されている文章は人間がお題となる画像から想起した文章であり、これは成立している大喜利であると言える。また、画像と文章をランダムに組み替えたペアは画像と文章の関連性がないため、これは大喜利として成立していないと言える。このようなデータを学習したAIは、意味的に破綻した大喜利を識別する能力を獲得することが期待できる。

2. 従来研究

2.1 The Hateful Memes Challenge [1]

[1]は、ミームが攻撃的であるか否かを判定するAIの分類精度を競うコンペティションである。ミームとは、ジョークや社会風刺を目的としてインターネット上で拡散される、画像と文章からなるコンテンツである。このコンペティションでは、ミームとその攻撃性に関するラベルが付与されたデータセットが提供された。提供されたミームは、インターネット上で収集されたミームの画像を類似したフリー画像に置き換えたものである。この際、置き換え後のミームの攻撃性は、アノテーターによってラベル付けされた。アノテーターはミームを「攻撃的である」「どちらとも言えない」「攻撃的ではない」の3種類に分類する。1つのミームに対して5人がラベル付けを行った上で最終的なラベルが決定される。このコンペティションでは、データのバラエティを向上させるため、攻撃的とラベル付けされたミームに対し、文章を変更して攻撃的でなくしたミーム、画像を変更して攻撃的でなくしたミーム、ランダムに画像と文章を組み替えたミームが追加された。ランダムに組み替えられたミームは、画像と文章に関連性がないため、攻撃的ではないとされる。データセットの総ミーム数は10,000件であり、攻撃的なミームと攻撃的でないミームがそれぞれ5,000件ずつ含まれている。

このコンペティションでは、画像と文章を同時に事前学習したマルチモーダルモデルであるVisualBERT[4]が69%の分類精度を達成した。マルチモーダルで事前学習したVisualBERTは、ユニモーダルで事前学習したVisualBERTよりも高い分類精度を示し、BERTやResNet152といった文章のみ、または画像のみを用いるシングルモーダルモデルよりも高い分類精度を

達成した。これらの結果から、ミームの攻撃性を判定するためには、画像と文章の両方を考慮すること、それらを同時に事前学習することが有効であることが示唆される。

2.2 ボケ判定AIを作ろう！[2]

[2]は、画像と文章のペアからなる大喜利が面白いかなかを判定するAIの分類精度を競うコンペティションである。このコンペティションでは、大喜利投稿サイト「ボケて」[3]に投稿された大喜利と、それが面白いかなかのラベルが付与されたデータセットが提供された。ボケては、お題となる画像に対してユーザーが大喜利となるような面白い文章を投稿するソーシャルネットワークサービスである。ボケてではユーザーが、投稿された大喜利に対して最大3つの星を投票できる仕組みになっている。提供されたデータセットのラベルは、この星の数に基づいて付与されている。

しかし、このラベリング方法には以下のような問題がある。星の投票数が多い大喜利は、多くのユーザーによって面白いと評価されたものであり、面白い大喜利であると言える。これに対し、星の投票数が少ない大喜利には、(i)本当に面白くないため評価が低い場合と、(ii)面白いにもかかわらず多くのユーザーの目に触れず評価されなかった場合の2種類が存在する。特に、ボケてに投稿された大喜利の総数は1億件を超えており、(ii)のようなケースが多数存在することは十分に考えられる。このような背景から、星の数の大小に基づいて大喜利の面白さをラベル付けすることは困難である。

[12]は、このコンペティションで1位となったユーザーの解法である。この解法も、[1]と同様に、画像と文章を入力とするマルチモーダルモデルを用いている。この解法では、文章の特徴抽出にはRoBERTa[5]を使用し、画像の特徴抽出にはVision-Transformer[6]、Swin-Transformer[7]、英語の画像と文章で事前学習されたCLIP-ViT[8]、日本語の画像と文章で事前学習されたCLOOB[9]を使用している。これらのモデルが出力した特徴量をニューラルネットワークへ入力し、面白いかなかの分類を学習している。

2.3 ColBERT[10]

[10]では、短文が面白いかなかを判定するAIを提案している。この研究では、Redditのjokes/humorサブコミュニティに投稿された文章を面白い文章とし、政治やエンターテインメントといったニュース記事の見出しを面白くない文章としてデータセットを構築している。Redditは、ユーザーが投稿やコメントを通じて情報を共有し、議論できるソーシャルネットワークサービスであり、jokes/humorサブコミュニティにはユーザーが面白いと判断した文章が投稿されている。データセットの総文章数は200,000件であり、面白い文章と面白くない文章がそれぞれ100,000件ずつ含まれている。

[10]では、分類器としてBERT[11]を用いており、98%の分類精度を達成している。この結果から、文章のみで構成されるシングルモーダルなデータに対して、BERTを用いた手法が極めて高い精度で面白さを判定できることが示された。

3. 提案手法

本研究では、画像と文章のペアが大喜利として成立している場合を適合していると定義し、それを判定する AI を提案する。提案手法では、データセットを作成する際、大喜利として成立している画像と文章のペアは「ボケて」[3] の WEB サイトをスクレイピングすることで収集する。ボケてに存在する大喜利は画像と人間が画像から想起して投稿した面白文章で構成されるため、これを大喜利として成立している正例とする。また、大喜利として成立していない画像と文章のペアを、正例の画像と文章をランダムに組み替えることで作成する。ランダムに組み替えられた画像と文章は関連性が無いため、これを大喜利として成立していない負例とする。このデータセットはプログラムによって作成可能であるため、手間を必要としない。

提案手法では、ボケてのウェブサイトをスクレイピングすることでデータセットを作成するが、ボケてに投稿されている大喜利の中には本研究の目的に適さないお題画像や文章も含まれている。これらを以下の前処理によって取り除く。

a) 画像中に文字を含むお題画像

ボケてには、図 1a に示すような、画像中に文字で大喜利のお題を記載したお題画像が投稿されている。このような画像に対して人間が大喜利を作成する場合、画像中の文字を認識し、その文章に基づいて面白い文章を想起する。本研究の目的は、画像から直接面白い文章を想起することにあるため、画像中の文字を含む大喜利は対象外とする。スクレイピングで収集したお題画像に対して、Google Cloud Vision の OCR 機能 [13] を使用して光学文字認識を行い、文字が検出された画像はデータセットから除外した。

b) 固有名詞を含む文章

ボケてには、固有名詞を含む面白文章が投稿されている。このような面白文章を想起するためには、画像からの想起に加えて固有名詞の情報を必要とするため、本研究の目的とする画像から直接想起する面白文章とは異なる。そのため、固有名詞を含む文章も事前に取り除く。スクレイピングで収集した文章に対して、McCab [14] を用いて形態素解析を行い、固有名詞と判定された単語を含む文章はデータセットから除外した。

c) アニメーションや漫画のお題画像

ボケてには、図 1b に示すような、アニメーションのフレームや漫画のコマを切り抜いたお題画像が投稿されている。このような画像に対して人間が大喜利を作成する場合、画像中のキャラクターの情報を必要とするため、本研究の目的である画像から直接想起する面白文章とは異なる。したがって、アニメーションや漫画のお題画像も事前に除外する。スクレイピングで収集したお題画像に対して、現実の画像であるかアニメーションや漫画の画像であるかを分類する AI を用いて分類を行い、現実画像でない判定された画像はデータセットから除外した。

提案手法では、ボケてに存在しない大喜利の負例として、画像と文章をランダムに組み替えたペアを用いる。これに加えて、ランダムに組み替えた大喜利以外の、ボケてに存在しない画像と文章のペアを学習することで、判定 AI のロバスト性が向上す

ることが期待できる。そこで、提案手法では、ボケてに存在しない文章として画像のキャプションを追加する。キャプションは、単に画像を説明する文章であり、面白文章を投稿するボケてには存在しない文章と言える。キャプションはキャプション生成 AI を用いることで自動的に生成できるため、提案手法のプログラムによってデータセットを作成する利点を損なわない。提案手法ではキャプション生成 AI として Salesforce/blip2-flan-t5-xl [15] を使用する。また、キャプション生成 AI が出力するキャプションは英語であるため Mitsua/elan-mt-bt-en-ja [16] で日本語に翻訳した。

提案手法では、画像の特徴抽出器として rinna/japanese-clip-vit-b-16 [8] を、文章の特徴抽出器として rinna/japanese-clip-vit-b-16 および sonoisa/sentence-luke-japanese-base-lite [17] を採用する。rinna/japanese-clip-vit-b-16 は画像と日本語の文章を同時に学習したマルチモーダルモデルであり、これを用いることで [1], [12] と同様に高い分類精度が得られることが期待できる。rinna/japanese-clip-vit-b-16 は、画像または文章を 512 次元の特徴量に、sonoisa/sentence-luke-japanese-base-lite は文章を 512 次元の特徴量に変換する。これらの特徴量を結合し、4 層の全結合層からなるニューラルネットワークに入力する。全結合層のニューロン数は、出力層を除くすべての層で 1024 とし、活性化関数には Leaky ReLU を使用する。出力層のニューロン数は 1 とし、活性化関数には Sigmoid を用いる。また、rinna/japanese-clip-vit-b-16 および sonoisa/sentence-luke-japanese-base-lite のパラメータは学習中に更新しない。



(a) 画像中に文字を含むお題画像

(b) アニメーションのお題画像

図 1: 前処理によって取り除いた画像の例

4. 実験

4.1 実験 1: キャプションを含むデータセットの学習

本節では、負例として画像のキャプション文章を含む場合と含まない場合の 2 種類のデータセットを用いて判定 AI を学習し、その結果を比較する。学習に使用するデータは、ボケて [3] から収集した画像 251,799 枚、大喜利文章 2,297,194 件、キャプション文章 251,799 件である。収集した画像のうち 1% の画像と、それに対応する文章を検証用データとする。また、ランダムに画像と文章を組み替えた負例の数は、正例と同数とする。最適化手法には AdamW [18] を用い、学習率などのハイパーパラメータは PyTorch のデフォルト値 [19] を使用した。ミニバッチサイズは 64、学習の反復回数は 15 回とした。

学習したモデルの検証用データに対する分類精度を表1に示す。二値分類のしきい値を0.5と定め、モデルの出力が0.5より大きい場合に大喜利として成立している、0.5以下の場合に大喜利として成立していないと判定したとする。表1から、キャプションの有無に関わらず、判定AIは大喜利として成立しているか否かを71%から72%の精度で判定できることがわかる。さらに、キャプションを学習したモデルは98%の精度で画像とキャプション文章のペアを大喜利として成立していないと判定できたのに対し、キャプションを学習していないモデルでは、この判定の精度が4%と著しく低下した。この結果から、ボケてに投稿されている大喜利は、キャプションほど画像との関連性が高いわけではないものの、ランダムに組み替えられた画像と文章のペアよりは関連性が高いことが示唆される。

表1: 検証用データに対する分類精度

学習に用いたデータセット	正例に対する分類精度	負例の大喜利に対する分類精度	キャプションに対する分類精度
キャプション有り	72.21%	71.21%	98.93%
キャプション無し	71.02%	72.29%	4.12%

学習したモデルにボケてに投稿された大喜利を入力した際の評価を表2に示す。ここで、表2の画像は、ボケてに投稿された実際の大喜利のお題画像ではなく、ボケてのお題画像に類似したフリー画像である。表2から、赤ちゃんがジュースを持っている画像と『ギャン泣きした後のジュースがうめえー。』という文章、ラーメンの画像と『シェフの気まぐれサラダ』という文章がペアとなっており、これらの文章は画像から想起可能な面白文章であり、大喜利として成立した画像と文章のペアであると言える。評価値は1に近いほど画像と文章のペアが大喜利として成立していること、0に近いほど画像と文章のペアが大喜利として成立していないことを示す。表2から、キャプションを学習したモデルは、大喜利のお題画像を類似画像に置き替えても、高い評価を維持していることがわかる。一方、キャプションを学習していないモデルは、『しりとり「リンゴ」待ち』という大喜利に対して、しきい値0.5を下回る評価を与えており、大喜利として成立していると判定できていない。

学習したモデルに表2の大喜利の画像と文章をランダムに組み替えたペアを入力した際の評価を表3に示す。表3から、ランダムに組み替えたペアは、赤ちゃんがジュースを持っている画像に対して『シェフの気まぐれサラダ』という文章、ゴリラの画像に対して『ギャン泣きした後のジュースがうめえー。』という文章がペアとなっており、ボケてに投稿された成立している大喜利と比べ画像と文章の関連性が低いことがわかる。学習したモデルは表2の評価値と比べ、小さな評価値を出力しており、このことからモデルが大喜利が成立しているか否かを判定可能であると言える。しかし、キャプションを学習したモデルが、ラーメンの画像と『ギャン泣きした後のジュースがうめえー。』という文章のペア、ラーメンの画像と『しりとり「リンゴ」

表2: ボケての大喜利に対する評価

画像		
大喜利	ギャン泣きした後のジュースうめえー。	
キャプション有り	0.8098	0.9714
キャプション無し	0.5842	0.9834
画像		
大喜利	しりとり「リンゴ」待ち	
キャプション有り	0.6431	0.6244
キャプション無し	0.4025	0.2860
画像		
大喜利	シェフの気まぐれサラダ	
キャプション有り	0.9802	0.9189
キャプション無し	0.9977	0.9264

待ち』という文章のペアに対して、しきい値の0.5を超えた評価値を出力しており、成立している大喜利であると予測している。これらの文章は画像から想起できるものではなく、この予測は誤りであると言える。また、キャプションを学習していないモデルは、赤ちゃんがジュースを持っている画像と『シェフの気まぐれサラダ』という文章のペアに対して、しきい値の0.5を超えた評価値を出力しており、成立している大喜利であると予測している。このペアは、本来の大喜利とは異なる画像と文章の組み合わせであるものの、画像中のジュースをサラダであると解釈した大喜利であることができるため、必ずしも誤った評価とは言い切れない。

学習したモデルに画像とキャプションのペアを入力した際の評価を表4に示す。キャプションはデータセットの作成時と同様に、Salesforce/blip2-flan-t5-xl [15] と Mitsua/elan-mt-bt-en-ja [16] を用いて生成した。表4から、ゴリラが枝を食べている画像に対して『ゴリラが枝を食べている様子』というキャプション、ラーメンの画像に対して『ラーメンに麺と卵を入れたもの』というキャプションがペアとなっており、これらは画像に対する適切なキャプションであると言える。また、表4から、キャプションを学習したモデルが画像とキャプションのペアに対して低い評価値を出力しており、これにより画像とキャプションが大喜利として成立していないことを正確に判定できていることがわかる。一方、キャプションを学習していないモデルは、画像とキャプションのペアに対し高い評価値を出力しており、このペアが大喜利として成立していると誤って判定していることが確認できる。

学習したモデルに、画像と画像に対する大喜利文章を生成す

表 3: ボケてに存在しない大喜利に対する評価

画像	 	
大喜利	ギャン泣きした後のジュースうめえー.	
キャプション有り	0.4325	0.5926
キャプション無し	0.2499	0.3737
画像	 	
大喜利	しりとり「リンゴ」待ち	
キャプション有り	0.2109	0.8639
キャプション無し	0.2573	0.4279
画像	 	
大喜利	シェフの気まぐれサラダ	
キャプション有り	0.3122	0.0499
キャプション無し	0.6709	0.0892

る AI が生成した文章のペアからなる大喜利を入力した際の評価を表 5 に示す. 大喜利生成 AI として [20] を使用した. 表 5 から, 赤ちゃんがジュースを持っている画像に対して『え? これ毒なの?』という文章, ゴリラの画像に対して『おい, バナナの皮持ってこいよ.』という文章がペアとなっており, 大喜利生成 AI が画像に適した文章を生成していることがわかる. 表 5 から, ゴリラが枝を食べている画像と『「今日から俺が人間のパパ?」』という文章のペアからなる大喜利に対して, モデルが低い評価値を出力していること, 一方でその他の画像と文章のペアからなる大喜利に対して高い評価値を出力していることがわかる. このことから, [20] の大喜利生成 AI が生成する大喜利の多くは成立した大喜利であると言える. 表 2 と表 5 から, モデルが同じ画像であっても文章が異なる場合に, 異なる評価を出力していることがわかる. このことから, モデルは画像と文章の関連性を考慮して評価を出力していると言える.

これらの結果から, ボケてから収集した画像と文章のペアを学習したモデルが, 画像と文章のペアが大喜利として成立しているか否かを判定できることがわかる. また, キャプションを

表 4: 画像とキャプションに対する評価

画像	 	
大喜利	ゴリラが枝を食べている様子	ラーメンに麺と卵を入れたもの
キャプション有り	0	0
キャプション無し	0.9878	0.9952

表 5: 大喜利生成 AI が生成した大喜利に対する評価

画像	 	
大喜利	え? これ毒なの?	「これ水じゃないか…」
キャプション有り	0.7203	0.8612
キャプション無し	0.6591	0.7805
画像	 	
大喜利	「今日から俺が人間のパパ?」	おい, バナナの皮持ってこいよ
キャプション有り	0.4013	0.8411
キャプション無し	0.3150	0.9661
画像	 	
大喜利	レモンの量の間違えた.	「お待たせしました, ライスの方です」
キャプション有り	0.9034	0.6504
キャプション無し	0.8976	0.6108

負例として学習することで, 画像とキャプションのペアが大喜利として成立していないと正確に判定できることが示唆される.

4.2 実験 2: 負例の数を増やしたデータセットの学習

本節では, 提案手法の判定 AI が学習するデータセットにおいて, 負例の大喜利の数を正例の大喜利の数の 2 倍, 3 倍に変更し, その結果を比較する. 実験 1 では, 判定 AI が学習するデータセットにおいて, 負例と正例の大喜利の数は同じであった. このデータセットを学習した判定 AI の分類精度は約 71% であり, 十分な精度とは言えない. そこで, 本節では負例の大喜利の数を増加させ, データセットの多様性を高めることで精度向上を試みる. 負例の大喜利は画像と文章を組み替えるだけであるため, 負例の数を増やしても提案手法のプログラムによってデータセットを人手を介さずに作成できるという利点は損なわれない. 本節では, モデルが学習するデータセットに画像に対するキャプションも含める. 学習するデータセットは, 負例の数が正例と同じ, 正例の 2 倍, 正例の 3 倍の構成となる. 最適化手法には AdamW [18] を使用し, 学習率などのハイパーパラメータは PyTorch のデフォルト値 [19] を使用した. ミニバッチサイズは 64, 学習の反復回数は 15 回とした.

学習したモデルの検証用データに対する分類精度を図 2 に示す. 二値分類のしきい値を 0.1 から 0.9 まで 0.1 刻みで変化させ, それぞれのしきい値における分類精度を示している. 図 2 の横軸は二値分類のしきい値, 縦軸は分類精度を表しており, 赤線はキャプションに対する分類精度, 青線は正例の大喜利に対する分類精度, 緑線は負例の大喜利に対する分類精度を示している. 実線は負例の数が正例と同じデータセットを学習した

モデルの分類精度、破線は負例の数が正例の2倍のデータセットを学習したモデルの分類精度、点線は負例の数が正例の3倍のデータセットを学習したモデルの分類精度を表している。図2から、いずれのデータセットを学習したモデルも、キャプションに対しては大喜利として成立していないと判定していることがわかる。また、データセットにおける負例の数が増加すると、正例の大喜利と負例の大喜利の分類精度が交差するしきい値が小さくなることが確認できる。さらに、いずれのデータセットを学習したモデルも最適なしきい値における分類精度が約71%であることがわかる。これらの結果から、負例の数を増加させたデータセットを学習しても、判定AIの分類精度には改善が見られないと考えられる。




図2: 検証用データに対する各しきい値における分類精度

5. おわりに

本研究では、画像と文章のペアが大喜利として成立しているか否かを判定するAIを提案した。実験から、提案手法は71%の精度で画像と文章のペアが大喜利として成立しているか否かを判定することが確認できた。また、ボケてにない負例として画像のキャプションを学習させることで、画像とキャプションのペアが大喜利として成立していないと判定できることも確認された。

今後の課題として、負例の大喜利の作成方法の改善が挙げられる。提案手法では、ボケての画像と文章をランダムに組み替えることで負例を作成している。ボケての画像と文章は多様であるためランダムに組み替えた負例の多くは画像と文章の関連性が低くなる。しかし、ランダムに組み替えても、関連性が高い画像と文章のペアとなる可能性がある。この問題を解決するために、画像をCLIPなどの画像認識モデルで特徴量に変換し、組み替える前の画像と組み替えた後の画像の特徴量同士の類似度が低くなるように画像を置き換えることで、より質の高い負例のペアが作成できることが期待できる。また、提案手法では画像と文章の特徴抽出器を2種類のみ使用しているが、この特徴抽出器を変更する、または、数を増やすことで、判定精度の向上が期待できる。

本研究では、大喜利として成立しているかどうかを判断する

ことを目的としていたが、実際の応用では大喜利の質や面白さを評価することが求められる場面が多い。そのため、本研究で提案した大喜利の成立判定AIを発展させ、大喜利が面白いかな否かを判定するAIの開発へとつなげることが今後の重要な課題である。

謝辞

本研究の一部は科研費基盤研究(c)(課題番号:23K11267)の補助を得た。ここに謝意を表する。

文献

- [1] Kiela Douwe, et al., “The hateful memes challenge: Detecting hate speech in multimodal memes”, *proc. Advances in Neural Information Processing Systems* 33, pp. 2611-2624, Dec. 2020.
- [2] Nishika Inc., “ボケ判定 AI を作ろう！ (ボケてコンペ # 1)”, <https://competition.nishika.com/competitions/bokete/summary>, 最終閲覧日: 2025 年 2 月 14 日.
- [3] 株式会社オモロキ, “ボケて”, <https://bokete.jp/>, 最終閲覧日: 2025 年 2 月 14 日.
- [4] Li Liunian Harold, et al., “Visualbert: A simple and performant baseline for vision and language”, *arXiv preprint arXiv:1908.03557*, Aug. 2019.
- [5] Liu Yinhan, et al., “Roberta: A robustly optimized bert pretraining approach”, *arXiv preprint arXiv:1907.11692* 364, Jul. 2019.
- [6] Alexey Dosovitskiy, et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”, *arXiv:2010.11929*, Oct. 2020.
- [7] Liu Ze, et al., “Swin transformer: Hierarchical vision transformer using shifted windows”, *proc. International Conference on Computer Vision*, pp.10012-10022, Oct. 2021.
- [8] Hugging Face, “rinna/japanese-clip-vit-b-16”, <https://huggingface.co/rinna/japanese-clip-vit-b-16>, 最終閲覧日: 2025 年 2 月 14 日.
- [9] Fürst Andreas, et al., “Cloob: Modern hopfield networks with in-foloolb outperform clip”, *proc. Advances in Neural Information Processing Systems* 35, pp. 20450-20468, Nov. 2022.
- [10] Annamoradnejad Issa, et al., “ColBERT: Using BERT sentence embedding in parallel neural networks for computational humor”, *Expert Systems with Applications* 249, 123685, Sep. 2024.
- [11] Kenton Jacob, et al., “Bert: Pre-training of deep bidirectional transformers for language understanding”, *proc. Annual Conference of the North American Chapter of the Association for Computational Linguistics*, Vol. 1, No. 2, Jun. 2019.
- [12] Qiita Inc., “「笑い」を理解する AI を作ってみました～ボケ判定 AI を作ろう！ (ボケてコンペ # 1) 1st place solution ～”, <https://qiita.com/z-lai/items/2d51ce123d77ad7100e8>, 最終閲覧日: 2025 年 2 月 14 日.
- [13] Google LLC, “Detect text in images”, <https://cloud.google.com/vision/docs/ocr>, 最終閲覧日: 2025 年 2 月 14 日.
- [14] GitHub Inc., “MeCab: Yet Another Part-of-Speech and Morphological Analyzer”, <https://taku910.github.io/mecab>, 最終閲覧日: 2025 年 2 月 14 日.
- [15] Hugging Face, “Salesforce/blip2-flan-t5-xl”, <https://huggingface.co/Salesforce/blip2-flan-t5-xl>, 最終閲覧日: 2025 年 2 月 14 日.
- [16] Hugging Face, “Mitsua/elan-mt-base-en-ja”, <https://huggingface.co/Mitsua/elan-mt-base-en-ja>, 最終閲覧日: 2025 年 2 月 14 日.
- [17] Hugging Face, “sonoisa/sentence-luke-japanese-base-lite”, <https://huggingface.co/sonoisa/sentence-luke-japanese-base-lite>, 最終閲覧日: 2025 年 2 月 14 日.
- [18] Ilya Loshchilov, et al., “Decoupled Weight Decay Regularization”, *proc. International Conference on Learning Representations*, Apr. 2017.
- [19] Pytorch, “AdamW”, <https://pytorch.org/docs/stable/generated/torch.optim.AdamW.html> 最終閲覧日: 2025 年 2 月 17 日.
- [20] 山富 龍, 他, “Transformer を用いた大喜利の生成に関する研究”, 電子情報通信学会 2024 年総大会情報・システムソサイエティ 特別企画ジュニア&学生ポスターセッション予稿集, ISS-SP-033, Mar. 2024.