

Schedule-Free ADINA：学習率調整不要な 時空間2次ダイナミクス慣性付適応的勾配アルゴリズム

野村 太暉[†] 山富 龍[†] マハブーブ シェヘラザード[†] 二宮 洋[†]

[†] 湘南工科大学大学 〒251-8511 神奈川県藤沢市辻堂西海岸 1-1-25

E-mail: {23B2119@sit, 25T2501@sit, shaa@info, ninomiya@info}.shonan-it.ac.jp

あらまし 近年、ニューラルネットワーク (NN) の学習アルゴリズムとしての手法であるニュートン法を常微分方程式で表し慣性項と Adam を導入することで、学習の高速化とロバスト性の向上を実現した ADINA が提案された。しかし、ADINA はバッチサイズが小さくなると学習が安定しなくなるという問題がある。一方、各反復における NN のパラメータの反復平均を利用することで、学習率を調整せず更新量を減衰させる Schedule-Free 手法がある。本研究では、ADINA に Schedule-Free 手法を導入することで、ADINA のミニバッチ学習におけるロバスト性向上を試みた新たな最適化手法を提案する。提案手法の有効性を NN を用いた数値実験により示す。

キーワード ニューラルネットワーク, 最適化手法, 微分方程式, 反復平均化, 適応的学習, 慣性項

Schedule-Free ADINA: Learning Rate Schedule-Free Spatiotemporal Second-Order Dynamics Inertial Adaptive Gradient Algorithm

Taiki NOMURA[†], Ryo YAMATOMI[†], Shahrzad MAHBOUBI[†], and Hiroshi NINOMIYA[†]

[†] Shonan Institute of Technology 1-1-25 Tsujido Nishi-Kaigan, Fujisawa City, Kanagawa, 251-8511 Japan

E-mail: {23B2119@sit, 25T2501@sit, shaa@info, ninomiya@info}.shonan-it.ac.jp

Abstract Recently, a novel optimization algorithm named ADINA has been proposed. It integrates an inertial term and the Adam optimizer into an Ordinary Differential Equations (ODEs)-based framework derived from the Newton method, aiming to achieve fast convergence and enhanced robustness. However, due to its complex update mechanism, ADINA is sensitive to the noise inherent in stochastic gradients during mini-batch learning, which often leads to instability during training. In contrast, the Schedule-Free framework utilizes iterate averaging as a core mechanism to suppress stochastic noise and stabilize the learning process by eliminating the necessity for learning rate schedules. In this study, we propose a novel optimization algorithm, Schedule-Free ADINA, which incorporates the stabilizing mechanism of Schedule-Free framework into the ADINA. This integration is designed to alleviate the challenges associated with learning rate tuning in ADINA and overall performance, particularly in small mini-batch conditions. The effectiveness of the proposed method is demonstrated through benchmark experiments using neural networks.

Key words Neural Networks, Optimization Method, ODE systems, Iterate Averaging Method, Adaptive Learning, Momentum Term.

1. はじめに

近年、IoT 技術の発展に伴い観測データは大規模かつ複雑化しており、要素間に強い相互作用を持つ非線形性を示すものが含まれる。このようなデータをニューラルネットワーク (NN) で高精度かつ高速に処理するためには、高性能な最適化手法が不可欠である。

最適化問題に対し、Dynamical Inertial Newton method (DIN) [1] と Dynamical Adam [2] を基礎とする最適化手法 Adaptive mo-

mentum estimation in DIN Algorithm (ADINA) [3] が提案された。ADINA は、ニュートン法 [4] に由来する曲率情報を効率的に活用しつつパラメータごとに適応的に学習を変更することで、高い学習性能を達成する。しかしミニバッチ学習において、その複雑な更新が全データの勾配とミニバッチ勾配との乖離の影響を受けやすく、結果として学習の安定が実用上の重要な課題として指摘されている。

Schedule-Free [5] は、学習の各反復のパラメータ平均を用いる反復平均化により、学習率スケジューリングの自動化を実現

した。このメカニズムは Polyak-Ruppert averaging [6] と Primal averaging [7] の原理を応用したものである。反復平均化は学習率スケジューリングの自動化のみならず、その平均化プロセスを通じて全データの勾配とミニバッチの勾配との乖離を軽減し、学習全体を安定させるという特性を持つことが予想される。

本研究では、ADINA に Schedule-Free 手法の反復平均化を導入した新たな最適化手法 Schedule-Free ADINA を提案する。提案手法は ADINA が抱えるミニバッチ学習への脆弱性という課題に対し、反復平均化によって全データの勾配とミニバッチ勾配との乖離を軽減することで、小さいバッチサイズでも安定した学習が期待できる。

提案手法の有用性を確認するために、MNIST データセットを用いて全結合モデルおよび畳み込みニューラルネットワーク (CNN) モデルに対する計算機実験を実施する。

2. 従来研究

本研究では (1), (2) に示す最適化について考える。

$$\operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^d} E_{\mathcal{D}}(\mathbf{w}), \quad (1)$$

$$E_{\mathcal{D}}(\mathbf{w}) = \frac{1}{N} \sum_{(\mathbf{p}, \mathbf{c}) \in \mathcal{D}} e(\mathbf{f}_{\mathbf{w}}(\mathbf{p}), \mathbf{c}). \quad (2)$$

ここで、 $\mathbf{w} \in \mathbb{R}^d$ は NN のパラメータ、 $\mathcal{D} = \{(\mathbf{p}_i, \mathbf{c}_i)\}_{i=1}^N$ は N 個のデータから成る訓練データセット、 $\mathbf{p}_i$ は i 番目の入力、 $\mathbf{c}_i$ はそれに対応する教師信号、 $\mathbf{f}_{\mathbf{w}}(\mathbf{p})$ はパラメータ $\mathbf{w}$ を重みとして持つ入力 $\mathbf{p}$ に対する NN の出力、 $e(\mathbf{f}_{\mathbf{w}}(\mathbf{p}), \mathbf{c})$ は NN の出力 $\mathbf{f}_{\mathbf{w}}(\mathbf{p})$ と教師信号 $\mathbf{c}$ が一致するとき最小となる誤差関数である。

NN の最適化では差分方程式で記述された勾配法 [8] が用いられる。勾配法は誤差関数 $E_{\mathcal{D}}(\mathbf{w})$ の勾配を利用して、誤差が最も減少する方向にパラメータ $\mathbf{w}$ を更新する手法である。勾配法の更新式を (3) に示す。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla E_{\mathcal{D}}(\mathbf{w}_k). \quad (3)$$

ここで、 k は学習の反復回数、 $\mathbf{w}_k$ はステップ k におけるパラメータ、 η は学習率、 $\nabla E_{\mathcal{D}}(\mathbf{w}_k) = \partial E_{\mathcal{D}}(\mathbf{w}_k) / \partial \mathbf{w}_k$ は勾配である。

本稿で議論する最適化アルゴリズムは、離散時間表現と連続時間表現の二つの視点で考える。離散時間表現の更新式は、現在のパラメータ $\mathbf{w}_k$ から次の $\mathbf{w}_{k+1}$ を求める差分方程式で記述される。一方、連続時間表現の更新ステップは、パラメータ $\mathbf{w}(t)$ が時間と共に変化する微分方程式として記述される。離散時間表現と連続時間表現を対応付けるため、離散時間におけるステップ k のパラメータ $\mathbf{w}_k$ は、連続時間における時刻 t のパラメータ $\mathbf{w}(t)$ に対応すると考える。また、時間ステップ幅を η とすると、ステップ k の次のステップ $k+1$ のパラメータ $\mathbf{w}_{k+1}$ は時刻 $t+\eta$ のパラメータ $\mathbf{w}(t+\eta)$ 、ステップ k の前のステップ $k-1$ のパラメータ $\mathbf{w}_{k-1}$ は時刻 $t-\eta$ のパラメータ $\mathbf{w}(t-\eta)$ に対応する。すなわち、以下の関係が成立すると考える。

$$\mathbf{w}_k \approx \mathbf{w}(t), \quad (4)$$

$$\mathbf{w}_{k+1} \approx \mathbf{w}(t+\eta), \quad (5)$$

$$\mathbf{w}_{k-1} \approx \mathbf{w}(t-\eta). \quad (6)$$

従って、 $\mathbf{w}(t)$ の時刻 t に対する時間微分を次のように示すこととする。

$$\frac{\partial \mathbf{w}(t)}{\partial t} = \dot{\mathbf{w}}(t) \approx \frac{\mathbf{w}_{k+1} - \mathbf{w}_k}{\eta}, \quad (7)$$

$$\frac{\partial^2 \mathbf{w}(t)}{\partial t^2} = \ddot{\mathbf{w}}(t) \approx \frac{\mathbf{w}_{k+1} - 2\mathbf{w}_k + \mathbf{w}_{k-1}}{\eta^2}. \quad (8)$$

2.1 DIN [1]

勾配法は一般的に、誤差関数のパラメータ $\mathbf{w}$ に関する 1 次微分で得られる勾配を用いる 1 次手法と、誤差関数のパラメータ $\mathbf{w}$ に関する 2 次微分で得られるヘッセ行列を用いる 2 次手法に分類できる。Dynamical Inertial Newton method (DIN) は、モーメンタム法 [9] に由来する時間の 2 階微分 (加速度) $\ddot{\mathbf{w}}(t)$ と、ニュートン法に由来するパラメータ空間の 2 次微分 (ヘッセ行列) $\nabla^2 E_{\mathcal{D}}(\mathbf{w}_k) = \partial^2 E_{\mathcal{D}}(\mathbf{w}_k) / \partial \mathbf{w}^2$ を組み合わせたアルゴリズムである。微分方程式で示されるニュートン法の更新式を (9) に示す。

$$\eta \nabla^2 E_{\mathcal{D}}(\mathbf{w}(t)) \ddot{\mathbf{w}}(t) + \nabla E_{\mathcal{D}}(\mathbf{w}(t)) = \mathbf{0}. \quad (9)$$

モーメンタム法は過去の更新量を考慮することで慣性の概念を勾配法に取り入れた手法である。微分方程式で示されるモーメンタム法の更新式を (10) に示す。

$$\ddot{\mathbf{w}}(t) + a \dot{\mathbf{w}}(t) + \nabla E_{\mathcal{D}}(\mathbf{w}(t)) = \mathbf{0}. \quad (10)$$

ここで a は、摩擦の影響を調整するハイパーパラメータである。

連続時間表現のニュートン法 (9) と、モーメンタム法 (10) を組み合わせることで、DIN が導出される。DIN を (11) に示す。

$$\ddot{\mathbf{w}}(t) + a \dot{\mathbf{w}}(t) + b \nabla^2 E_{\mathcal{D}}(\mathbf{w}(t)) \dot{\mathbf{w}}(t) + \nabla E_{\mathcal{D}}(\mathbf{w}(t)) = \mathbf{0}. \quad (11)$$

ここで、 b はヘッセ行列の影響を調整するハイパーパラメータである。

(11) はヘッセ行列を含む形式で最適化手法が定式化されているが、これは計算コストおよびメモリ使用量の観点で実装上のボトルネックとなる。この問題に対処するため、ヘッセ行列を明示的に計算せずに済むよう (11) を連立一次常微分方程式系に変換する手法が提案されており、そのダイナミクスは (12) のように示される。

$$\begin{cases} \ddot{\mathbf{w}}(t) + b \nabla E_{\mathcal{D}}(\mathbf{w}(t)) + (a - \frac{1}{b}) \dot{\mathbf{w}}(t) + \frac{1}{b} \mathbf{y}(t) = \mathbf{0}, \\ \dot{\mathbf{y}}(t) + (a - \frac{1}{b}) \mathbf{w}(t) + \frac{1}{b} \mathbf{y}(t) = \mathbf{0}. \end{cases} \quad (12)$$

連続時間で表現された DIN をコンピュータ上で実行するために (12) を離散化して差分方程式に変換する。(7), (12) より得られる、DIN を離散時間で表現した更新式を (13) に示す。

$$\begin{cases} \mathbf{w}_{k+1} = \mathbf{w}_k + \eta [(\frac{1}{b} - a) \mathbf{w}_k - \frac{1}{b} \mathbf{y}_k - b \nabla E_{\mathcal{D}}(\mathbf{w}(t))], \\ \mathbf{y}_{k+1} = \mathbf{y}_k + \eta [(\frac{1}{b} - a) \mathbf{w}_k - \frac{1}{b} \mathbf{y}_k]. \end{cases} \quad (13)$$

2.2 ADINA [3]

最適化手法 Adam [10] は、パラメータごとに適切に学習率を変更する RMSProp [8] と、モーメント法を組み合わせた手法である。Adam の更新式を (14)–(16) に示す。

$$\mathbf{m}_{k+1} = \beta_1 \mathbf{m}_k + (1 - \beta_1) \nabla E_{\mathcal{D}}(\mathbf{w}_k), \quad (14)$$

$$\mathbf{v}_{k+1} = \beta_2 \mathbf{v}_k + (1 - \beta_2) (\nabla E_{\mathcal{D}}(\mathbf{w}_k))^2, \quad (15)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{\mathbf{m}_{k+1} / (1 - \beta_1^{k+1})}{\sqrt{\mathbf{v}_{k+1} / (1 - \beta_2^{k+1}) + \epsilon}}. \quad (16)$$

ここで、 ϵ は零除算をさけるためのハイパーパラメータ、 $\mathbf{m}_k$ および $\mathbf{v}_k$ はそれぞれ 1 次モーメント項と 2 次モーメント項、 β_1 、 β_2 はそれぞれ 1 次モーメント項及び 2 次モーメント項を制御するハイパーパラメータである。また、学習の初期ステップ $k=0$ において $\mathbf{m}_0 = \mathbf{v}_0 = \mathbf{0}$ である。なお、 $(\nabla E_{\mathcal{D}}(\mathbf{w}_k))^2$ は勾配ベクトルの各要素の 2 乗である。

離散的な最適化手法 Adam を連続時間表現に拡張した手法として Dynamical Adam [2] が提案されており、その更新式は (17)–(19) で示される。

$$\dot{\mathbf{m}}(t) = \phi (\nabla E_{\mathcal{D}}(\mathbf{w}(t)) - \mathbf{m}(t)), \quad (17)$$

$$\dot{\mathbf{v}}(t) = \psi ((\nabla E_{\mathcal{D}}(\mathbf{w}(t)))^2 - \mathbf{v}(t)). \quad (18)$$

$$\dot{\mathbf{w}}(t) = - \frac{\mathbf{m}(t) / (1 - e^{-\phi t})}{\sqrt{\mathbf{v}(t) / (1 - e^{-\psi t}) + \epsilon}} \quad (19)$$

ここで、 $\phi = (1 - \beta_1) / \eta$ 、 $\psi = (1 - \beta_2) / \eta$ である。

離散化された DIN はヘッセ行列の計算コストという問題を解決した一方、慣性項による学習の加速効果が不十分であるという課題が残されていた。この課題を克服するために提案された ADINA では、DIN を連立 1 階常微分方程式に変換する際にそのダイナミクスが Adam のダイナミクスと構造的に類似するように設計されている。連立 1 階常微分方程式で表した DIN の更新式 (12) と、Dynamical Adam の (17), (18), (19) より、連続時間表現の ADINA の更新式 (20)–(22) を得る。

$$\dot{\mathbf{g}}(t) = a \left(\frac{1 - ab}{a} \nabla E_{\mathcal{D}}(\mathbf{w}(t)) - \mathbf{g}(t) \right), \quad (20)$$

$$\dot{\mathbf{v}}(t) = \frac{1 - \beta_2}{\eta} (\nabla E_{\mathcal{D}}(\mathbf{w}(t))^2 - \mathbf{v}(t)), \quad (21)$$

$$\dot{\mathbf{w}}(t) = - \frac{\mathbf{g}(t) / (1 - e^{-\frac{1-\beta_1}{\eta} t}) + b \nabla E_{\mathcal{D}}(\mathbf{w}(t))}{\sqrt{\mathbf{v}(t) / (1 - e^{-\frac{1-\beta_2}{\eta} t}) + \epsilon}}. \quad (22)$$

ここで、 $\mathbf{g}(t)$ は Adam の 1 次モーメント項に対応する変数である。これを、(7) で離散化した差分方程式の ADINA の更新式は (23)–(25) 以下で示される。

$$\mathbf{g}_{k+1} = \beta_1 \mathbf{g}_k + (1 - \beta_1) \frac{1 - ab}{a} \nabla E_{\mathcal{D}}(\mathbf{w}_k), \quad (23)$$

$$\mathbf{v}_{k+1} = \beta_2 \mathbf{v}_k + (1 - \beta_2) \nabla E_{\mathcal{D}}(\mathbf{w}_k), \quad (24)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{\mathbf{g}_{k+1} / (1 - \beta_1^{k+1}) + b \nabla E_{\mathcal{D}}(\mathbf{w}_k)}{\sqrt{\mathbf{v}_{k+1} / (1 - \beta_2^{k+1}) + \epsilon}}. \quad (25)$$

ここで、 $\beta_1 = 1 - a\eta$ である。

ADINA は、DIN が持つ曲率情報を活用した高い学習性能を維持しながら、Adam の適応的な学習率調整やバイアス補正による安定性を組み合わせることで、低計算コストかつ高いロバスト性を実現する。

3. 提案手法

本研究では、ADINA が抱えるミニバッチ学習への脆弱性を克服するため、反復平均化の原理を応用した新たな最適化手法 Schedule-Free ADINA を提案する。ADINA は一般の最適化問題に対して高い学習性能を示す一方で、ミニバッチ学習で生じる誤差の乖離に起因する不安定性という課題をもつ。そこで本研究では、Schedule-Free 手法で用いられる反復平均化の考え方を ADINA に導入することを考える。

3.1 Schedule-Free [5]

深層学習の最適化手法の多くは、性能を高めるために学習率スケジュールの手動調整に大きく依存している。これらの手法では、総訓練ステップ数を事前に把握する必要があり、実運用上の大きな制約となっている。この課題を解決する Schedule-Free 手法は、反復平均化により学習率の事前調整を不要にするアプローチである。代表的な反復平均化の手法には、Polyak-Ruppert averaging [6] および Primal averaging [7] がある。

勾配法ではすべてのデータを使ってパラメータの更新をしていた。しかし、大規模なデータセット $\mathcal{D}$ でこれを行うには計算時間が膨大となり現実的ではない。これを解決するために $\mathcal{D}$ から小規模のデータ（ミニバッチ） $\mathcal{B}_k$ を抽出し、少ないデータセットでパラメータの更新を行う手法として確率的勾配降下法 (Stochastic Gradient Descent, SGD) [11] がある。SGD の更新式を (26) に示す。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla E_{\mathcal{B}_k}(\mathbf{w}_k). \quad (26)$$

$E_{\mathcal{B}_k}(\mathbf{w}_k)$ から計算される誤差は、 $E_{\mathcal{D}}(\mathbf{w}_k)$ で計算される本来目的とする誤差と異なる。SGD ではこの乖離により全データに対する最適な勾配が得られないという課題がある。

これに対し、Polyak-Ruppert averaging は、SGD のステップ k までの各更新で得られるパラメータの平均 $\mathbf{x}_k$ を用いて推論を行う。Polyak-Ruppert averaging の更新式を (27), (28) に示す。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla E_{\mathcal{B}_k}(\mathbf{w}_k), \quad (27)$$

$$\mathbf{x}_{k+1} = (1 - \frac{1}{k+1}) \mathbf{x}_k + \frac{1}{k+1} \mathbf{w}_{k+1}. \quad (28)$$

$\mathbf{x}_k$ はステップ k までのパラメータの平均を表し、 $\mathbf{x}_0 = \mathbf{0}$ である。Polyak-Ruppert averaging では平均を計算することでミニバッチ学習による誤差の乖離を軽減し、推論として用いる $\mathbf{x}_k$ はより安定で真の最適解に近い値となる。しかし、勾配計算とパラメータ更新は $\mathbf{w}_k$ を用いて行われるため、探索の軌道そのものはミニバッチと全データでの誤差の乖離の影響を受け、依然として不安定な挙動を示す課題がある。

これに対して、Primal averaging は勾配の計算にステップ k までのパラメータの平均 $\mathbf{x}_k$ を用いる。Primal averaging の更新式を (29), (30) に示す。

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla E_{\mathcal{B}_k}(\mathbf{x}_k), \quad (29)$$

$$\mathbf{x}_{k+1} = \left(1 - \frac{1}{k+1}\right)\mathbf{x}_k + \frac{1}{k+1}\mathbf{w}_{k+1}. \quad (30)$$

Primal averaging では平均化された点で勾配を計算することで誤差の乖離が平滑化され学習も安定するものの、収束が遅くなるという問題がある。

Schedule-Free 手法は、Polyak-Ruppert averaging と Primal averaging を内包し、それぞれの利点を活かすことで学習率スケジュールに依存せずに安定性と収束速度の両立を目指している。

学習の反復における平均を使うことで、学習率スケジューリングの手動調整を回避する手法として Schedule-Free SGD が提案された。Schedule-Free SGD による更新式を (31)–(33) に示す。

$$\mathbf{y}_k = (1 - \lambda)\mathbf{w}_k + \lambda\mathbf{x}_k, \quad (31)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla E_{\mathcal{B}_k}(\mathbf{y}_k), \quad (32)$$

$$\mathbf{x}_{k+1} = \left(1 - \frac{1}{k+1}\right)\mathbf{x}_k + \frac{1}{k+1}\mathbf{w}_{k+1}. \quad (33)$$

ここで、 λ は $\mathbf{w}_k$ と $\mathbf{x}_k$ の内分する割合のハイパーパラメータである。また、 $\mathbf{x}_k$ は各更新で得られるパラメータの平均、 $\mathbf{y}_k$ は各更新で得られるパラメータと、これまでのパラメータの平均を内分したパラメータを表す。

3.2 提案手法: Schedule-Free ADINA

Schedule-Free 手法のパラメータと平均化したパラメータの内分を勾配の更新に使う考え方を ADINA に導入する。提案する Schedule-Free ADINA の更新式を (34)–(38) に示す。

$$\mathbf{y}_k = (1 - \lambda)\mathbf{w}_k + \lambda\mathbf{x}_k, \quad (34)$$

$$\mathbf{g}_{k+1} = \beta_1 \mathbf{g}_k + (1 - \beta_1) \left(\frac{1 - ab}{a} \right) \nabla E_{\mathcal{B}_k}(\mathbf{y}_k), \quad (35)$$

$$\mathbf{v}_{k+1} = \beta_2 \mathbf{v}_k + (1 - \beta_2) (\nabla E_{\mathcal{B}_k}(\mathbf{y}_k))^2, \quad (36)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{\frac{\mathbf{g}_{k+1}}{1 - \beta_1^{k+1}} + b \nabla E_{\mathcal{B}_k}(\mathbf{y}_k)}{\sqrt{\frac{\mathbf{v}_{k+1}}{(1 - \beta_2^{k+1})} + \epsilon}}, \quad (37)$$

$$\mathbf{x}_{k+1} = \left(1 - \frac{1}{k+1}\right)\mathbf{x}_k + \frac{1}{k+1}\mathbf{w}_{k+1}. \quad (38)$$

ここで、 a は摩擦の影響を調整するハイパーパラメータ、 b はヘッセ行列の影響を調整するハイパーパラメータ、 β_1, β_2 はそれぞれ 1 次モーメント項及び 2 次モーメント項を制御するハイパーパラメータ、 η は学習率、 λ はステップ k でのパラメータ $\mathbf{w}_k$ とステップ k までのパラメータの平均 $\mathbf{x}_k$ を内分する割合のハイパーパラメータである。 $\mathbf{g}_k, \mathbf{v}_k, \mathbf{x}_k$ はそれぞれ 1 次モーメント項、2 次モーメント項、ステップ k までのパラメータの平均で、 $\mathbf{g}_0 = \mathbf{v}_0 = \mathbf{x}_0 = \mathbf{0}$ である。提案手法である Schedule-Free ADINA は、二つの異なる考え方を組み合わせた手法である。まず、ADINA が持つ変数変換によるヘッセ行列計算の削除により、2 次最適化手法固有の高い学習性能を低計算量で実現する。また、適応的学習率を用いることで Adam 同様の安定性が得られる。加えて、Schedule-Free の反復平均化を用いることで、ADINA の課題であったミニバッチ学習における全データとの

誤差の乖離を低減し学習過程全体の安定が期待される。

4. 実験

本実験では、手書き数字認識の標準データセットである MNIST を使用した。MNIST は 28×28 ピクセルのグレースケール画像と、それに対応する 0~9 の正解ラベルから構成され、学習用データが 60,000 件、検証用データが 10,000 件含まれている。全結合モデルでは、各画像を 1 次元ベクトル (784 次元) に変換してネットワークに入力した。

全結合モデルは、入力層、2 層の中間層、および出力層から構成される。各層のニューロン数は順に 784, 100, 50, および 10 と設定した。中間層には ReLU 活性化関数を、出力層には Softmax 活性化関数をそれぞれ適用し、最終的に 10 クラスに分類する。

CNN モデルは、入力層、2 層の畳み込み層、および出力層から構成される。畳み込み層の出力チャンネル数はそれぞれ 32 および 64 とし、カーネルサイズ、ストライド幅、およびパディングサイズはそれぞれ 3, 2, 1 に設定した。各畳み込み層の出力には ReLU 活性化関数を適用した後、全結合層を介して出力層へ接続され、Softmax 活性化関数により 10 クラスに分類する。

いずれのモデルにおいても損失関数には交差エントロピーを用い、学習は 50 エポックで行った。また、ハイパーパラメータは [3] に従い、Adam の学習率 $\eta = 10^{-3}$ 、 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ 、 $\epsilon = 10^{-8}$ 、および ADINA に従って $\alpha = 0.1$ 、 $\beta = 0.9$ を設定した。

4.1 実験 1: λ とバッチサイズによる影響

本節では、提案手法におけるハイパーパラメータ λ およびバッチサイズが学習に与える影響について検討する。先行研究である [5] では、 $\lambda = 0.9$ が推奨されているが本実験ではその妥当性を検証するため λ を 0.1 から 0.9 まで 0.1 刻みで変更し、分類性能の変化を観察する。また、[3] に従いバッチサイズを 16, 32, 64, 512, 1024, 2048 に設定し、それぞれの条件下での検証精度を比較する。

表 1 および 2 は、それぞれ全結合モデルおよび CNN モデルにおけるハイパーパラメータ λ とバッチサイズの違いによる最大検証精度の変化を示す。太字は各列の最大値を示す。いずれのモデルにおいても 16, 32 などの小さいバッチサイズでは λ を 0.7 ~ 0.9 の様に大きく設定することで高い精度が得られる。逆に 1024, 2048 などの大きなバッチサイズでは、 λ を 0.1 ~ 0.3 の様に小さくする方が高精度を示すことが確認できる。これは、バッチサイズの大きさに応じて勾配のばらつきが変化し、それに伴って学習の安定性や探索挙動が変わることと関係していると考えられる。バッチサイズが小さい場合、勾配のノイズが大きくなるため、過去の情報をより強く反映させる。すなわち λ を大きく取ることで学習の安定性が向上する。一方、大きなバッチサイズでは勾配のばらつきが小さくなるため、過去の情報に依存しすぎず現在の勾配に素早く追従するように、すなわち λ を小さく調整する方が有効である。

以上の結果より、バッチサイズに応じて λ を適応的に調整することが、提案手法の性能を最大化する上で有効であることが

分かる．将来的には，バッチサイズに応じて λ を自動調整するメカニズムの導入も有望な拡張と考えられる．

表 1: 実験 1: 全結合モデルの最大検証精度 (%)

λ	Batch Size					
	16	32	64	512	1024	2048
0.1	96.41	97.18	97.68	98.26	98.19	97.77
0.2	96.60	97.34	97.75	98.22	98.26	98.02
0.3	96.65	97.54	97.84	98.33	98.13	97.75
0.4	97.01	97.13	97.86	98.23	98.07	97.82
0.5	97.26	97.72	98.05	98.21	97.99	97.86
0.6	97.24	97.67	98.01	98.15	97.73	97.64
0.7	97.41	97.79	97.93	97.88	97.67	97.80
0.8	97.59	97.50	97.96	97.86	97.86	97.53
0.9	97.39	97.53	97.65	97.57	97.72	97.63

表 2: 実験 1: CNN モデルの最大検証精度 (%)

λ	Batch Size					
	16	32	64	512	1024	2048
0.1	98.22	98.22	98.83	99.23	99.24	99.09
0.2	97.96	98.34	98.84	99.14	99.16	99.07
0.3	98.32	98.45	98.87	99.19	99.11	98.98
0.4	98.42	98.68	98.96	99.13	99.19	99.02
0.5	98.70	98.99	98.94	99.10	99.08	98.91
0.6	98.77	98.80	99.05	99.16	99.17	98.81
0.7	98.99	98.96	99.10	99.20	99.14	98.93
0.8	98.98	99.04	99.05	99.11	99.00	98.83
0.9	98.94	98.96	98.90	98.88	98.74	98.77

4.2 実験 2: 従来手法との比較

本節では，提案手法の Schedule-Free ADINA の有効性を検証するため従来手法との性能比較実験を行う．使用するデータセット，モデル，誤差関数，学習回数は実験 1 同様である．比較する手法は，もっとも主流な最適化手法である Adam, Adam に Schedule-Free を導入した Schedule-Free Adam, 提案手法の原型である ADINA とした．

Schedule-Free Adam はベースとなる最適化手法として SGD の代わりに Adam を用いたものであり， $\mathbf{w}_k$ の更新ステップを Adam の更新式に置き換える．Schedule-Free Adam の更新式を (39)–(42) に示す．

$$\mathbf{y}_k = (1 - \beta_1)\mathbf{w}_k + \beta_1\mathbf{x}_k, \quad (39)$$

$$\mathbf{v}_{k+1} = \beta_2\mathbf{v}_k + (1 - \beta_2)(\nabla E_{\mathcal{B}_k}(\mathbf{y}_k))^2, \quad (40)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \frac{\nabla E_{\mathcal{B}_k}(\mathbf{y}_k)}{\sqrt{\mathbf{v}_k/(1 - \beta_2^{k+1}) + \epsilon}}, \quad (41)$$

$$\mathbf{x}_{k+1} = (1 - \frac{1}{k+1})\mathbf{x}_k + \frac{1}{k+1}\mathbf{w}_{k+1}. \quad (42)$$

ここで，ハイパーパラメータ β_1, β_2 はそれぞれ 0.9, 0.999 が推奨値である．

各アルゴリズムのハイパーパラメータは，実験 1 と同様に推奨値を用いた．特に，Schedule-Free ADINA における λ については，実験 1 に基づき，各バッチサイズにおいて最も精度が高かった値を使用した．

結果を図 1, 2 に示す．すべてのグラフにおいて横軸は学習回数，縦軸は検証用データに対する検証精度を表す．青点線は Adam, 黄破線は ADINA, 緑実線は Schedule-Free Adam, 赤実線は提案手法の Schedule-Free ADINA を示す．16, 32 などのバッチサイズが小さい設定において提案手法である Schedule-Free ADINA は Adam, Schedule-Free Adam と同等の検証精度を示すことが確認できる．また，バッチサイズが 64 以上の場合では提案手法が Adam, Schedule-Free Adam と同等，ADINA を上回る学習能力を示すことが確認できる．すべてのバッチサイズにおいて，提案手法が ADINA と比べ学習終了時において検証精度が高いことが確認できる．バッチサイズが 16 のグラフに着目すると，ADINA は学習回数ごとに検証精度が上下するのに対し提案手法は安定した検証精度を示している．これは反復平均化によりミニバッチ学習における全データとの誤差の乖離を低減したことが要因であると考えられる．バッチサイズが 2048 のグラフに着目すると，Schedule-Free ADINA と比べて ADINA のほうが検証精度の上昇が速いことが確認できる．これは，バッチサイズが大きくなることで 1 反復当たりの学習回数が減少するため，平均のパラメータによる誤差が十分に全データの誤差を表せていないためであると考えられる．ただし，この差は学習の初期に限定的でありグラフが示すように，最終的な検証精度は提案手法のほうが ADINA より高くなる．したがって，これは収束の初期軌道の違いであり提案手法の最終的な性能やロバスト性を損なうものではないと考えられる．

5. おわりに

本研究では，高性能な最適化手法である ADINA がバッチサイズが小さいと学習が不安定になるという課題を解決するため，Schedule-Free で用いられる反復平均化を ADINA に応用した，新たな最適化手法 Schedule-Free ADINA を提案した．実験により，提案手法が特に小さなバッチサイズにおいて，ADINA と比較して学習プロセスを大幅に安定させ最終的な汎化性能を改善することを示した．これは反復平均化により，ADINA の課題であったミニバッチ学習における全データとの誤差の乖離を低減したことが要因であると考えられる．

今後の課題としては，より大規模なデータセットやさらに複雑なモデルに対する本手法の有効性の網羅的な検証が挙げられる．また，ADINA のハイパーパラメータ群 a, b と反復平均化の λ の相互作用に関する，より詳細な分析や提案手法の理論




図 1: 実験 2: 全結合層モデルの学習結果




図 2: 実験 2: CNN モデルの学習結果

的な収束解析も今後の重要な研究テーマである。

謝辞

本研究の一部は科研費基盤研究 (c)(課題番号:23K11267) の補助を得た。ここに謝意を表する。

文 献

- [1] F. Alvarez, H. Attouch, J. Bolte, and P. Redont, “A second-order gradient-like dissipative dynamical system with Hessian-driven damping: Application to optimization and mechanics,” *Journal de*

Mathématiques Pures et Appliquées, vol. 81, no. 8, pp. 747–779, 2002.

- [2] C. Ma, L. Wu, and W. E, “A qualitative study of the dynamic behavior for adaptive gradient algorithms,” *Proc. Machine Learning Research (MSML)*, vol. 145, pp. 1–22, 2021.
- [3] S. Mahboubi, and H. Ninomiya, “Adaptive Gradient Algorithm with Momentum based on Spatiotemporal Second-order Dynamical Model,” International Joint Conference on Neural Networks, 2024.
- [4] J. Nocedal and S. J. Wright, “Numerical Optimization,” 2nd ed., New York, NY, USA: Springer, 2006.
- [5] A. Defazio, H. Mehta, X. Yang, K. Mishchenko, A. Khaled, and A. Cutkosky, “The Road Less Scheduled,” in *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, 2024, to appear.
- [6] B. T. Polyak, “New method of stochastic approximation type,” *Automation and Remote Control*, vol. 51, no. 7, pp. 937–946, 1990.
- [7] W. Tao, M. Li, S. Zhang, and J. Yi, “Primal averaging: A new gradient evaluation step to attain the optimal individual convergence,” *IEEE Transactions on Cybernetics*, vol. 48, no. 12, pp. 3369–3379, 2018.
- [8] I. Goodfellow, Y. Bengio, and A. Courville, “Deep learning (Adaptive Computation and Machine Learning series),” Cambridge, MA, USA: MIT Press, 2016.
- [9] B. T. Polyak, “Some methods of speeding up the convergence of iteration methods,” *USSR Computational Mathematics and Mathematical Physics*, vol. 4, no. 5, pp. 1–17, 1964.
- [10] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proc. 3rd Int. Conf. Learning Representations (ICLR)*, San Diego, CA, USA, 2015.
- [11] H. Robbins and S. Monro, “A stochastic approximation method,” *Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, Sep. 1951.