

貴論文 (TY2508) について慎重に審査した結果、査読者 B は

1. 掲載      2. 照会后掲載      3. 照会后判定      4. 返却      (番号に丸印をつける)

が適当と考えます。

以下に、査読者のコメントを示しますので、これに基づいて論文を修正して下さい。また、返却となった場合にも、査読者のコメントに十分留意して書き直し、再度投稿されることを期待します。

本論文は、画像をお題とした大喜利生成という、高度な認知的推論と創造性が求められるタスクに対し、Transformer ベースのアーキテクチャ「Warai Transformer (WiT)」を提案するものです。LSTM ベースの従来手法の限界を指摘した上で、Vision Transformer (ViT) とマルチヘッドアテンションを組み合わせたモデルを構築し、さらに「ボケて」から収集したデータセットに対する適切な自動クリーニング手法を提案・実施しています。実験の結果、学習精度および人間の主観評価の両面で従来手法を上回り、大規模言語モデル (Gemini) と同等の面白さを達成したことを示しています。

ユーモアという主観的で難易度の高い生成タスクに対し、工学的なアプローチで挑んでいる点は高く評価できます。また、膨大なノイズを含む Web スクレイピングデータに対し、非現実画像、文字入り画像、固有名詞を含む文章を自動除去する仕組みを導入したことは、本タスクの精度向上に大きく寄与しており、他のマルチモーダル学習にも応用可能な有用な知見です。

さらに、Attention Map を用いて、モデルが画像内のどのオブジェクト（楽器や顔など）に着目して特定の単語を生成したかを解析しており、「ブラックボックス化」という AI の課題に対し、生成過程の可視化とその解釈に取り組んでいることも評価できます。

また、既存の大喜利モデル (NJM, GUMI-AE) だけでなく、Gemini や Watashiha Llama といった最新の LLM、さらには人間を比較対象に含めた多角的な主観評価を行っている点は、結果の信頼性を高めているといえます。

「CLS トークン」「キャプション AI」に関して補足するような説明があるとよりよいと考えます。