

Warai Transformer: Transformer を用いた画像に対する大喜利生成 AI

山富 龍¹, マハブーブ シェヘラザード¹, 二宮 洋¹

¹ 湘南工科大学大学院 工学研究科 電気情報工学専攻, 神奈川県藤沢市辻堂西海岸 1-1-25

Warai Transformer: Humorous Caption Generation from Images using Transformer-based AI

Ryo Yamatomi¹, Shahrzad Mahboubi¹ and Hiroshi Ninomiya¹

¹Graduate School of Science and Technology, Shonan Institute of Technology,

Department of Electrical and Information Engineering,

1-1-25 Tsujido Nishi-Kaigan, Fujisawa City, Kanagawa, 251-0057 Japan

E-mail: 25T2501@sit.shonan-it.ac.jp, shaa@info.shonan-it.ac.jp, ninomiya@info.shonan-it.ac.jp

Abstract In this study, we propose a novel AI model for humorous caption generation, called Warai Transformer (WiT), specifically designed for Japanese Ogiri task. Conventional approaches to Ogiri generation are typically trained on image–humor caption (Ogiri) pairs. However, they often encounter difficulties such as domain discrepancies between image feature extractors and training data for Ogiri generation, as well as limitations in language generation accuracy due to the reliance on LSTM-based encoders. To address these issues, the proposed method employs a Transformer-based feature extractor, enabling more accurate visual understanding and the generation of captions, including the intentional incongruities and twists characteristic of Ogiri. Furthermore, we propose a preprocessing pipeline that automatically filters unsuitable data, such as unreal images, images containing text, and Ogiris with specific proper nouns. Experimental evaluations demonstrate that WiT surpasses conventional models in terms of learning loss, and subjective evaluation through questionnaires indicates its superiority in generating humorous captions. These results indicate the effectiveness of Transformer-based architectures for creative text generation tasks such as Ogiri.

Keywords: Humorous Caption Generation, Transformer, Image-to-Text Generation, Multimodal Learning

1. はじめに

近年、情報通信技術の発展により、膨大かつ多様な情報が蓄積されるようになった。それに伴い、そのようなデータを有効に活用する手段として、人工知能（Artificial Intelligence, AI）が注目を集めている。AI の応用分野は広範であり、医療や工業といった実用的な領域にとどまらず、絵画や音楽などの創作分野において

も活用が進んでいる。創作分野における AI として、文章を入力としその内容に適した画像を生成する Stable Diffusion [1] や、文章を入力としその内容に適した音声生成する AudioCraft [2] などがある。こうした創作物の自動生成技術は、娯楽としての利用にとどまらず、創作活動における発想支援、広告・マーケティング分野におけるアイデア生成、教育における言語能力育成など、幅広い応用が期待されている。

AIによる創作的コンテンツの生成タスクの一つに、画像を入力とし、その内容にふさわしいユーモアを伴う短い文（大喜利キャプション）を生成する大喜利生成がある [3, 4]。このタスクは、画像の説明文を生成する従来のキャプション生成とは異なり、画像に描かれた状況を正確に理解した上で、その内容に意図的なズレや意外性を加えることによって笑いを誘うという特徴を持つ。ここで、「面白さ」という概念そのものが主観的で多様であり、人によって受け取り方が大きく異なるため、このタスクはAIに高度な認知的推論と創造的発想を要求する。このため、大喜利生成を学習するAIには、画像を正しく認識する視覚的理解能力に加えて、笑いを生み出すための発想力と、適切な言葉を選んで表現する言語生成能力が求められる。大喜利生成は人間にとっても容易ではない高次の認知的活動を要するタスクであり、AIにとっても極めて挑戦的であると言える。大喜利のようなユーモア生成タスクは人間の柔軟な発想力や言語運用能力を模倣するものであり、これを実現するAIの構築は創造性支援ツールや対話エージェントにおける自然で魅力的なインタラクションの設計など幅広い応用可能性を有している。

これまでに大喜利生成AIとして、Neural Joking Machine (NJM) [3]が提案されている。NJMは、画像とそれに対応する大喜利文章のペアから構成される画像一大喜利文章データセットを用い、画像から文章を生成するImage2Textモデル [5]を学習することで構築されたAIである。Image2Textモデルは、画像を特徴量に変換する画像の特徴抽出器と、文章を特徴量に変換する文章の特徴抽出器から構成されるモデルである。NJMは、画像に対して適切な大喜利を出力可能であることが実験により示されているが、学習データに含まれている画像と、画像の特徴抽出器が事前に学習に使用した画像との間にドメインの乖離があるため、十分な精度が得られないという問題がある。

この問題を解消した大喜利生成AIとして、Generative Model of Suitable Meme Sentences for Images Using Autoencoder (GUMI-AE) [4]が提案されている。GUMI-AEでは、画像の特徴抽出器として画像一大喜利データセットに適したAutoencoder [6]を用いることで、NJMにおけるドメインの乖離を改善している。また、GUMI-AEは、NJMと比較して高い精度で学習可能であることが実験により示されている [4]。

従来の大喜利生成AIであるNJMおよびGUMI-AEはいずれも、文章の特徴抽出器として再帰型ニューラルネットワーク (Recurrent Neural Network, RNN) [7]の一種であるLong Short-Term Memory (LSTM) [7]

を用いている。RNNは、自身の出力を再帰的に入力する構造により時系列データの処理に適した構造を持ち、時系列データの一種である文章を扱うために使用されている。しかし、RNNはその構造に起因し勾配消失問題が生じ、十分な精度で学習できない場合がある。このような問題から、NJMおよびGUMI-AEにおいてLSTMを文章の特徴抽出器として用いることは、学習の精度を制限する一因となっていると考えられる。

本研究では、NJMおよびGUMI-AEの課題を解決するため、特徴抽出器としてTransformer [8]を用いた大喜利生成AIであるWarai Transformer (WiT)を提案する。RNNが時系列データを逐次的に処理するのに対し、Transformerは並列処理を行う構造を持ち、これによりRNNを用いるモデルに比べて高い精度で学習可能である。WiTは、Transformerを特徴抽出器として用いることで、NJMやGUMI-AEと比べ高精度に大喜利生成タスクを学習できることが期待できる。また、Transformerは推論時に入力の各要素間の関連性を示すAttention Mapを出力する。WiTはTransformerを用いることでAttention MapからAIの生成過程を解析可能であり、従来の大喜利生成AIの生成過程がブラックボックスである問題の解消も期待できる。

さらに、NJMおよびGUMI-AEの学習に用いられた画像一大喜利文章データセットには、大喜利生成に適さない画像や文章が含まれている問題が存在する。本研究では、これらの不適切なデータをプログラムにより自動的に除去し、大喜利生成AIの学習に適したデータセットを構築する手法についても提案する。

本論文の構成は以下の通りである。2章では、従来の大喜利生成AIである、NJMとGUMI-AEについて述べる。3章では、提案手法を構成する基盤技術である、Image2TextモデルとTransformerについて述べる。4章では、提案手法の大喜利生成AIであるWiTと、大喜利生成AIの学習に不適切な画像と文章を自動的にフィルタリングする手法について述べる。5章では実験として、提案手法による大喜利生成AIの学習に不適切な画像のフィルタリングの精度を検証する。また、提案手法であるWiTと、従来手法であるNJM, GUMI-AEを同じデータセットを用いて学習しその結果を比較する。さらに、WiT, NJM, GUMI-AE, 大規模言語モデルであるGemini [9], 事前に大喜利文章を学習した大規模言語モデルであるWatashiha Llama [10]が生成した大喜利の定性的な評価と、面白さを評価するアンケートを実施する。

2. 関連研究

本章では本研究の従来研究である Neural Joking Machine (NJM) [3] と Generative Model of Suitable Meme Sentences for Images using Autoencoder (GUMI-AE) [4] について説明する。

2.1 Neural Joking Machine (NJM)[3]

[3] は、画像と対応する大喜利からなるデータセットの構築手法と、そのデータを用いた大喜利生成 AI である NJM を提案している。


この研究では、大喜利投稿サイト「ボケて」[11] に着目し、画像とその画像に対応する大喜利をスクレイピングにより収集し、画像—大喜利ペアのデータセットを構築している。ボケてではお題となる画像に対してユーザが面白文章（大喜利）を投稿する SNS であり、2025 年 8 月時点で約 780 万枚のお題画像と約 1.1 億件の大喜利が投稿されている。

このデータセットの一部を用いて画像を入力とし文章を生成する Image2Text モデル [5] に学習させることで NJM を実現している。Image2Text モデルは画像の特徴抽出器と文章の特徴抽出器から構成され、NJM は画像の特徴抽出器として ResNet 152[12]、文章の特徴抽出器として LSTM[7] を使用している。ResNet 152 は ImageNet[13] で事前学習されており、NJM ではそのパラメータを固定した転移学習の手法を採用している。[3] が実施した NJM が生成した大喜利の面白さを評価するアンケートでは、NJM がキャプション AI と比べ面白い文章を生成する頻度が高い、人間と比べると面白い文章を生成する頻度が低いという結果が得られた。これは画像—大喜利ペアのデータセットを学習することで AI により大喜利生成が可能であることを示唆している。

しかし、ボケてでは図 1(a) に示すようなアニメーションの 1 カットやイラスト、図 1(b) に示すような画像中に文章で大喜利のお題が書かれた画像などの非現実画像が頻繁に使用されている。ImageNet で事前学習した ResNet 152 はこれらの非現実画像との間にドメイン乖離が生じており、十分な特徴抽出が困難である。ドメイン乖離の問題から、NJM は十分な精度で大喜利生成を学習できていない可能性がある。このように、現実画像で事前学習されたモデルは非現実画像を含むデータへの対応に限界があり、大喜利生成 AI の性能向上には非現実画像への対応が重要な課題となる。



(a) アニメーションの 1 カットのお題画像



(b) 文字を含むお題画像

図 1: お題画像として使用される非現実画像

2.2 Generative Model of Suitable Meme Sentences for Images using Autoencoder (GUMI-AE)[4]

我々はこれまでに、NJM のドメイン乖離問題を解消するため、画像の特徴抽出器を変更した大喜利生成 AI である GUMI-AE を提案している [4]。GUMI-AE では、画像の特徴抽出器としてボケての画像を用いて事前学習した Autoencoder (AE) [6] のエンコーダを使用している。AE は入力の復元を目的として学習されるニューラルネットワークであり、学習済みのエンコーダは入力を表す特徴量を出力する。GUMI-AE はボケての画像を用いて事前に学習した Autoencoder のエンコーダを用いることで、ボケての非現実画像に適した特徴抽出が可能となる。[4] が実施した実験では、NJM と GUMI-AE を同じデータセットを用いて学習した場合に GUMI-AE が NJM と比べ低い学習損失が得られている。また、[4] が実施した GUMI-AE が生成した大喜利の面白さを評価するアンケートでは、GUMI-AE が NJM と比べ面白い文章を生成する頻度が高いという結果が得られた。これは、ボケてのドメインに適応した画像の特徴抽出器を用いることで学習の精度が改善されることを示唆している。

GUMI-AE は、文章の生成には、NJM と同様に LSTM を用いている。LSTM は RNN[7] の一種であり、時系列順に線形変換と非線形変換を繰り返す構造を持つため時系列データの学習を可能としているが、勾配消失問題や長文に対する学習精度の低下が知られている。

3. 基盤技術

本章では、提案手法の基盤技術である Image2Text モデル [5] と Transformer [8] について説明する。

3.1 Image2Text モデル [5]

Image2Text モデルは、画像を入力とし、それに対応する文章を生成するニューラルネットワークモデルである。Image2Text モデルの学習には、画像とそれに対応する文章のペアからなるデータセットを用いる。文章は単語ごとに分割（分かち書き）し、データセットの全文を分かち書きして得られた全ての単語群（語彙）に一意の ID を付与する。その後、分かち書きされた文章の各単語をその単語の ID に置き換えることで文章を数値として扱う。さらに、数値化した文章の先頭には文章の始まりを表す Begin of Sentence トークン（BoS トークン）の ID を、末尾には文章の終わりを表す End of Sentence トークン（EoS トークン）の ID を追加する。Image2Text モデルの学習に用いるデータセットを $\{(\mathbf{I}_s, w_{s,1}, w_{s,2}, \dots, w_{s,C_s})\}_{s=1}^S$ とする。ここで、 S はデータ数、 $\mathbf{I}_s$ は s 番目の画像、 $w_{s,c}$ は s 番目の画像に対応する文章を分かち書きして得られた c 番目の単語の ID、 C_s は s 番目の画像に対応する文章を分かち書きした際の単語の数である。特に、 $w_{s,1}$ は BoS トークンの ID、 w_{s,C_s} は EoS トークンの ID である。Image2Text モデルは、画像 $\mathbf{I}_s$ とそれに対応する文章の途中までの文を入力とし、全語彙に対し入力された途中文に続くべきか否かを表す推奨度を確率分布として出力する。このモデルは入力した途中文、すなわち $w_{s,1}, w_{s,2}, \dots, w_{s,c-1}$ に続く単語 $w_{s,c}$ に対する推奨度の確率が最大となるように学習する。Image2Text モデルが最小化する誤差関数を (1) に示す。

$$-\sum_{s=1}^S \sum_{c=2}^{C_s} \log F(\mathbf{I}_s, w_{s,1}, \dots, w_{s,c-1})_{w_{s,c}} \quad (1)$$

ここで、 $F(\cdot)_{w_{s,c}} \in [0, 1]$ は、Image2Text モデルが単語 $w_{s,c}$ に対して出力する推奨度を表す。

学習済みの Image2Text モデルが、ある画像 $\mathbf{I}$ に対して文章を生成する過程は次の通りである。まず、BoS トークンの ID を w_1 とし、 $\mathbf{I}$ と w_1 をモデルに入力する。モデルは BoS トークンに続く単語の推奨度を確率分布として出力する。この確率分布に基づき単語を選択し、これを 2 番目の単語 w_2 とする。次に、 $\mathbf{I}$ と w_1, w_2 を入力し、モデルの出力する確率分布に基づき単語を選択し 3 番目の単語 w_3 とする。この処理を繰り返し、EoS トークンが出力されるまで単語を途中文の末尾に追加することで完全文が生成される。確率分布から単語を選択する方法として、最も高い確率を示す単語を選択する貪欲法や、確率分布に基づきランダムに選択する

ルーレット選択がある。

3.2 Transformer [8]

Transformer は、時系列データのような複数の要素から構成されるデータを扱うためのニューラルネットワークである。従来、このようなデータには RNN [7] が用いられていたが、その構造のため勾配消失問題や長期依存性の学習困難といった課題があった。Transformer は、Self Attention 機構により、入力内の全ての要素間の関係性を並列に処理できる。これにより、RNN と比較して長期依存関係の把握や学習効率の面で優れた性能を示す。Transformer を構成する要素として Self Attention, Cross Attention, Multi Head Attention, Transformer を画像分類に応用したモデルとして Vision Transformer がある。以降の節ではこれらについて説明する。

3.2.1 Self Attention

Self Attention は、入力を構成する全ての要素間の関連性を並列に計算する仕組みである。その Self Attention を (2)–(4) に示す。

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V \quad (2)$$

$$\mathbf{A} = \text{softmax}\left(\frac{1}{\sqrt{d}}\mathbf{Q}\mathbf{K}^T\right) \quad (3)$$

$$\mathbf{Z} = \mathbf{A}\mathbf{V} \quad (4)$$

ここで、 $\mathbf{x}_i \in \mathbb{R}^{1 \times D}$ を入力の i 番目の要素、 D を入力の次元数、 L を入力の要素数とすることで、 $\mathbf{X} = [\mathbf{x}_1^T \mathbf{x}_2^T \dots \mathbf{x}_L^T]^T \in \mathbb{R}^{L \times D}$ は全入力から構成される行列を示す。また、 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{D \times d}$ は Self Attention が学習するパラメータ、 d は出力の次元数である。さらに、 $\text{softmax}(\mathbf{x})_i = e^{x_i} / \sum_{x \in \mathbf{x}} e^x$ は、ベクトルを確率分布に変換する関数であり、行列に対しては各行ごとに適用される。 $\mathbf{A} \in \mathbb{R}^{L \times L}$ は Attention Map と呼ばれ、その要素 $a_{i,j} \in [0, 1]$ は、入力の i 番目の要素が j 番目の要素にどれだけ重要視するかを表す。出力 $\mathbf{Z}$ は、Attention Map $\mathbf{A}$ に基づき、入力を線形変換した $\mathbf{V}$ から情報を重み付けした総和であり、これは入力の各要素が他の全ての要素に対してどれだけ重要視するかに応じて情報を集約していると言える。Self Attention では、入力の要素同士の重要度を決定するパラメータ $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ は学習によって最適化される。

なお、Self Attention は入力の全ての要素の関係性を並列に考慮する一方で、時系列データにおける要素の順序を考慮していない。この問題を解決するため、

Self Attention では Position Encoding が併用される。Position Encoding は、入力に含まれる要素の順序情報を明示的に付与する手法である。データの内容に依存しない固定の位置を表すベクトルを順序に応じて各要素に加算することで、モデルが要素の位置を識別可能としている。この位置を表すベクトルには、正弦関数や余弦関数を用いた静的なベクトルのほか、学習可能なパラメータとして与える方法もある。

3.2.2 Cross Attention

Self Attention は1つのモジュール内で使用される構造であるのに対し、Cross Attention は2つのモジュールを扱うモデルで用いられる構造である。Cross Attention は、画像に対するキャプション生成や質問に対する応答文生成といった、エンコーダ-デコーダモデルにおいて用いられる。Cross Attention を (5)-(7) に示す。

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_{\mathbf{Q}}, \quad \mathbf{K} = \mathbf{Y}\mathbf{W}_{\mathbf{K}}, \quad \mathbf{V} = \mathbf{Y}\mathbf{W}_{\mathbf{V}} \quad (5)$$

$$\mathbf{A} = \text{softmax} \left(\frac{1}{\sqrt{d}} \mathbf{Q}\mathbf{K}^T \right) \quad (6)$$

$$\mathbf{Z} = \mathbf{X} + \mathbf{A}\mathbf{V} \quad (7)$$

ここで、 $\mathbf{x}_i \in \mathbb{R}^{1 \times D}$ をデコーダの入力の i 番目の要素、 L をデコーダの入力の要素数とすることで、 $\mathbf{X} = [\mathbf{x}_1^T \ \mathbf{x}_2^T \ \dots \ \mathbf{x}_L^T]^T \in \mathbb{R}^{L \times D}$ はデコーダの全入力から構成される行列を、 $\mathbf{y}_i \in \mathbb{R}^{1 \times D}$ をエンコーダの入力の i 番目の要素、 M をエンコーダの入力の要素数とすることで、 $\mathbf{Y} = [\mathbf{y}_1^T \ \mathbf{y}_2^T \ \dots \ \mathbf{y}_M^T]^T \in \mathbb{R}^{M \times D}$ はエンコーダの全入力から構成される行列を示す、また、 $\mathbf{W}_{\mathbf{Q}}, \mathbf{W}_{\mathbf{K}}, \mathbf{W}_{\mathbf{V}} \in \mathbb{R}^{D \times d}$ は Self Attention が学習するパラメータである。 $\mathbf{A} \in \mathbb{R}^{L \times M}$ は Attention Map であり、その要素 $a_{i,j} \in [0, 1]$ は、デコーダの入力の i 番目の要素が、エンコーダの入力の j 番目の要素をどれだけ重要とみなすかを表す。 $\mathbf{A}\mathbf{V}$ の各行は、デコーダの各要素にとってエンコーダの各要素を重要度で重み付けた和となっており、これを $\mathbf{X}$ と加算することで、デコーダ側の情報を保持しつつ、エンコーダの情報を統合した特徴表現を得ることができる。

3.2.3 Multi Head Attention

Multi Head Attention は、複数の Self Attention または Cross Attention を並列に処理する構造である。複数の Self Attention を並列に用いた Multi Head Self Attention を (8) と (9) に示す。

$$\mathbf{Z} = [\mathbf{SA}_1(\mathbf{X}), \mathbf{SA}_2(\mathbf{X}), \dots, \mathbf{SA}_H(\mathbf{X})] \quad (8)$$

$$\hat{\mathbf{Z}} = \mathbf{Z}\mathbf{W}_{\mathbf{Z}} \quad (9)$$

ここで、 $\mathbf{SA}_i(\cdot)$ は i 番目の Self Attention の出力、 H は並列にする Self Attention の数（ヘッド数）、 $[\mathbf{SA}_1(\mathbf{X}), \mathbf{SA}_2(\mathbf{X}), \dots, \mathbf{SA}_H(\mathbf{X})] \in \mathbb{R}^{L \times dH}$ はそれぞれの Self Attention の出力を列方向に結合した行列、 $\mathbf{W}_{\mathbf{Z}} \in \mathbb{R}^{dH \times d}$ は線形変換のパラメータである。各 Self Attention は異なるパラメータによって異なる特徴を抽出し、その出力は列方向に結合された後、線形変換によって次層の入力次元に変換される。この処理により、多様な視点から得られた特徴を統合した表現が得られる。Multi Head Cross Attention も同様に、複数の Cross Attention の出力を列方向に結合し、線形変換によって1つの特徴表現に集約する。

3.2.4 Vision Transformer[14]

Vision Transformer (ViT)[14] は、Transformer を画像分類に応用したモデルである。ViT では、入力画像を小領域（パッチ）に分割し、各パッチを一次元ベクトル化し線形変換することで、画像全体を各パッチ列からなる行列として表現する。この行列の先頭には、CLS トークンが付加される。CLS トークンを含む行列は Self Attention に入力され、特徴抽出が行われる。最終的に、Self Attention が出力した行列のうち CLS トークンに対応する行が出力層に入力され、出力層は画像のカテゴリを予測する。CLS トークンは、学習初期は乱数のベクトルであり、Self Attention のパラメータと同様に学習によって最適化される。画像を ViT に入力する際、CLS トークンは初期値として画像の内容に関わらず同じ値を持つ。Self Attention により全てのパッチの情報が CLS トークンに集約されるため、出力層は CLS トークンを用いて画像のカテゴリを予測可能になる。

4. 提案手法

4.1 Warai Transformer (WiT)

本研究では、Transformer [8] を用いた大喜利生成 AI である Warai Transformer を提案する。従来大喜利生成 AI である NJM [3] や GUMI-AE [4] では、文章の特徴抽出に LSTM [7] が用いられていた。しかし、LSTM のような再帰型ニューラルネットワークは時系列データを逐次的に処理するため、長期の依存関係の学習が困難であるという問題がある。提案手法では、こ




図 2: Warai Transformer (WiT) の構造

の問題を解決するために Transformer を採用し、時系列データを並列に処理可能とすることで、LSTM の構造的な問題を解消している。さらに、Transformer は Attention Map を通じて各トークン間の関係性を明示的に捉えることができるため、大喜利生成 AI の生成過程を分析することが可能となる。これにより、モデルがどのような文脈の手がかりをもとにユーモアを形成しているのかを解析でき、大喜利生成における発想のメカニズムを構造的に理解する手がかりが得られることが期待できる。

提案手法である WiT の構造を図 2 に示す。WiT は、Vision Transformer (ViT) [14]、Self Attention Block、Cross Attention Block、全結合層 [7] から構成される。ViT には、ImageNet [13] で事前学習されたモデルを用い、出力層に最も近い中間層の特徴量のうち、CLS トークンを除いた各パッチに対応するベクトルのみを使用する。Self Attention Block は、Self Attention 層、Layer Normalization 層 [15]、全結合層、残差接続 [12] から構成される。Cross Attention Block は、Cross Attention 層、Layer Normalization 層、全結合層、残差接続から構成される。Attention Block は Self Attention Block と Cross Attention Block から構成され、これを任意の回数 N 回繰り返す。入力された途中文は単語単位に分かち書きされ、各単語は一意的学習可能なベクトルに変換される。各単語を表すベクトルには、順序の情報を付

与するための Position Encoding (PE) ベクトルが加算される。提案手法では、この PE ベクトルも学習可能なパラメータとする。画像は ViT に入力され、パッチごとの特徴ベクトルに変換される。その後、各パッチの特徴ベクトルは全結合層に入力され、次元数が単語ベクトルと一致するように調整される。Self Attention Block には途中文を入力し、その出力と画像特徴ベクトルを Cross Attention Block に入力する。出力層は、全語彙に対して、入力された途中文の直後に続く単語の確率分布を出力する。WiT の主なハイパーパラメータは、単語ベクトルおよびパッチベクトルの次元数、Attention Block の繰り返し回数 N 、Multi Head Self Attention と Multi Head Cross Attention のヘッド数 H 、および ViT のファインチューニングの有無である。ファインチューニングとは目的のタスクを学習する際に、事前に学習されたパラメータを初期値として再学習を行う手法である。これにより、事前学習で得られたパラメータと比べ、目的のタスクに適したパラメータが得られることが期待できる。しかし、ファインチューニングは学習時のパラメータ数が増加するため、コンピュータの要求スペックが向上する、学習時間が増加する問題がある。

4.2 大喜利生成 AI のためのデータセット構築

本研究では、従来の大喜利生成 AI の学習に用いられてきた画像—大喜利データセットに含まれる不適切なデータを除去するための機械的なフィルタリング手法を提案する。このデータセットは、大喜利投稿サイトボケて [11] に投稿されたお題画像と、それに対応するユーザー投稿の大喜利をスクレイピングによって収集することで構築される。しかし、このように機械的に収集されたデータには、画像に対する大喜利生成という本研究の目的に適さないものが多数含まれている。それらを目視で除去するには膨大な労力を要するため、不適切なデータを自動的に除外する機械的なフィルタリングが不可欠である。

● 非現実画像の除去

ボケてでは、図 1(a) に示すようなアニメーションの 1 フレームや漫画の一部、イラストといったキャラクターが描画された非現実画像がお題画像として使用されている。これらに対する大喜利は、画像中のキャラクターに関する背景知識を前提とすることが多く、視覚情報のみに基づく大喜利生成の学習には適していない。そこで本研究では、画像が現実画像か否かを判定する画像分類 AI を構築し、非現実画像と判断された画像および対応する大喜利ペアをデータセットから除去する。この分類器の学習には、正例として ImageNet Mini [16] の現実画像、負例として Tagged Anime Illustrations データセット [17] の非現実画像を用いる。分類器として、ImageNet[13] で事前学習済みの ResNet152[12] を使用する。この際、事前学習済みの ResNet152 の出力層を取り除き、新たに活性化関数が Sigmoid 関数の全結合層を出力層として追加する。

学習済みの分類器は入力された画像に対し、分類スコアを出力する。分類スコアは、1 に近いほど分類器が現実画像であると判断したこと、また、0 に近いほど分類器が非現実画像であると判断したことを表す。分類器が出力した分類スコアに対してしきい値を定め、入力された画像が現実画像か非現実画像であるかハードに分類する。具体的には、ボケてから収集したお題画像を入力し、分類スコアが所定のしきい値を上回った場合、その画像を現実画像と分類する。また、分類スコアが所定のしきい値を下回った場合、その画像は非現実画像と分類し、その画像と画像に対応する大喜利をデータセットから除去する。しきい値は、大きな値に設定することで非現実画像を現実画像と誤分類する偽陽性率が低くなるが、これと同時に現実画像を非現

実画像と誤分類する偽陰性率が高くなるトレードオフの関係がある。

● 文字を含む画像の除去

ボケてでは、図 1(b) に示すような文字でお題が記述されている画像がお題画像として使用されている。これらに対する大喜利は、画像中に記述された文章の内容に依存しており、視覚情報のみに基づく大喜利生成の学習には適していない。そこで本研究では、光学文字認識により画像中の文字の有無を判定し、文字が検出された画像と画像に対応する大喜利をデータセットから除去する。光学文字認識には Google Cloud Vision API [18] を用いる。

● 固有名詞を含む大喜利の除去

ボケてでは、人物名や地名などの固有名詞が含まれている大喜利が投稿されている。このような大喜利は、その固有名詞の背景知識を前提としており、視覚情報のみに基づく大喜利生成の学習には適していない。そこで本研究では、大喜利中の各単語に対して固有名詞かどうかを判定し、固有名詞を含む大喜利をデータセットから除去する。固有名詞の判定には、形態素解析器 MeCab [19] を用いる。MeCab は、人手で整備された辞書に基づき文章を分かち書き、および、品詞を推定する辞書ベースの形態素解析器である。

5. 実験

本章では、提案手法の有効性を検証するために 4 つの実験を実施する。実験 1 では、現実画像、非現実画像、文字を含む画像に対し提案手法のフィルタリングを施し、その結果を分析する。実験 2 では、WiT を提案手法によってフィルタリングした画像—大喜利データセットを用いて学習し、WiT が生成した大喜利について分析する。実験 3 では、実験 2 で学習した WiT と、従来の大喜利生成 AI である NJM, GUMI-AE を同じデータセットを用いて学習し、その結果を比較する。実験 4 では、実験 2, 実験 3 で学習した WiT, NJM, GUMI-AE と大規模言語モデルである Gemini [9], 事前に大喜利文章を学習した大規模言語モデルである Watashiha Llama [10] が生成した大喜利の面白さを評価するアンケートを実施する。

5.1 実験 1: 提案手法のフィルタリング性能

本実験では、現実画像、非現実画像、文字を含む画像に対し提案手法のフィルタリングを施し、分類精度、

適合率, 再現率, F1 Score により評価する. 現実画像として, ImageNet Mini [16] の検証用画像を用いる. 非現実画像として, Tagged Anime Illustrations データセット [17] のうち, 画像が現実画像か否かを判定する画像分類 AI の学習に用いていない画像を用いる. 文字を含む画像は, ボケてから文字でお題が記述されている画像を取得し, これらから文字を取り除いた後, ケータイ大喜利データセット [20] のお題文章をプログラムによって描画することで作成する. 現実画像, 非現実画像がそれぞれ 3,923 枚, そして, 文字を含む画像が 954 枚である. 画像が現実画像か否かを判定する画像分類 AI は, 0 から 1 の範囲で入力された画像が現実画像であるかのスコアを出力する. この際, 人手によりしきい値を定め, しきい値を超えた画像を現実画像, それ以外の画像を非現実画像とする. また, 光学文字認識により文字を画像中に含むと判断された画像は非現実画像とする.

各閾値における分類結果を表 1 に示す. 表 1 から, しきい値が 0 の場合に, 文字を含む画像を 100% の精度で除去できていることがわかる. このことから, 十分な精度を持つ光学文字認識器を用いることで, 文字を含む画像をデータセットから取り除くことが可能であると言える. ただし, しきい値が 0 の場合の現実画像の分類精度に着目すると, 34% の現実画像が光学文字認識によって取り除かれていることがわかる. 図 3 に, 光学文字認識により文字を含むと判断された現実画像を示す. 取り除かれた現実画像として, 図 3(a) に示すような看板に文字が描画されている画像と, 図 3(b) に示すようなコピーライトなどの文字が描画されている画像があった. ここで, 画像内に含まれるコピーライト表記に係る著作権を考慮し, 図 3(b) は著者が作成した模擬例であり, ImageNet には含まれていない. 図 3(b) のようにコピーライトなどが描画されている画像はボケてではお題画像として使用されていないため, 大喜利生成 AI の学習に用いるデータをフィルタリングする際は現実画像の分類精度が向上することが考えられる. 次に, しきい値を向上させることで, 非現実画像を分類する精度が向上していることがわかる. このことから, 画像が現実画像か否かを判定する画像分類は現実画像に対し高いスコアを出力するよう, 適切に学習できていると言える. しきい値を 0.998 とした際に, 非現実画像は完全に取り除かれたが, 現実画像の 64% も同様に取り除かれる結果となった. このことから, 大喜利生成 AI の学習に用いるデータを十分に確保するためには適切なしきい値を定める必要がある.

表 1: 実験 1 の各閾値における分類結果

しきい値	0.0	0.75	0.998
現実画像の分類精度	65.23%	63.93%	45.65%
非現実画像の分類精度	43.58%	99.51%	100%
文字を含む画像の分類精度	100%	100%	100%
適合率	0.5362	0.9924	1.0
再現率	0.6523	0.6393	0.4565
F1 Score	0.5886	0.7776	0.6268




図 3: 光学文字認識で文字を含むと判定された画像

表 2: フィルタリングの条件によるデータの数

フィルタリングの条件	画像	大喜利
フィルタリング無し	586,745 枚	7,768,180 件
文字を含む画像のフィルタリング	284,776 枚	3,282,120 件
固有名詞を含む大喜利のフィルタリング	550,945 枚	4,222,632 件
しきい値: 0.0	268,538 枚	1,735,354 件
しきい値: 0.75	220,138 枚	1,378,064 件
しきい値: 0.998	22,389 枚	93,232 件

5.2 実験 2: WiT の実装

本実験では, 提案手法である WiT について, いくつかのハイパーパラメータを変更しそれらが性能に与える影響を検証する. WiT の学習には, 提案手法に基づくフィルタリングと, 以下の条件による前処理を施したデータセットを用いる. 全ての大喜利をサブワードに分割し, 単語数が 4 未満または 32 以上の大喜利を除去する. さらに, 数字やローマ字を含む文, およびデータセット全体で 16 回未満しか出現しない単語を含む大喜利を除去する. 表 2 に, 提案手法のフィルタリ

ングの条件を変更した際の、それぞれの条件における画像の枚数と大喜利の件数を示す。ここで、フィルタリング無しは、提案手法のフィルタリングを施していないボケてから収集したデータの数である。また、文字を含む画像のフィルタリングと固有名詞を含む大喜利のフィルタリングは、フィルタリング無しのデータにそれぞれのフィルタリングのみを施した際のデータ数である。さらに、それぞれのしきい値は、フィルタリング無しのデータに文字を含む画像のフィルタリングと固有名詞を含む大喜利のフィルタリングを施した上で、それぞれのしきい値により非現実画像をフィルタリングした際のデータ数である。フィルタリングを施していない場合のデータ数と比べ、文字を含む画像をフィルタリングを施した結果、おおよそ半数のデータが取り除かれていることがわかる。これは、収集された画像の半数が、セリフを含む漫画の1コマや文字で大喜利のお題が書かれた画像などの、画像内の文字情報に依存したお題画像であることを示唆している。また、固有名詞を含む大喜利のフィルタリングにおいても大喜利の件数が大きく減少していることから、特定のキャラクターや人物などの背景知識を前提とした大喜利が多数存在することが確認できる。さらに、非現実画像の判定しきい値によるデータ数の推移に着目すると、しきい値を0.998に設定した場合、画像数はおおよそ2万枚まで大きく減少し、大喜利生成AIの学習に必要なデータ量を確保できなくなる懸念がある。一方で、しきい値0.75ではおおよそ22万枚の画像が確保されており、不適切な画像を排除してデータの質を高めつつ、学習に十分な規模を維持できていると言える。このことから、データの質と量のトレードオフを考慮し、本実験ではしきい値0.75として非現実画像をフィルタリングしたデータセットを用いる。これらの前処理の結果、最終的なデータセットは、画像220,138枚とそれに対応する大喜利1,378,064件から構成される。このうち99%の画像とそれに対応する大喜利を学習に用い、残りの1%を後述する生成した大喜利の面白さを評価するアンケートで使用する。

本実験ではWiTの特徴量の次元数を1,024, Multi Head Attentionのヘッド数 H を8に固定する。Attention Blockの繰り返し回数 N は、1または5に設定し、ViTのファインチューニング(Fine Tuning, FC)を行う条件と行わない条件を組み合わせで比較する。各モデルのパラメータ数を表3に示す。最適化手法にはAdamW[21]を用い、学習率は $\eta = 0.0001$, その他のハイパーパラメータは[21]の推奨値とした。また、ミニバッチサイズは32, 学習反復回数を50エポックとした。これ

らのハイパーパラメータは、実験に基づき決定した。




図 4: 実験 2 の学習結果

表 3: 各モデルのパラメータ数


モデル	学習時の パラメータ	推論時の パラメータ
WiT (Layer:5, FC)	185,803,219	185,803,219
WiT (Layer:5)	99,413,971	185,803,219
WiT (Layer:1, FC)	135,389,651	135,389,651
WiT (Layer:1)	49,000,403	135,389,651
GUMI-AE	60,751,827	128,432,403
NJM	46,071,763	104,215,571

学習結果を図4に示す。図4の縦軸は学習損失、横軸は学習反復回数、赤線は $N = 5$ でViTをファインチューニングしたモデル、緑線は $N = 1$ でViTをファインチューニングしたモデル、青線は $N = 5$ でViTをファインチューニングしていないモデル、水色線は $N = 1$ でViTをファインチューニングしていないモデルである。図4から、青線と水色線を比較すると、Attention Blockの層数を増加させることで学習損失が低下していることが確認できる。これは、層数の増加によりパラメータ数が増加し、モデルの表現力が向上することで多様なパターンに対応できるようになったと考えられる。次に、赤線と青線を比較すると、ViT

をファインチューニングすることでファインチューニングしない場合と比べ学習損失が低下していることが確認できる。この損失の低下もパラメータ数の増加によるものであると考えられる。さらに、青線と緑線を比較すると、ViTをファインチューニングするよりも、Attention Blockの層数を4層増加させる方が、学習損失の低下により大きく寄与していることが確認できる。表3から、Attention Blockの層数を4層増加する場合と比べViTをファインチューニングする場合の方が学習時のパラメータ数が増加するため、Attention Blockの層数を増加させることは、相対的に効率的な性能向上手段であると言える。ただし、モデルのパラメータ数を単純に増加させた場合に、必ずしも性能向上につながるとは限らず、過学習の問題を引き起こす場合があることに注意が必要である。

Attention Blockの層数 $N = 5$ で ViT をファインチューニングした WiT によって生成された大喜利を表4に示す。ここで、各画像は WiT へ入力するお題画像、各画像の下の記事が WiT が生成した大喜利である。この表で使用した画像は学習に使用していない未知の画像であり、WiT はそれらを入力として大喜利を生成している。文章の生成には、大喜利生成 AI が出力した確率分布から単語を選択する手法として、 $K = 5$ の Top-K サンプリング [22] を用いた。Top-K サンプリングとは、AI が出力した確率分布から確率が上位 K の単語のみを抽出し、選ばれた K 個の単語の中からルーレット選択する。Top-K サンプリングでは、推奨度が高い単語から選択するため文法が適切な文章が生成されやすく、ルーレット選択によって多様性のある文章が生成可能である。表4から、WiT は画像に含まれる物体や構造を適切に捉えるだけでなく、それを基に文脈的な解釈やズレを導入することで、大喜利特有のユーモアを含む文章を生成していることがわかる。表4(c)のスーツ姿の男性が土下座する画像に対して生成された「サラリーマンの一夜干し」という大喜利は、土下座という姿勢が喚起する無力感や屈辱感と、「干される」という比喩的表現を重ねることで、ブラックユーモアを生み出している。干物のように動けなくなった魚と、職場で立場を失った社員という構図の重なりは、単なる物体認識では捉えきれない概念的類似の抽出によるものであると考えられる。また、表4(i)のナースに無理やり食事を与えられている男性の画像に対する「おれ、糖尿なんだわ」という大喜利は、状況の理不尽さに対する冷静なツッコミとして機能しており、コント的な文脈を想起させる。表4(j)のウクレレを持った犬の画像に対して出力された「弾き語り」という大喜利は、ウ

表 4: WiT が生成した大喜利

(a)  歯の隙間に挟まったモノが取れない	(b)  ちょっと踊ってくる
(c)  サラリーマンの一夜干し	(d)  バントのサイン。
(e)  新しく買った衣装が斬新	(f)  自暴自棄。
(g)  あーんパーンチ	(h)  エア・輪ゴム鉄砲
(i)  おれ、糖尿なんだわ	(j)  弾き語り

クレレを持った犬のぬいぐるみの前足が楽器を構える人間のように配置されている点に着目しており、擬人化の技法が用いられている。このような視覚構図の解釈と自然言語表現の対応付けから、WiT が画像と言語




図 5: WiT の生成過程の Attention Map

を統合的に理解していると考えられる。以上の結果から、WiT は単に画像のキャプションを生成するのではなく、視覚情報に対して意図的に誤解や意外な文脈を適用することで、大喜利に特有のズレや意外性を再現していると言える。

図 5 に WiT の生成過程の Attention Map を示す。各列の画像はそれぞれのトークンに対応する Attention Map であり、各パッチを塗りつぶす赤色が濃いほど重要度が高いことを示す。大喜利生成 AI は BoS トークンに続くトークンを逐次的に生成しており、生成されたトークンに対応する Attention Map を左から右の順に配置している。図 5(a) と図 5(b) は、2 枚の類似した状況の画像が「弾き語り」という大喜利を生成した際に、各トークンが画像のそれぞれのパッチに対しどれだけ重要であると判断しているかを可視化した Attention Map である。図 5(a) はウクレレを持った犬のぬいぐるみ、図 5(b) は赤いギターを持った人物の例である。2 枚の画像において、「弾」という意味的に楽器と関係のある語の入力に対し、ウクレレやギターのような楽器の付近への重要度が高くなっていることが確認できる。また、「語」という意味的に口と関係のある語の入力に

対し、奏者の顔や口の付近への重要度が高くなっていることが確認できる。これらのことから WiT は、「弾き語り」という言葉の意味を理解していること、単語と画像中のオブジェクトを対応づけた学習ができていることがわかる。図 5(c) は、大きく口を開けてサムズアップする男性の画像に対し、「あーんパーンチ」という大喜利を生成した際の Attention Map であり、各トークンが画像の各パッチに対してどの程度重要であると判断しているかを示している。図 5(c) より、WiT は「あーん」の生成時において、口の部分に高い重要度を割り当てていることが確認できる。これは、口を大きく開けた視覚的特徴に基づいて当該語を生成していることを示唆しており、生成過程が画像中の対応する視覚的要素と一致していることを示す結果である。一方で、人間の解釈においては、拳の存在が「パーンチ」という語の選択に寄与すると考えられる。これに対して、「パーンチ」の生成時における Attention Map では、拳領域に対する顕著な重要度の集中は観察されない。これは、WiT が拳の視覚的特徴に直接依存して「パーンチ」を生成したのではなく、口の形状に基づいて生成された「あーん」という語を起点とし、視覚情報ではなく言語




図 6: 実験 3 の学習結果

的な連想に基づいて後続く語を生成した可能性を示唆している。以上の結果は、WiT が視覚情報に基づく直接的な対応関係のみに依存するのではなく、生成済みの語を起点とした言語的な連想を通じて大喜利を生成していることを示すものであり、人間の発想の過程とは異なる非自明な生成の一例であると言える。このように、WiT の生成過程の Attention Map を解析することで、モデルが適切な視覚的領域に着目しているかを確認でき、生成された大喜利が妥当な理解に基づいているかを評価できる。さらに、生成過程の解析を応用することで、人間がどのようなメカニズムでユーモアを生み出しているのかという原理を理解するための知識発見にもつながると考えられる。

5.3 実験 3: WiT と従来の大喜利生成 AI の学習結果の比較

本実験では、提案手法である WiT と、従来の大喜利生成 AI である NJM [3], GUMI-AE [4] を、同様のデータセットを用いて学習しその結果を比較する。GUMI-AE の Autoencoder のエンコーダは、5 層の畳み込み層と 1 層の全結合層、デコーダは 1 層の全結合層と 5 層の畳み込み層から構成され、エンコーダの出力次元数は 16,384 とした。Autoencoder は実験 2 で使用したデータセットと同様の画像で学習している。NJM および GUMI-AE は、ResNet152 または Autoencoder のエンコーダ、2 層の全結合層と 1 層の LSTM 層で構成される。WiT, NJM, GUMI-AE のパラメータ数を表 3 に

示す。本実験で使用するデータセット、学習反復回数、バッチサイズなどの条件は実験 2 と同様である。

学習結果を図 6 に示す。図 6 の縦軸は学習損失、横軸は学習反復回数、赤線は層数 $N = 5$ の Vision Transformer (ViT) をファインチューニングした WiT、緑線は層数 $N = 1$ でファインチューニングを行っていない WiT、青線は GUMI-AE、水色線は NJM である。図 6 の緑線、青線、水色線に着目すると、学習損失が Attention Block の層数 $N = 5$ の WiT, NJM, GUMI-AE の順に小さくなっていることがわかる。表 3 に示すように、これらのモデルのパラメータ数には大差がないことから、学習損失の差異は画像の特徴抽出器による影響が大きいと考えられる。[4] における実験では、ポケットの画像で学習した Autoencoder のエンコーダを用いた GUMI-AE が、NJM と比較して低い学習損失を示していた。これは、[4] で使用した画像が ImageNet の画像と大きく乖離しており、学習データに特化した特徴抽出器が有効であったと考えられている。一方で、本実験においては、提案手法による前処理によって非現実画像がデータセットから除去され、ImageNet の画像とドメインが近くなったことで、ImageNet で事前学習された汎用的な画像特徴抽出器の有効性が高まったと考えられる。

5.4 実験 4: WiT と従来の大喜利生成 AI の生成した大喜利の面白さの比較

本実験では、実験 2、実験 3 で学習した大喜利生成 AI と一般的な大規模言語モデル、大喜利を事前学習した大規模言語モデル、人間が生成した大喜利の面白さを評価する。本研究では、大喜利生成 AI が出力した大喜利の評価にあたり、BLEU や CIDEr といった自動評価指標は使用しない。これらの指標は、主に画像キャプション生成のように一意に正解となる文章を定義できるタスクに適しているが、大喜利生成では同様の画像に対して多様で創造的な解答が成立し得る。したがって、単一の参照文との n-gram の一致に基づく自動評価では、ユーモアや創造性といった大喜利生成の本質的な要素を適切に捉えることができない。このような理由から、本研究では人間の主観的判断に基づく評価を採用し、大喜利生成 AI が出力した大喜利の定性的な評価と、面白さを評価するアンケートを実施した。

5.4.1 実験 4.1: 大喜利生成 AI が生成した大喜利の定性的な評価

本実験で比較対象とする大喜利生成手法は、以下の 7 種類である。人間、大規模言語モデルである Gemini (gemini-2.0-flash) [9], 事前に大喜利文章を学習した Watashiha Llama [10], 実験 2 で学習した Attention Block の層数 $N = 5$ で ViT をファインチューニングした WiT, ファインチューニングを行っていない WiT, 実験 3 で学習した NJM, GUMI-AE である。AI に入力するお題画像は、実験 2 で収集したボケテの画像のうち、学習に用いていない 1% の画像である。人間による大喜利は、画像に対応する大喜利の中からランダムに 1 件を選択した。Gemini には、画像とともに「この画像に対して、30 文字程度で一言面白文章を考えてください」というプロンプトを与えて大喜利を生成させた。Watashiha Llama は、文章によるお題に対し大喜利生成を事前学習した大規模言語モデルであるため、画像をキャプション生成モデルに入力し、得られた説明文をお題として与え大喜利を生成させた。キャプション生成モデルとして blip2-flan-t5-xxl [23] を用い、生成されたキャプションを elan-mt-bt-ja-en [24] によって日本語に変換した。blip2-flan-t5-xxl は、画像とテキストのマルチモーダル学習に基づき、画像から自然言語のキャプションを生成するモデルである。BLIP-2 アーキテクチャにより、視覚情報を効率的にテキスト表現に変換し、高度な言語生成能力を活かした自然で詳細なキャプション生成を可能にしている。elan-mt-bt-ja-en は大規模なコーパスとバイリンガルデータを用いて学習されており、意味を保持した自然な日本語への翻訳を可能としている。表 5 に、これらの AI によって生成されたキャプションを示す。ここで、画像が AI への入力であり、画像と同じ列の英文が blip2-flan-t5-xxl によって生成された画像のキャプション、和文が elan-mt-bt-ja-en によって翻訳されたキャプションである。表 5 から、blip2-flan-t5-xxl と elan-mt-bt-ja-en を用いることで、画像の状況に応じたキャプションが得られていることがわかる。WiT, NJM, GUMI-AE には画像を入力し大喜利を生成させた。

それぞれの手法に同じ画像を入力し生成された大喜利を表 6 に示す。ここで、列が大喜利生成 AI に入力した画像、行が同じ列の画像に対してそれぞれ大喜利生成 AI が生成した大喜利である。表 6 ではボケテから収集した画像を大喜利生成 AI への入力としたが、これらの画像の著作権は投稿者に帰属するため掲載できない。そこで、画像生成 AI に元のお題画像と類似した画像になるようプロンプトを与え生成された画像を表 6

表 5: キャプション AI が生成したキャプション



には掲載している。

WiT は、表 6(a) の猫が運転しているお題画像に対し「乗ってく?」という大喜利を生成している。この大喜利では、猫を人間と見立てる擬人化によって人間の行為へと積極的に読み替え、本来成立し得ない状況をあえて成立させる大喜利特有のズレを生み出している。次に、表 6(b) の三人の軍人が野原を進む画像に対しては「この後、彼らは爆発したのであった。」という大喜利を生成している。この大喜利では、戦場に居る人物から起こり得るストーリーを想像し、いわゆる「爆発オチ」に繋げている。さらに、表 6(c) の岩上の人物と水中の複数の人物という構図に対しては「シンクロの練習」という大喜利を生成している。この大喜利では、水中で整列するように見える人物群をシンクロナイズドスイミングの選手として、岩上の人物を指導者として見なす、画像中の物体の配置そのものを別の文脈へ変換する高度な見立てが働いている。

一方で、既存の大喜利生成 AI が生成した大喜利にはいくつかの問題が見られる。GUMI-AE は、表 6(c) に対し「お前、どこ中?」という大喜利を生成しているが、水中に複数の人物がいるという特徴が活用されておらず、画像内容との結び付きが十分ではない。NJM は、表 6(a) に対し「おい、その猫! 俺の車に乗って!!」という大喜利を生成しているが、この内容が成立するためには画像にもう一匹の猫が写っている必要があり、状況の前提が画像と整合していない。Watashiha Llama は、同じく表 6(a) に対し「トラックの窓に座っている猫は、猫じゃなかった」という大喜利を生成しているが、前提となるキャプションを誤って生成しており、その誤認に基づく大喜利になっているため、画像に適していない。Gemini は、表 6(c) に対し「『教官、温水プールじゃなかったんですか?』」という大喜利を生成しており、岩上の人物を教官、水中の人物を訓練生と読み替える発想は見られるものの、表 6(b) に対して生成した「撮影隊、道に迷ってガチの戦場へ…」は人物が撮

表 6: 大喜利生成 AI が生成した大喜利

	(a)	(b)	(c)
入力画像			
Caption	トラックの窓に座っている猫	軍服姿の男たちが 野原を歩いている	水の中の岩の上に 立つ男と人々の集団
WiT	乗ってく？	この後、彼らは 爆発したのであった。	シンクロの練習
GUMI-AE	あー、やっぱり俺達の方が いいっていうんだな'	お前、俺が見えるのか !?	お前、どこ中？
NJM	おい、そこの猫！ 俺の車に乗って !!	お前、今から神の使い方を 間違ってるらしいぞ	この後、海が割れ目に 入った事に気づく
Watashiha Llama	トラックの窓に座っている猫は、 猫じゃなかった	野原を歩く軍装の男たち 「うっ、足が …!」	岩が動いてしまって 皆岩から落ちたが、 俺だけ岩の上に残った
Gemini	「猫も免許取る時代？ どこまで行くの？」	「撮影隊、道に迷って ガチの戦場へ…」	「教官、温水プール じゃなかったんですか？」
human	ねずみとりする 公務員が許せない	熊が出たら 死んだ振りしろよ！	なぜか釣る気が起きない

影機材を持っていないため、画像理解に破綻がある。

これに対し、人間の生成した大喜利は、表 6(a) に対する「ねずみとりする公務員が許せない」のように、交通取り締まりの俗称である「ねずみとり」と猫の好物であるねずみの二重意味を掛け合わせた言語的工夫がされている。また、表 6(b) の「熊が出たら死んだ振りしろよ！」のように、自然な文脈推測に基づいたストーリーが見られる。さらに、表 6(c) に対する「なぜか釣る気が起きない」は、岩上の人物を釣り人と、水中の人物を魚と見なす擬獣化に基づく大喜利となっている。

これらを比較すると、WiT は人間の大喜利生成に見られる擬人化 (擬獣化)、視覚情報の別文脈への変換、画像に存在しないストーリーの想像といった高度な発想を獲得している一方、他手法では画像理解の不足や文脈の取り違いといった粗が散見される。このことから、WiT は大喜利生成という創造的タスクにおいて、人間に近い多様で柔軟な発想を展開できていると言える。

5.4.2 実験 4.2: 大喜利生成 AI が生成した大喜利のアンケートによる評価

本実験では、[3, 4] に倣い大喜利生成 AI が生成した大喜利の面白さをアンケートにより評価する。アンケートで比較する手法とお題画像として、実験 4.1 と同様の大喜利生成 AI と画像を用いる。アンケートでは、各回答ごとにこれらの画像からランダムに 1 枚を抽出し、それぞれの手法が大喜利を生成する。それぞれの手法が生成した大喜利を、どの手法が大喜利を生成したか人間には伏せランダムな順番で重複なく評価させる。アンケートの被験者には、お題画像とそれに対応する大喜利を提示し、被験者は各大喜利に対し「面白い」、「やや面白い」、「やや面白くない」、「面白くない」の 4 段階で評価を選択する。アンケートの参加人数は 16 人であり、総得票数は 634 件であった。

アンケートが有効に機能していることを確認するため、手法と面白さの 4 段階の評価が独立であるという帰無仮説のもとでカイ二乗検定を実施する。期待度数の最小値は 14.7 であり、カイ二乗検定の適用条件を満たして




図 7: 大喜利の面白さを評価するアンケートの結果

いた。その結果、有意水準 $\alpha = 0.05$ に対し $p = 6 \times 10^{-5}$ となり、帰無仮説は棄却された。このことから、手法によって投票カテゴリの分布が異なることが統計的に示されており、本アンケートは少なくとも手法間の面白さの差異を識別できていると言える。一方で、Cramér の $V = 0.16$ となっており、効果量は十分に大きいとは言えない。これは、本アンケートが主観的評価に基づく多カテゴリの選択問題であり、評価のばらつきが大きいことが原因であると考えられる。

図 7、表 7 にアンケート結果を示す。図 7 の横軸は大喜利生成手法を、縦軸は各評価項目に対する投票割合である。赤は「面白い」、緑は「やや面白い」、オレンジは「やや面白くない」、青は「面白くない」に対する投票割合である。表 7 はそれぞれの大喜利生成 AI に入力した画像と生成した大喜利、その大喜利がアンケートによって得られた評価である。表 7 では表 6 と同様に、画像生成 AI に元のお題画像と類似した画像になるようプロンプトを与え生成された画像を掲載している。図 7 から、WiT、NJM、GUMI-AE に着目すると、Attention Block の層数 $N = 5$ で ViT をファインチューニングした WiT に対して「面白い」と評価された割合が、他の手法と比べて高いことが確認できる。また、図 7 を比較すると、学習損失が同等のモデルに対する投票割合も概ね類似している。さらに、学習精度が最も高い Attention Block の層数 $N = 5$ で ViT をファインチューニングした WiT に対する「面白い」の投票割合が特に高いことから、学習精度と大喜利の面白さには一定の相関があると考えられる。

Watashiha Llama と WiT を比較すると、Watashiha Llama に対する「面白くない」の投票割合が高い傾向にあった。Watashiha Llama は画像のキャプション文から大喜利を生成しているが、このキャプション生成過程において画像の機微な情報が失われ、大喜利としての面白さが低下したと考えられる。表 7 の Watashiha Llama が生成した大喜利のうち「面白くない」と評価された大喜利のお題画像に対し、キャプション生成 AI は「a figure skater performing in the ice」というキャプションを生成している。この画像に対し人間は「おむつが限界のサイン」や「X染色体」といったポーズに基づいた大喜利を投稿しているが、Watashiha Llama は画像をキャプションに変換する過程でポーズの情報が損なわれたためこれに基づく面白い大喜利を生成できていない。この結果から、画像に対する大喜利生成は、画像と大喜利をそれぞれシングルモーダルで学習した AI を組み合わせるのではなく、画像と大喜利をマルチモーダルで学習することが有効であると言える。

次に、Gemini と WiT を比較すると、「面白い」に対する投票割合は両者で同等であった。これは、WiT は Gemini と比べてパラメータ数が大幅に少ないにもかかわらず、画像—大喜利データセットを用いて大喜利生成にドメインを特化して学習を行うことで、このドメインにおいては大規模言語モデルと同等の頻度で面白い大喜利を生成できることを示唆している。一方で、「面白くない」に対する投票割合は Gemini の方が WiT よりも低かった。これは、Gemini は大規模データセットで学習されているため文法的に誤った出力が少なく、結

表 7: 各手法が生成した大喜利とそのアンケート評価

面白い	面白くない
WiT (Layer:5, FC)	
 何とも思えないが 何とも言えない	 近くに将来の 自分を熱で描ける
WatashihaLlama	
 「さあ！私と一緒に 夢の国へ行こう！」	 指が冷たくて うまく弾けません
Gemini	
 「あの～、先生。 診察より雑談の方が 長いんですけど…」	 重いのは、恋の悩み じゃなくてボーリングの 球だった！

果として「面白くない」と評価される頻度が低くなったためであると考えられる。表 7 の「面白くない」と評価された大喜利に着目すると、WiT が生成した大喜利には文法的誤りが含まれているのに対し、Gemini が生成した大喜利は面白さには欠けるものの文法的には適切であった。WiT は Top-K サンプリングにより単語を選択するため文法的に不自然な文章が生成される場合があり、このような文章が「面白くない」と評価される一因になったと考えられる。以上より、Gemini と WiT は「面白い」と評価される大喜利を生成する頻度は同等である一方で、「面白くない」と評価される大喜

利の生成頻度は WiT の方が高く、生成された文章品質の安定性においては Gemini が優れていることが示唆される。

最後に、人間による大喜利と AI による大喜利を比較すると、「面白い」に対する投票割合は人間の方が高かった。このことは、本実験で用いたモデルおよびデータセットでは、人間と同等のユーモアを再現するには不十分であったことを示している。

6. まとめ

本研究では、Transformer を用いた新たな大喜利生成 AI である Warai Transformer (WiT) と、大喜利生成タスクに適したデータセットの構築手法を提案した。従来の大喜利生成 AI である NJM および GUMI-AE では、文章の特徴抽出器として LSTM を使用しており、LSTM の構造にによって高精度に大喜利生成を学習できていない問題が考えられた。WiT は、Transformer を文章と画像の特徴抽出器として用いることで、従来の大喜利生成 AI の問題の解消を試みる。

実験では、提案手法のフィルタリングにより、大喜利生成 AI の学習に不適切な画像を十分に除去できることを確認した。また、WiT は画像を入力するとその画像に対し適切な大喜利を生成すること、Cross Attention の Attention Map を用いることで大喜利の生成過程でモデルが単語と画像中のオブジェクトを関連付けて大喜利を生成していることを確認した。ただし、Attention Map の解析は可視化結果に基づく定性的な評価にとどまっており、モデルがどの程度一貫して視覚情報に基づいた生成を行っているかや、特定の視覚的特徴が生成結果に与える影響の強さについては、定量的に明らかにされていない。今後は、WiT が重要視している部分と画像中のオブジェクト領域との対応関係を定量的に評価する指標を導入することで、WiT における視覚情報と言語生成の関連性をより客観的に評価する必要がある。さらに、WiT を従来の大喜利生成 AI である NJM および GUMI-AE と比較した実験では、WiT が他手法を上回る学習精度を達成することを確認した。さらに、AI が生成した大喜利の面白さを評価するアンケートでは、WiT は従来の大喜利生成 AI と比べ高い頻度で面白い大喜利を生成可能であること、大規模言語モデルである Gemini と同等の頻度で面白いと評価される大喜利を生成可能であることを確認した。これらの結果は、大喜利という創造性を要する高度な言語生成タスクに対して、Transformer ベースの構造が有効に機能することを示唆している。

一方で、アンケートの結果からは、依然として人間と同程度の面白さを持つ大喜利の生成には至っておらず、さらなる性能向上が求められる。特に、これまでの大喜利生成 AI では単語の読み方の音韻情報を考慮しておらず、同音異義語を用いたダジャレ表現などに対して対応できないという課題がある。この課題に対しては、発音や読みを扱うモジュールを導入することで、音韻情報を考慮した大喜利が生成可能となると考えている。

また、アンケートではカイ二乗検定から手法によって投票カテゴリの分布が異なることを統計的に示しているが、Cramér の V は小さな値となっており、効果量が十分に大きいとは言えない。今後の研究では、より大規模な母集団に基づくアンケートを実施することで、今回得られた効果量が標本数の制約による推定誤差を含むものか、あるいは主観評価に固有の評価傾向を反映したものかを検証することが重要である。さらに、本研究で実施したアンケートでは、参加者は複数回の回答が可能となっており、また、投票カテゴリが順序尺度となっている。そのためカイ二乗検定では、参加者の評価の傾向と、投票カテゴリが持つ順序尺度としての情報を十分に反映した解析を行うことができなかった。今後の研究では、参加者の評価の傾向を踏まえた統計モデルを導入し、手法間の差異をより厳密に評価する必要がある。

大喜利生成 AI が生成した大喜利の面白さを定量的に評価することも重要な課題である。ボケてには投稿された大喜利の面白さを評価するシステムがあり、これを活用することで画像と文章のペアからそれが大喜利として面白いかな否かを分類する AI の構築が可能であると考えられる。このような AI が実現することで大喜利の定量的な評価のみならず、そのフィードバックに基づいて大喜利生成 AI を最適化することで出力の質を自律的に向上させる枠組みも構築可能であると考えられる。

参考文献


- [1] P. Esser, S. Kulal, A. Blattmann, R. Entezari, J. Müller, H. Saini, Y. Levi, D. Lorenz, A. Sauer, F. Boesel, D. Podell, T. Dockhorn, Z. English, and R. Rombach :Scaling rectified flow transformers for high-resolution image synthesis, Proc. the 41st International Conference on Machine Learning, vol.235, pp.12606-12633, 2024.
- [2] J. Copet, F. Kreuk, I. Gat, T. Remez, D. Kant, G. Synnaeve, Y. Adi, and A. Défossez :Simple and Controllable Music Generation, Proc. Neural Information Processing Systems, vol.36, pp.47704-47720, 2023.
- [3] 美濃口 宗尊, 吉田 光太, 螺良 和樹, 池谷 拓夢, 片岡 裕雄, 中村 明生:Neural Joking Machine, 精密工学会誌, vol.85, no.12, pp.1151-1156, 2019.
- [4] R. Yamatomi, S. Mahboubi, and H. Ninomiya :Generative Model of Suitable Meme Sentences for Images Using AutoEncoder, Proc. Pacific Rim International Conference on Artificial Intelligence, pp.237-248, 2023.
- [5] O. Vinyals, A. Toshev, S. Bengio and D. Erhan :Show and Tell: A Neural Image Caption Generator, Proc. Computer Vision and Pattern Recognition, pp.3156-3164, 2015.
- [6] G. E. Hinton, and R. R. Salakhutdinov :ucing the Dimensionality of Data with Neural Networks, Science, vol.313, no.5786, pp.504-507, 2006.
- [7] I. Goodfellow, Y. Bengio, A. Courville(著), 岩澤有祐, 鈴木雅大, 中山浩太郎, 松尾豊 (監訳), 黒滝紘生, 河野慎, 味曾野雅史, 保住純, 野中尚輝, 富山翔司, 角田貴大 (訳) : 深層学習, 株式会社ドワンゴ, March 2018.
- [8] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin :Attention is All you Need, Proc. Neural Information Processing Systems, pp.1-11, vol.30, 2017.
- [9] Google LLC :Gemini, <https://gemini.google.com/>, Last Accessed: 2025 年 11 月 24 日.
- [10] Hugging Face :watashiha/Watashiha-Llama-2-13B-Ogirisft, <https://huggingface.co/watashiha/Watashiha-Llama-2-13B-Ogirisft>, Last Accessed: 2025 年 11 月 24 日.
- [11] 株式会社オモロキ: ボケて, <https://bokete.jp/>, Last Accessed: 2025 年 11 月 24 日.
- [12] K. He, X. Zhang, S. Ren, and J. Sun :Deep Residual Learning for Image Recognition, Proc. Computer Vision and Pattern Recognition, pp.770-778, 2016.
- [13] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei :Imagenet: A large-scale hierarchical image database, Proc. Computer Vision and Pattern Recognition, pp. 248-255, 2009.
- [14] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby :An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, Proc. International Conference on Learning Representations, 2021.
- [15] J. L. Ba, J. R. Kiros, and G. E. Hinton :Layer Normalization, arXiv preprint, arXiv:1607.06450, 2016.
- [16] Kaggle :ImageNet 1000 (mini), <https://www.kaggle.com/datasets/figotin/imagenetmini-1000>, Last Accessed: 2026 年 2 月 13 日.
- [17] Kaggle :Tagged Anime Illustrations, <https://www.kaggle.com/datasets/mylesoneill/tagged-anime-illustrations>, Last Accessed: 2025 年 11 月 24 日.
- [18] Google LLC, :Detect text in images, <https://cloud.google.com/vision/docs/ocr>, Last Accessed: 2025 年 11 月 24 日.
- [19] GitHub Inc. :MeCab: Yet Another Part-of-Speech and Morphological Analyzer, <https://taku910.github.io/mecab>, Last Accessed: 2025 年 11 月 24 日.
- [20] Hugging Face :YANS-official/ogiri-keitai, <https://huggingface.co/YANS-official/ogiri-keitai>, Last

Accessed: 2026 年 2 月 13 日.

- [21] I. Loshchilov and F. Hutter :Decoupled Weight Decay Regularization, Proc. International Conference on Learning Representations, 2017.
- [22] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi :The Curious Case of Neural Text Degeneration, Proc. International Conference on Learning Representations, 2020.
- [23] Hugging Face :Salesforce/blip2-flan-t5-xxl, <https://huggingface.co/Salesforce/blip2-flan-t5-xxl>, Last Accessed: 2025 年 11 月 24 日.
- [24] Hugging Face :Mitsua/elan-mt-bt-ja-en, <https://huggingface.co/Mitsua/elan-mt-bt-ja-en>, Last Accessed: 2025 年 11 月 24 日.



山富 龍 2023 年 3 月湘南工科大学工学部情報工学科卒業。2025 年 3 月湘南工科大学大学院工学研究科電気情報工学専攻博士前期課程修了。2025 年 4 月湘南工科大学大学院工学研究科電気情報工学専攻博士後期課程入学。ニューラルネットワークの学習アルゴリズム、ニューラルネットワークを用いた画像に対する大喜利文章の生成に関する研究に従事。電子情報通信学会会員。



マハブービ シェヘラザード 2018 年 3 月湘南工科大学工学部情報工学科卒業。2020 年 3 月湘南工科大学大学院工学研究科電気情報工学専攻博士前期課程修了。2023 年 3 月湘南工科大学大学院工学研究科電気情報工学専攻博士後期課程終了。2023 年 4 月湘南工科大学情報学部情報学科助教。ニューラルネットワークの学習アルゴリズムに関する研究に従事。電子情報通信学会、IEEE 各会員。



二宮 洋 1998 年 3 月静岡大学大学院電子科学研究科電子応用工学専攻博士後期課程終了。1995 年 4 月日本学術振興会 (JSPS) の研究員 (DC1)。1998 年 4 月湘南工科大学工学部情報工学科専任講師。2023 年 4 月湘南工科大学情報学部情報工学科教授。ニューラルネットワークの学習アルゴリズム、進化計算の研究に従事。電子情報通信学会、情報処理学会、信号処理学会、IEEE 各会員。

(原稿受付: ; 原稿再受付:)