

平均化パラメータスナップショットを用いた 反復近似を行う確率的分散減少勾配法

Averaged parameter Snapshot Approximated Iteration SVRG

浅井傑¹
Suguru Asai

山富龍¹
Ryo Yamatomi

二宮洋¹
Hiroshi Ninomiya

湘南工科大学 AI R&D Center¹
Shonan Institute of Technology, AI R&D Center.

1 まえがき

近年、非線形問題の最適化において確率的勾配降下法 (SGD) が広く用いられてきた。しかし、SGD はミニバッチを用いて勾配を計算するため勾配分散が大きくなり、学習が不安定化する課題がある。これに対し、基準点における勾配および全データを使った勾配 (フル勾配) を用いて分散を削減する Stochastic Variance Reduced Gradient (SVRG) [1] や 1 エポック前の平均勾配でフル勾配を近似することで計算量を抑えつつ分散削減を図る No Full Grad SVRG[2] が提案されている。しかし、No Full Grad SVRG では、基準点におけるフル勾配と平均勾配との乖離により、学習が不安定化する場合がある。そこで本研究では、平均パラメータにおける勾配および平均勾配を用いる Averaged parameter Snapshot Approximated Iteration SVRG (ASAI-SVRG) を提案し、数値実験を通じてその有効性を示す。

2 ASAI-SVRG

SVRG は毎エポック開始時に 1 エポック前最後のパラメータを基準点として設定し、その基準点でのフル勾配を計算する。その後、毎イテレーション基準点でのミニバッチ勾配を計算し、基準点でのフル勾配およびミニバッチ勾配を No Full Grad SVRG は基準点におけるフル勾配と 1 エポック前の平均勾配との乖離に起因する学習の不安定化する課題がある。本研究では 1 エポック前の平均パラメータに基づく勾配および平均勾配を用いる ASAI-SVRG を提案する。エポック数を S 、1 エポックあたりのイテレーション数を t 、最適化するパラメータを $\mathbf{w}_s^t$ 、そして目的関数を f とし以下に ASAI-SVRG のアルゴリズムを示す。

Algorithm 1 ASAI-SVRG

Require: $\mathbf{w}_0^0$; 初期パラメータ, η ; 学習率, f ; 目的関数, $\mathcal{D}$; データセット, $\mathbf{a}_0 \leftarrow 0$, $\hat{\mathbf{x}}_0 \leftarrow \mathbf{w}_0^0$

- 1: **for** $s = 0, 1, \dots, S - 1$ **do**
- 2: $\mathbf{a}_s^0 \leftarrow 0$, $\mathbf{x}_s^0 \leftarrow 0$
- 3: **for** $t = 0, 1, \dots, T - 1$ **do**
- 4: ミニバッチ $\mathbb{B}_s^t$ をサンプリング $\subset \mathcal{D}$
- 5: $\mathbf{a}_s^{t+1} \leftarrow \frac{t}{t+1} \mathbf{a}_s^t + \frac{1}{t+1} \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t)$
- 6: $\mathbf{v}_s^t \leftarrow \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{x}}_s) + \hat{\mathbf{a}}_s$
- 7: $\mathbf{w}_s^{t+1} \leftarrow \mathbf{w}_s^t - \eta \mathbf{v}_s^t$
- 8: $\mathbf{x}_s^{t+1} \leftarrow \frac{t}{t+1} \mathbf{x}_s^t + \frac{1}{t+1} \mathbf{w}_s^{t+1}$
- 9: **end for**
- 10: $\hat{\mathbf{a}}_{s+1} \leftarrow \mathbf{a}_s^T$, $\hat{\mathbf{x}}_{s+1} \leftarrow \mathbf{x}_s^T$
- 11: **end for**
- 12: **return** $\mathbf{w}_s^T$

No Full Grad SVRG は 1 エポック前の平均勾配 $\mathbf{a}_{s-1}^T$ を、基準点 $\hat{\mathbf{w}}_s^t$ におけるフル勾配の近似として利用する。

$$\mathbf{v}_s^t = \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{w}}_s) + \hat{\mathbf{a}}_s. \quad (1)$$

$\hat{\mathbf{w}}_s^t$ は軌跡 $\mathbf{w}_{s-1}^0, \mathbf{w}_{s-1}^1, \dots, \mathbf{w}_{s-1}^T$ の端点であり、この点でのフル勾配と平均勾配で乖離が生じやすい。一方、ASAI-SVRG では前エポックの平均パラメータを基準点として用いる。

$$\mathbf{v}_s^t = \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{x}}_s) + \hat{\mathbf{a}}_s. \quad (2)$$

端点 $\mathbf{w}_{s-1}^T$ が学習反復によって外れ値的な振る舞いを示した場合、誤った基準点になる。これに対し、平均パラメータ $\mathbf{x}_{s-1}^T$ は前エポックの全反復の平均であるため、個々の更新による変動の影響を平滑化して打ち消す効果がある。その結果 1 エポック前の平均勾配 $\mathbf{a}_{s-1}^T$ が平均パラメータ $\mathbf{x}_{s-1}^T$ によるフル勾配をより正確に近似できると考えられる。

3 実験

本実験では、CIFAR10 を用いて ASAI-SVRG の有効性を評価する。比較手法として SGD, SVRG[1], No Full Grad SVRG[2] を用いる。分類モデルには畳み込み層 3 層の 128-100-10 の CNN モデルを採用し、エポックを 500 回、学習率は 0.001、バッチサイズは 64 とした。実験結果の縦軸は予測精度、横軸は各手法の計算量をそろえるために、全データに対しての勾配計算回数をを用いる。

実験結果を図 1 に示す。図 1 より提案手法 ASAI-SVRG は従来手法に比べて誤差推移の振動が少なく、安定した学習が可能であることが確認できる。また、収束速度においても SGD と同等であることから、SGD とほぼ同等の計算コストで勾配分散を低減できていると考えられる。




図 1 実験結果

4 まとめ

本研究では、No Full Grad SVRG の学習安定化を目指し、平均化パラメータをスナップショットパラメータとして用いる ASAI-SVRG を提案し、数値実験によりその有効性を示した。

参考文献

- [1] R.Johnson, et al, NeurIPS, 2013.
- [2] D.Medyakov, et al, 2502.14648, 2025.
- [3] A.Krizhevsky, Technical Report, University of Toronto, 2009.