

Polyak-Ruppert Averagingを用いた勾配分散低減勾配法

Polyak-Ruppert Averaging No Full Grad SVRG

浅井傑
Suguru Asai

山富龍
Ryo Yamatomi

二宮洋
Hiroshi Ninomiya

湘南工科大学 AI R&D Center
Shonan Institute of Technology, AI R&D Center.

1 まえがき

近年、AIの最適化において確率的勾配降下法 (SGD) が広く用いられてきた。しかし、SGD はミニバッチを用いて勾配を計算するため勾配分散が大きくなり、学習が不安定化する場合がある。これに対し、基準点における勾配および全データを使った勾配 (フル勾配) を用いて分散を低減する Stochastic Variance Reduced Gradient (SVRG) や、1 エポック前の平均勾配でフル勾配を近似することで計算量を抑えつつ分散低減を図る No Full Grad SVRG が提案されている。しかし、No Full Grad SVRG では、基準点におけるフル勾配と平均勾配との乖離に起因して、学習が不安定化する場合がある。そこで本研究では、平均パラメータを基準点とする Polyak-Ruppert Averaging No Full Grad SVRG (Polyak-SVRG) を提案する。

2 Polyak-SVRG

本研究では、1 エポック前の平均パラメータを基準点とし、その点における勾配と平均勾配を利用する Polyak-SVRG を提案する。エポック数を S 、1 エポックあたりのイテレーション数を T 、とし Polyak-SVRG を Algorithm 1 に示す。

Algorithm 1 Polyak-SVRG

Require: $\mathbf{w}_0^0$; 初期パラメータ, η ; 学習率, f ; 目的関数, $\mathcal{D}$; データセット, $\hat{\mathbf{a}}_0 \leftarrow 0$, $\hat{\mathbf{x}}_0 \leftarrow \mathbf{w}_0^0$

- 1: **for** $s = 0, 1, \dots, S-1$ **do**
- 2: $\mathbf{a}_s^0 \leftarrow 0$, $\mathbf{x}_s^0 \leftarrow 0$
- 3: **for** $t = 0, 1, \dots, T-1$ **do**
- 4: ミニバッチ $\mathbb{B}_s^t \subset \mathcal{D}$ をサンプリング
- 5: $\mathbf{v}_s^t \leftarrow \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{x}}_s) + \hat{\mathbf{a}}_s$
- 6: $\mathbf{w}_s^{t+1} \leftarrow \mathbf{w}_s^t - \eta \mathbf{v}_s^t$
- 7: $\mathbf{a}_s^{t+1} \leftarrow \frac{t}{t+1} \mathbf{a}_s^t + \frac{1}{t+1} \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t)$
- 8: $\mathbf{x}_s^{t+1} \leftarrow \frac{t}{t+1} \mathbf{x}_s^t + \frac{1}{t+1} \mathbf{w}_s^{t+1}$
- 9: $\hat{\mathbf{a}}_{s+1} \leftarrow \mathbf{a}_s^T$, $\hat{\mathbf{x}}_{s+1} \leftarrow \mathbf{x}_s^T$
- 10: **return** $\mathbf{x}_s^T$

SVRG[1] は、1 エポック前の最後のイテレーションのパラメータ $\mathbf{w}_{s-1}^T$ を基準点 $\hat{\mathbf{w}}_s$ とし、基準点における勾配とフル勾配を用いて分散を低減した補正勾配 $\mathbf{v}_s^t$ を計算する。SVRG の補正勾配を (1) を示す。

$$\mathbf{v}_s^t = \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{w}}_s) + \nabla f_{\mathcal{D}}(\hat{\mathbf{w}}_s). \quad (1)$$


No Full Grad SVRG[2] は 1 エポック前の平均勾配 $\mathbf{a}_{s-1}^T$ を基準点 $\hat{\mathbf{w}}_s^t$ におけるフル勾配の近似として利用する。No Full Grad SVRG の補正勾配を (2) に示す。

$$\mathbf{v}_s^t = \nabla f_{\mathbb{B}_s^t}(\mathbf{w}_s^t) - \nabla f_{\mathbb{B}_s^t}(\hat{\mathbf{w}}_s) + \hat{\mathbf{a}}_s. \quad (2)$$

ここで $\hat{\mathbf{w}}_s$ は、前エポックのパラメータの軌跡 $\mathbf{w}_{s-1}^0, \mathbf{w}_{s-1}^1, \dots, \mathbf{w}_{s-1}^T$ の端点であるため、この点におけるフル勾配と平均勾配の間に乖離が生じやすい。これに対し、提案手法 Polyak-SVRG では前エポックの平均パラメータ $\hat{\mathbf{x}}_s$ を基準点として用いる。平均パラメータは前エポックにおける全反復の平均であるため、個々の更新による急激な変動を平滑化する効果がある。その結果、1 エポック前の平均勾配 $\hat{\mathbf{a}}_s$ は、平均パラメータ $\hat{\mathbf{x}}_s$ におけるフル勾配をより正確に近似できると考えられる。

3 実験

本実験では、CIFAR10[3] の分類問題により Polyak-SVRG の有効性を評価する。比較手法には SGD, SVRG[1], No Full Grad SVRG[2] を用いる。分類モデルは畳み込み層 3 層の CNN モデル、学習率は 0.001、バッチサイズは 64 とする。実験結果を図 1 に示す。なお、各手法の計算コストを公平に比較するため、横軸は全データに対する勾配計算回数 (SGD における 1 エポック相当の計算量)、縦軸は予測精度としている。図 1 より、提案手法 Polyak-SVRG は従来手法に比べて精度推移の振動が少なく、安定した学習が可能であることが確認できる。



4 まとめ

図 1 実験結果

本研究では、No Full Grad SVRG の学習不安定化を改善することを目的とし、平均パラメータを基準点として用いる Polyak-SVRG を提案し、数値実験によりその有効性を示した。

謝辞 本研究は科研費 (23K11267) の補助を得た。

参考文献

- [1] R.Johnson, et al, NeurIPS, 2013.
- [2] D.Medynikov, et al, 2502.14648, 2025.
- [3] A.Krizhevsky, Technical Report, University of Toronto, 2009.